

CONȚINUTUL CURSULUI #5:

- II.3. Norme vectoriale și matriciale. Numere de condiționare. Condiționarea sistemelor.
- II.4. Metode iterative de rezolvare a sistemelor de ecuații liniare.
 - II.4.1. Metode iterative de aproximare.
 - II.4.2. Metoda Jacobi.
 - II.4.3. Metoda Jacobi pentru matrice diagonal dominante pe linii.
 - II.4.4. Metoda Jacobi relaxată.
 - II.4.5. Metoda Gauss - Seidel relaxată.

II.4. Norme vectoriale și matriciale. Numere de condiționare.
Condiționarea sistemelor.

Definiția (II.13.)

Fie $v \in \mathbb{R}^n$, $v = (v_1, \dots, v_n)^T$. Definim următoarele norme vectoriale:

- 1. $\|v\|_1 = \sum_{i=1}^n |v_i|$ - norma unu;
- 2. $\|v\|_\infty = \max_{i=1, n} |v_i|$ - norma infinit;
- 3. $\|v\|_2 = \sqrt{\sum_{i=1}^n v_i^2}$ - norma doi.

Definiția (II.14.)

Fiind dată o normă vectorială $\|\cdot\|$ pe spațiul \mathbb{R}^n , se definește norma matricială pe spațiul $\mathcal{M}_n(\mathbb{R})$ subordonată normei vectoriale pe \mathbb{R}^n astfel:

$$\|A\| = \sup_{v \in \mathbb{R}^n \setminus \{0\}} \frac{\|Av\|}{\|v\|} \tag{1}$$

Teorema (II.5.)

Norma matricială subordonată normei vectoriale $\|\cdot\|_\infty$ poate fi exprimată astfel:

$$\|A\|_\infty = \max_{i=1, n} \sum_{j=1}^n |a_{ij}|, \quad A \in \mathcal{M}_n(\mathbb{R}), \quad A = (a_{ij})_{i,j=1, n} \tag{2}$$

Demonstrație: Fie $v \in \mathbb{R}^n \setminus \{0\}$ și fie $\beta = \|v\|_\infty$, astfel că $|v_j| \leq \beta, j = 1, n$. Atunci

$$|(Av)_i| = \left| \sum_{j=1}^n a_{ij} v_j \right| \leq \sum_{j=1}^n |a_{ij}| |v_j| \leq \beta \sum_{j=1}^n |a_{ij}| \tag{3}$$

Rezultă

$$\frac{\|Av\|_\infty}{\|v\|_\infty} = \frac{\max_{i=1, n} |(Av)_i|}{\beta} \leq \frac{\max_{i=1, n} \beta \sum_{j=1}^n |a_{ij}|}{\beta} = \max_{i=1, n} \sum_{j=1}^n |a_{ij}| \tag{4}$$

Cum inegalitatea (4) are loc pentru $\forall v \in \mathbb{R}^n \setminus \{0\}$, atunci putem scrie

$$\sup_{v \in \mathbb{R}^n \setminus \{0\}} \frac{\|Av\|_\infty}{\|v\|_\infty} \leq C, \tag{5}$$

unde $C := \max_{i=1, n} \sum_{j=1}^n |a_{ij}|$. Să demonstrăm că $\sup_{v \in \mathbb{R}^n \setminus \{0\}} \frac{\|Av\|_\infty}{\|v\|_\infty} \geq C$

Fie m astfel încât $\max_{i=1, n} \sum_{j=1}^n |a_{ij}| = \sum_{j=1}^n |a_{mj}|$. Considerăm vectorul $w \in \mathbb{R}^n$ construit astfel:

$$w_j = \begin{cases} \frac{|a_{mj}|}{a_{mj}}, & a_{mj} \neq 0 \\ 0, & a_{mj} = 0. \end{cases} \tag{6}$$

Atunci $\|w\|_\infty = \max_{i=1, n} |w_i| = \max_{i=1, n} \frac{|a_{mi}|}{|a_{mi}|} = 1$ și

$$\begin{aligned}\|Aw\|_{\infty} &= \max_{i=\overline{1,n}} |(Aw)_i| = \max_{i=\overline{1,n}} \left| \sum_{j=1}^n a_{ij} w_j \right| \geq \left| \sum_{j=1}^n a_{mj} w_j \right| \\ &= \left| \sum_{a_{mj} \neq 0} a_{mj} w_j \right| = \left| \sum_{a_{mj} \neq 0} a_{mj} \frac{|a_{mj}|}{a_{mj}} \right| = \sum_{j=1}^n |a_{mj}| = C\end{aligned}$$

sau

$$\frac{\|Aw\|_{\infty}}{\|w\|_{\infty}} \geq C \quad (7)$$

Am găsit astfel un vector $w \in \mathbb{R}^n$ care satisface inegalitatea (7), deci

$$\sup_{v \in \mathbb{R}^n \setminus \{0\}} \frac{\|Av\|_{\infty}}{\|v\|_{\infty}} \geq C \quad (8)$$

Din relațiile (5), (8) rezultă egalitatea

$$\sup_{v \in \mathbb{R}^n \setminus \{0\}} \frac{\|Av\|_{\infty}}{\|v\|_{\infty}} = C. \quad (9)$$

Teorema (II.6.)

Norma matricială subordonată normei vectoriale $\|\cdot\|_1$ poate fi exprimată prin relația $\|A\|_1 = \max_{j=\overline{1,n}} \sum_{i=1}^n |a_{ij}|$, $A \in \mathcal{M}_n(\mathbb{R})$, $A = (a_{ij})_{i,j=\overline{1,n}}$

Propoziția (II.4.)

Fie $B \in \mathcal{M}_n(\mathbb{R})$ simetrică. Atunci $\exists B = \{w_1, w_2, \dots, w_n\} \subset \mathbb{R}^n$ o bază ortonormată formată din vectori proprii ai matricei B , atașați valorilor proprii $\lambda_1, \lambda_2, \dots, \lambda_n$.

Teorema (II.7.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ și $\lambda_i^B, i = \overline{1,n}$ valorile proprii asociate matricei simetrice $B = A^T A$. Atunci

$$\|A\|_2 = \max_{i=\overline{1,n}} \sqrt{\lambda_i^B} \quad (10)$$

Demonstrație: Cum $B = A^T A \Rightarrow B$ este simetrică. Mai mult,

$$\langle Bv, v \rangle = \langle A^T A v, v \rangle = \langle Av, Av \rangle = \|Av\|_2^2 \geq 0, \forall v \in \mathbb{R}^n \Rightarrow$$

B este semipozitiv definită, iar conform Prop. (II.3.) b) rezultă că $\lambda_i^B \geq 0, \forall i = \overline{1,n}$, unde λ_i^B reprezintă valorile proprii asociate matricei B . Fie $v \in \mathbb{R}^n \setminus \{0\}$, atunci conform Prop. (II.4.) există o bază ortonormată $B = \{w_1, w_2, \dots, w_n\}$ formată din vectori proprii ai matricei B , în raport cu care v se scrie ca o combinație liniară de aceștia, i.e.

$$v = \sum_{i=1}^n c_i w_i, c_i \in \mathbb{R}, i = \overline{1,n}$$

Dar $Bw_i = \lambda_i^B w_i, i = \overline{1,n}$, astfel că

$$Bv = B \left(\sum_{i=1}^n c_i w_i \right) = \sum_{i=1}^n c_i (Bw_i) = \sum_{i=1}^n c_i \lambda_i^B w_i.$$

Presupunem în continuare că $\lambda_n^B \geq \lambda_{n-1}^B \geq \dots \geq \lambda_1^B \geq 0$, atunci

$$\|Av\|_2^2 = \langle Av, Av \rangle = \langle v, A^T A v \rangle = \langle v, Bv \rangle \quad (11)$$

$$= \left\langle \sum_{i=1}^n c_i w_i, \sum_{j=1}^n c_j \lambda_j^B w_j \right\rangle = \sum_{i,j=1}^n c_i c_j \lambda_j^B \langle w_i, w_j \rangle = \sum_{i,j=1}^n c_i c_j \lambda_j^B \delta_{ij} = \sum_{i=1}^n c_i^2 \lambda_i^B \leq \lambda_n^B \sum_{i=1}^n c_i^2 = \lambda_n^B \|v\|_2^2 \Rightarrow$$

$$\frac{\|Av\|_2}{\|v\|_2} \leq \sqrt{\lambda_n^B} \Rightarrow \sup_{v \in \mathbb{R}^n \setminus \{0\}} \frac{\|Av\|_2}{\|v\|_2} \leq \sqrt{\lambda_n^B} \Rightarrow \|A\|_2 \leq \sqrt{\lambda_n^B}$$

Pentru a demonstra egalitatea alegem $v = w_n \Rightarrow$

$$\begin{aligned}\frac{\|Av\|_2}{\|v\|_2} &= \frac{\|Aw_n\|_2}{\|w_n\|_2} = \|Aw_n\|_2 = \langle Aw_n, Aw_n \rangle = \langle w_n, Bw_n \rangle \\ &= \langle w_n, \lambda_n^B w_n \rangle = \lambda_n^B = \lambda_n^B \Rightarrow \|A\|_2 \geq \sqrt{\lambda_n^B}\end{aligned}$$

Din cele două inegalități rezultă

$$\|A\|_2 = \sqrt{\lambda_n^B} \quad (13)$$

Teorema (II.8.)

Fiind dată norma $\| \cdot \|$ subordonată normei vectoriale, atunci

$$\| AB \| \leq \| A \| \| B \|, \forall A, B \in \mathcal{M}_n(\mathbb{R}) \quad (14)$$

Demonstrație: Deoarece

$$\| A \| = \sup_{w \in \mathbb{R}^n \setminus \{0\}} \frac{\| Aw \|}{\| w \|} \Rightarrow \frac{\| Aw \|}{\| w \|} \leq \| A \| \Rightarrow \| Aw \| \leq \| A \| \| w \|$$

Astfel că

$$\| A(Bv) \| \leq \| A \| \| Bv \| \leq \| A \| \| B \| \| v \| \Rightarrow$$

$$\frac{\| ABv \|}{\| v \|} \leq \| A \| \| B \|, \forall v \in \mathbb{R}^n \setminus \{0\} \Rightarrow \quad (15)$$

$$\sup_{v \in \mathbb{R}^n \setminus \{0\}} \frac{\| ABv \|}{\| v \|} \leq \| A \| \| B \| \Rightarrow \| AB \| \leq \| A \| \| B \| \quad (16)$$

Teorema (II.9.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ nesingulară, atunci

$$\kappa_2(A) = \frac{\sqrt{\lambda_n^B}}{\sqrt{\lambda_1^B}} \quad (20)$$

unde $\lambda_n^B \geq \lambda_{n-1}^B \geq \dots \geq \lambda_1^B > 0, \lambda_i^B, i = \overline{1, n}$ sunt valorile proprii ale matricei $B = A^T A$.

Demonstrație: Dacă $v \in \mathbb{R}^n \setminus \{0\}$ și A nesingulară, atunci

$$0 < \| Av \|^2 = \langle Av, Av \rangle = \langle B^T Bv, v \rangle,$$

deci B este pozitiv definită, astfel că valorile proprii $\lambda_i > 0, i = \overline{1, n}$.

Vom demonstra următorul rezultat:

Dacă $\lambda \in \sigma(A^T A)$, atunci $\frac{1}{\lambda} \in \sigma(A^{-T} A^{-1})$.

Într-adevăr, fie $\lambda \in \sigma(A^T A)$, atunci λ este soluția ecuației $\det(A^T A - \lambda I_n) = 0$ sau $\det(A^T(I_n - \lambda A^{-T} A^{-1})A) = 0$.

Definiția (II.15.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice nesingulară. Definim numărul de condiționare al matricei A relativ la norma $\| \cdot \|_p, p \in \{1, 2, \infty\}$ numărul notat prin $\kappa_p(A)$ definit astfel:

$$\kappa_p(A) = \| A \|_p \| A^{-1} \|_p \quad (17)$$

sau la general

$$\kappa(A) = \| A \| \| A^{-1} \| \quad (18)$$

unde $\| \cdot \|$ este o normă subordonată unei norme vectoriale.

Obs.: Este evident că $\kappa(A^{-1}) = \kappa(A)$. Mai mult, deoarece

$$1 = \| AA^{-1} \| \leq \| A \| \| A^{-1} \| = \kappa(A) \Rightarrow \kappa(A) \geq 1. \quad (19)$$

Curs #5

November 7, 2018 9 / 39

Curs #5

November 7, 2018 10 / 39

Deoarece A este nesingulară (i.e. $\det(A) \neq 0$) din ultima relație rezultă

$$\det(I_n - \lambda A^{-T} A^{-1}) = 0$$

Mai mult, deoarece $\lambda > 0$ din relația de mai sus rezultă:

$$\det(A^{-T} A^{-1} - \frac{1}{\lambda} I_n) = 0, \quad (21)$$

deci $\frac{1}{\lambda} \in \sigma(A^{-T} A^{-1})$. Astfel că dacă $\sigma(A^T A) = \{\lambda_1, \lambda_2, \dots, \lambda_n\}$, atunci $\sigma((A^{-1})^T A^{-1}) = \{\frac{1}{\lambda_1}, \frac{1}{\lambda_2}, \dots, \frac{1}{\lambda_n}\} \Rightarrow$

$$\kappa_2(A) = \| A \|_2 \| A^{-1} \|_2 = \max_{1 \leq i \leq n} \sqrt{\lambda_i} \cdot \max_{1 \leq j \leq n} \frac{1}{\sqrt{\lambda_j}} = \frac{\sqrt{\lambda_n}}{\sqrt{\lambda_1}} \quad (22)$$

Să considerăm o abatere a datelor de intrare atât în matricea A cât și în vectorul termenilor liberi

$$A \rightarrow A + \delta A; \quad b \rightarrow b + \delta b \quad (23)$$

Această perturbare va afecta soluția $x \rightarrow x + \delta x$, deci soluția perturbată $x + \delta x$ verifică sistemul

Curs #5

November 7, 2018 11 / 39

Curs #5

November 7, 2018 12 / 39

$$(A + \delta A)(x + \delta x) = b + \delta b \quad (24)$$

Teorema (II.10.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ neregulară, $b \in \mathbb{R}^n \setminus \{0\}$ și fie sistemul $Ax = b$ și sistemul perturbat $(A + \delta A)(x + \delta x) = b + \delta b$, cu $\delta x, \delta b, \delta A \in \mathcal{M}_n(\mathbb{R})$.

Atunci soluția $x \in \mathbb{R}^n \setminus \{0\}$ și avem următoarea estimare

$$\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right) \quad (25)$$

Relația (25) ne indică faptul că eroarea relativă $\frac{\|\delta x\|}{\|x\|}$ a soluției sistemului

perturbat poate atinge valoarea însumată a erorilor relative $\frac{\|\delta A\|}{\|A\|}, \frac{\|\delta b\|}{\|b\|}$

amplificată cu valoarea numărului de condiționare $\kappa(A)$.

Un număr de condiționare mare presupune că la mici perturbări în datele de intrare se pot obține perturbări considerabile în soluția sistemului.

- Dacă $\kappa(A) \gg 1$ atunci eroarea relativă $\frac{\|\delta x\|}{\|x\|}$ poate fi mare. Vom spune în cazul acesta că sistemul este slab - condiționat;
- Dacă $\kappa(A) \approx 1$ atunci eroarea relativă $\frac{\|\delta x\|}{\|x\|}$ este mică și vom spune că sistemul este bine - condiționat;

Demonstrație Th. II.10.: Din (24) rezultă:

$$Ax + A\delta x + \delta Ax + \delta A\delta x = b + \delta b$$

Cum x verifică sistemul $Ax = b$ și neglijând produsul $\delta A\delta x$ în relația de mai sus se obține

$$A\delta x + \delta Ax \approx \delta b \quad (26)$$

de unde

$$\delta x \approx -A^{-1}\delta Ax + A^{-1}\delta b \quad (27)$$

Utilizând norma $\|\cdot\|$ în relația de mai sus rezultă

$$\|\delta x\| \leq \|A^{-1}\| \|\delta A\| \|x\| + \|A^{-1}\| \|\delta b\| \quad (28)$$

Prin urmare, cum $x \neq 0$ se obține estimarea

$$\begin{aligned} \frac{\|\delta x\|}{\|x\|} &\leq \|A^{-1}\| \|A\| \left(\frac{\|\delta A\|}{\|A\|} + \|A^{-1}\| \|A\| \frac{\|\delta b\|}{\|A\| \|x\|} \right) \\ &\leq \|A^{-1}\| \|A\| \left(\frac{\|\delta A\|}{\|A\|} + \frac{\|\delta b\|}{\|b\|} \right) \end{aligned} \quad (29)$$

În relația de mai sus s-a ținut seama că $\|b\| \leq \|A\| \|x\|$.

Exemplu: Fie sistemele $Ax = b$ și $(A + \delta A)(x + \delta x) = b + \delta b$ unde

$$A = \begin{pmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{pmatrix}; \quad A + \delta A = \begin{pmatrix} 10 & 7 & 8,1 & 7,2 \\ 7,08 & 5,04 & 6 & 5 \\ 8 & 5,98 & 9,89 & 9 \\ 6,99 & 4,99 & 9 & 9,98 \end{pmatrix}; \quad (30)$$

$$b = \begin{pmatrix} 32 \\ 23 \\ 33 \\ 31 \end{pmatrix}; \quad b + \delta b = \begin{pmatrix} 32,1 \\ 22,9 \\ 33,1 \\ 30,9 \end{pmatrix} \quad (31)$$

Soluția sistemului $Ax = b$ este $x = (1; 1; 1; 1)^T$, iar soluția sistemului $(A + \delta A)(x + \delta x) = b + \delta b$ este $x + \delta x \approx (333; -550; 144; -85)^T$. Se observă că o perturbație mică în datele de intrare produce perturbație considerabilă în soluție. Numărul de condiționare este $\kappa_2(A) = 2984 \gg 1$, deci sistemul inițial este slab-condiționat.

II.4.1. Metode iterative de aproximare.

Fie $A, B \in \mathcal{M}_n(\mathbb{R})$, $a, b \in \mathbb{R}^n$. Considerăm sistemul compatibil determinat

$$Ax = a \quad (32)$$

și un sistem echivalent

$$x = Bx + b \quad (33)$$

Definiția (II.16.)

O metodă iterativă de aproximare a soluției sistemului de ecuații liniare (32) presupune construcția unui șir recurent $(x^{(k)})_{k \in \mathbb{N}}$ conform formulei:

$$x^{(k+1)} = Bx^{(k)} + b, \quad x^{(0)} \in \mathbb{R}^n \text{ arbitrar} \quad (34)$$

Metoda iterativă (34) este convergentă dacă și numai dacă $\lim_{k \rightarrow \infty} x^{(k)} = x$, unde x este soluția sistemului (32).

Definiția (II.17.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$. Se definește raza spectrală $\rho(A)$ a matricei A astfel:

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i| \quad (35)$$

unde $\lambda_i \in \sigma(A)$, $i = \overline{1, n}$. Dacă $\lambda = a + bi \in C$ atunci $|\lambda| = \sqrt{a^2 + b^2}$.

Definiția (II.18.)

Matricea $A \in \mathcal{M}_n(\mathbb{R})$ se numește convergentă dacă șirul de matrice format din puterile A^k ale matricei A este convergent la matricea nulă (sau componentele puterii matricei A tind la zero). Vom scrie:

$$\lim_{k \rightarrow \infty} A^k = O_n \quad (36)$$

sau

$$\lim_{k \rightarrow \infty} (A^k)_{ij} = 0, \quad i, j = \overline{1, n} \quad (37)$$

Propoziția (II.5.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$. Următoarele afirmații sunt echivalente:

- a) A este o matrice convergentă;
- b) $\lim_{k \rightarrow \infty} \|A^k\| = 0$;
- c) $\lim_{k \rightarrow \infty} A^k x = 0_n, \forall x \in \mathbb{R}^n$;
- d) $\rho(A) < 1$.

Propoziția (II.6.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$. Atunci

$$\rho(A) \leq \|A\| \quad (38)$$

pentru orice normă matriceală $\|\cdot\|$ subordonată unei norme vectoriale.

Demonstrație: Fie $\lambda \in \sigma(A)$ și fie x vectorul propriu asociat valorii proprii λ cu proprietatea $\|x\| = 1$. Atunci $Ax = \lambda x$ de unde rezultă

$$\|Ax\| = |\lambda| \|x\| = |\lambda|$$

Pe de altă parte

$$\|Ax\| \leq \|A\| \|x\| = \|A\|$$

Din aceste relații rezultă $\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda| \leq \|A\|$.

Propoziția (II.7.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ cu $\|A\| < 1$, atunci

$$\exists (I_n - A)^{-1} \text{ și } \|(I_n - A)^{-1}\| \leq \frac{1}{1 - \|A\|} \quad (39)$$

Demonstrație: Dacă $\lambda_i, i = \overline{1, n}$ sunt valorile proprii ale matricei A atunci $1 - \lambda_i, i = \overline{1, n}$ sunt valorile proprii ale matricei $I_n - A$. Deoarece $\rho(A) < 1$ rezultă $|\lambda_i| < 1, i = \overline{1, n}$, iar $1 - \lambda_i \neq 0, i = \overline{1, n}$, deci $I_n - A$ este inversabilă. În continuare să observăm următoarea egalitate:

$$(I_n - A)(I_n + A + A^2 + \dots + A^{k-1}) = I_n - A^k \quad (40)$$

$$I_n + A + A^2 + \dots + A^k = (I_n - A)^{-1}(I_n - A^{k+1}) \quad (41)$$

Trecând la limită în relația de mai sus și ținând cont că $\lim_{k \rightarrow \infty} A^{k+1} = 0_n$ se obține următoarea estimare:

$$\| (I_n - A)^{-1} \| = \left\| \sum_{k=0}^{\infty} A^k \right\| \leq \sum_{k=0}^{\infty} \| A^k \| \leq \sum_{k=0}^{\infty} \| A \|^k = \frac{1}{1 - \| A \|} \quad (42)$$

Teorema (II.11.)

Fie $A \in \mathcal{M}_n(\mathbb{R})$ inversabilă, $a \in \mathbb{R}^n$ și o metodă iterativă (34) de aproximare a soluției sistemului de ecuații liniare $Ax = a$ definită de sistemul echivalent $x = Bx + b$. Atunci metoda iterativă este convergentă dacă și numai dacă

$$\rho(B) < 1 \quad (43)$$

Demonstrație: Fie $x^{(0)} \in \mathbb{R}^n$

$$\begin{aligned} x^{(k)} - x &= Bx^{(k-1)} + b - x = Bx^{(k-1)} - Bx \\ &= B(x^{(k-1)} - x) = \dots = B^k(x^{(0)} - x) \Rightarrow \end{aligned} \quad (44)$$

$$\| x^{(k+1)} - x^{(k)} \| \leq \| B \| \| x^{(k)} - x^{(k-1)} \| = q \| x^{(k)} - x^{(k-1)} \|$$

Evaluăm $(I - B)(x^{(k)} - x)$:

$$\begin{aligned} (I - B)(x^{(k)} - x) &= x^{(k)} - Bx^{(k)} - x + Bx \\ &= x^{(k)} - Bx^{(k)} - b + x^{(k)} - x^{(k+1)} \Rightarrow \end{aligned}$$

$$\begin{aligned} x^{(k)} - x &= (I - B)^{-1}(x^{(k)} - x^{(k+1)}) \\ &= (I - B)^{-1}B(x^{(k-1)} - x^{(k)}) \Rightarrow \end{aligned}$$

$$\begin{aligned} \| x^{(k)} - x \| &\leq \| (I - B)^{-1}B \| \| x^{(k)} - x^{(k-1)} \| \\ &\leq \frac{q}{1 - q} \| x^{(k)} - x^{(k-1)} \| \leq \dots \leq \frac{q^k}{1 - q} \| x^{(1)} - x^{(0)} \| \end{aligned}$$

Deoarece $q \in (0, 1) \Rightarrow \lim_{k \rightarrow \infty} \frac{q^k}{1 - q} = 0 \Rightarrow (x^{(k)})_{k \geq 0}$ converge la x , deci metoda iterativă este convergentă.

$$\begin{aligned} \lim_{k \rightarrow \infty} x^{(k)} \rightarrow x &\Leftrightarrow \lim_{k \rightarrow \infty} B^k(x^{(0)} - x) = 0, \forall x^{(0)} \in \mathbb{R}^n \Leftrightarrow \\ &\Leftrightarrow \lim_{k \rightarrow \infty} B^k = 0_n \Leftrightarrow \rho(B) < 1 \quad (\text{conform Prop. II.5.}) \end{aligned}$$

Teorema (II.12.)

Dacă $\| B \| = q$, $q \in (0, 1)$, atunci metoda iterativă (34) este convergentă și are loc următoarea estimare a erorii:

$$\| x^{(k)} - x \| \leq \frac{q^k}{1 - q} \| x^{(1)} - x^{(0)} \|, \forall k \in \mathbb{N}^* \quad (45)$$

Demonstrație: Deoarece $\| B \| < 1$, atunci conform Prop. II.7. rezultă că $\exists (I - B)^{-1}$ și $\| (I - B)^{-1} \| \leq \frac{1}{1 - \| B \|} = \frac{1}{1 - q}$

Evaluăm diferența $x^{(k+1)} - x^{(k)}$:

$$\begin{aligned} x^{(k+1)} - x^{(k)} &= Bx^{(k)} + b - x^{(k)} = Bx^{(k)} - Bx^{(k-1)} \\ &= B(x^{(k)} - x^{(k-1)}) \Rightarrow \end{aligned}$$

II.4.2. Metoda Jacobi Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice inversabilă, $a \in \mathbb{R}^n$, atunci avem următoarele echivalențe:

$$Ax = a \Leftrightarrow -Ax = -a \Leftrightarrow x - Ax = x - a \Leftrightarrow x = (I - A)x + a. \quad (46)$$

Considerând $B = I - A$, $b = a$, obținem sistemul $x = Bx + b$ în baza căruia se construiește metoda iterativă Jacobi.

Conform Th. II.11. metoda Jacobi este convergentă dacă și numai dacă $\rho(B) < 1$. Mai mult, dacă $\| B \| = q \in (0, 1)$, atunci conform Th. II.12. rezultă că metoda Jacobi este convergentă și are loc estimarea:

$$\| x^{(k)} - x \| \leq \frac{q^k}{1 - q} \| x^{(1)} - x^{(0)} \|, \quad k \in \mathbb{N}^* \quad (47)$$

ALGORITM (Metoda Jacobi)

Date de intrare: $A = (a_{ij})_{i,j=\overline{1,n}} \in \mathcal{M}_n(\mathbb{R})$ - inv.; $a \in \mathbb{R}^n$; ε .

Date de ieșire: $x_{\text{aprox}} \in \mathbb{R}^n$; N .

STEP 1: Se determină $q = \|I - A\|$;

if $q \geq 1$ then

OUTPUT('Metoda Jacobi nu asigură conv.')

STOP

endif

STEP 2: Se inițializează $x^{(0)} = 0$; $k = 0$;

STEP 3: Determină: $B = I - A$; $b = a$;

STEP 4: do

$k = k + 1$;

$x^{(k)} = Bx^{(k-1)} + b$;

while $\frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\| \geq \varepsilon$;

STEP 5: $x_{\text{aprox}} = x^{(k)}$, $N = k$.

Curs #5

November 7, 2018 25 / 39

II.4.3. Metoda Jacobi pentru matrice diagonal dominante pe linii.

Metoda Jacobi poate fi aplicată doar pentru o clasă restrânsă de matrice. În cele ce urmează vom prezenta metoda Jacobi pentru o clasă de matrice, pentru care această metodă este convergentă.

Definiția (II.19.)

Fie $A = (a_{ij})_{i,j=\overline{1,n}} \in \mathcal{M}_n(\mathbb{R})$

a) Spunem că A este diagonal dominantă pe linii dacă

$$|a_{ii}| > \sum_{j=\overline{1,n}, j \neq i} |a_{ij}|, \quad i = \overline{1, n}$$

b) Spunem că A este diagonal dominantă pe coloane dacă

$$|a_{jj}| > \sum_{i=\overline{1,n}, i \neq j} |a_{ij}|, \quad j = \overline{1, n}$$

Curs #5

November 7, 2018 26 / 39

Fie $D = \text{diag}(A) = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$. Se observă că $|a_{ii}| > 0$, $i = \overline{1, n}$, deci D este inversabilă. Se construiesc următoarele echivalențe:

$$\begin{aligned} Ax = a &\Leftrightarrow D^{-1}Ax = D^{-1}a \Leftrightarrow x - D^{-1}Ax = x - D^{-1}a \\ &\Leftrightarrow x = (I - D^{-1}A)x + D^{-1}a \end{aligned}$$

Considerând $B = I - D^{-1}A$, $b = D^{-1}a$ se obține sistemul $x = Bx + b$.

Teorema (II.13.)

Fie sistemul $Ax = a$ cu A matrice nesingulară și diagonal dominantă pe linii, și sistemul echivalent $x = Bx + b$, unde $B = I - D^{-1}A$, $b = D^{-1}a$.

Fie $q = \|B\|_{\infty}$ și $(x^{(k)})_{k \in \mathbb{N}}$ definit prin formula

$$x^{(k)} = Bx^{(k-1)} + b \quad (48)$$

Atunci $q < 1$ și $\|x^{(k)} - x\|_{\infty} \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|_{\infty}$, $k \in \mathbb{N}^*$.

Curs #5

November 7, 2018 27 / 39

Demonstrație: Componentele matricei $B = I - D^{-1}A$ se pot reprezenta după cum urmează:

$$b_{ij} = \delta_{ij} - d_{ik}^{-1}a_{kj} = \delta_{ij} - \frac{a_{ij}}{a_{ii}} = \begin{cases} 0, & i = j \\ -\frac{a_{ij}}{a_{ii}}, & i \neq j \end{cases}$$

Pe de altă parte, evaluând norma infinit a matricei B , se obține:

$$\begin{aligned} q = \|B\|_{\infty} &= \max_{i=\overline{1,n}} \sum_{j=\overline{1,n}} |b_{ij}| = \max_{i=\overline{1,n}} \sum_{j=\overline{1,n}, j \neq i} \frac{|a_{ij}|}{|a_{ii}|} \Rightarrow \\ q &= \max_{i=\overline{1,n}} \frac{\sum_{j=\overline{1,n}, j \neq i} |a_{ij}|}{|a_{ii}|} < 1 \end{aligned}$$

Conform Th. II.12. rezultă că metoda iterativă este convergentă și are loc estimarea din enunț.

Curs #5

November 7, 2018 28 / 39

ALGORITM (Metoda Jacobi pentru matrice diagonal dominante pe linii)**Date de intrare:** $A = (a_{ij})_{i,j=\overline{1,n}} \in \mathcal{M}_n(\mathbb{R})$ - inv.; $a \in \mathbb{R}^n$; ε .**Date de ieșire:** $x_{aprox} \in \mathbb{R}^n$; N .**STEP 1:** for $i=\overline{1:n}$ doif $|a_{ii}| \leq \sum_{j=\overline{1,n}, j \neq i} |a_{ij}|$ then

OUTPUT('Matr. nu este diag. dom. pe linii')

STOP.

endif

endfor

STEP 2: Se inițializează: $x^{(0)} = 0$; $k = 0$;**STEP 3:** Determină: $b_{ij} = \delta_{ij} - \frac{a_{ij}}{a_{ii}}$, $i, j = \overline{1, n}$; $b_i = \frac{a_i}{a_{ii}}$, $i = \overline{1, n}$; $q = \|B\|_{\infty}$;**STEP 4:** do $k = k + 1$; $x^{(k)} = Bx^{(k-1)} + b$; (B, b au fost calculați la STEP 3)while $\frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|_{\infty} \geq \varepsilon$ **STEP 5:** $x_{aprox} = x^{(k)}$; $N = k$;**II.4.4. Metoda Jacobi relaxată.**Metoda Jacobi relaxată este o variantă îmbunătățită a metodei Jacobi și constă în introducerea unui parametru $\sigma > 0$, numit parametru de relaxare.Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice simetrică și pozitiv definită, $a \in \mathbb{R}^n$. Sistemul $Ax = b$ este echivalent cu $\sigma Ax = \sigma a$ sau $(I - \sigma A)x = x - \sigma a$, deci

$$x = B_{\sigma}x + b_{\sigma}, \quad \sigma > 0 \quad (49)$$

cu $B_{\sigma} = I - \sigma A$, $b_{\sigma} = \sigma a$. Pentru $\sigma = 1$ avem metoda Jacobi.**Teorema (II.14.)**Fie $\lambda_n \geq \lambda_{n-1} \geq \dots \geq \lambda_1 > 0$ valorile proprii ale matricei $A \in \mathcal{M}_n(\mathbb{R})$ simetrice și pozitiv definite. Atunci metoda Jacobi relaxată este convergentă dacă și numai dacă

$$\sigma \in \left(0, \frac{2}{\rho(A)}\right) \quad (50)$$

Mai mult, dacă $q = \rho(B_{\sigma}) = \max_{i=\overline{1,n}} |1 - \sigma \lambda_i|$, atunci $q < 1$ și avem următoarea estimare a erorii

$$\|x^{(k)} - x\|_A \leq \frac{q^k}{1-q} \|x^{(1)} - x^{(0)}\|_A \quad (51)$$

unde $\|x\|_A = \sqrt{Ax, x} = \sqrt{\sum_{i,j=1}^n a_{ij}x_i x_j}$.**Demonstrație:** Deoarece A este simetrică și pozitiv definită rezultă că A este inversabilă, deci sistemul $Ax = a$ admite soluția unică x .Metoda iterativă construită în baza formulei (49) este convergentă dacă și numai dacă $\rho(B_{\sigma}) < 1$. În cele ce urmează vom deduce condiția pe care trebuie să o satisfacă σ astfel încât $\rho(B_{\sigma}) < 1$. Valorile proprii ale matricei $I - \sigma A$ sunt $1 - \sigma \lambda_1, \dots, 1 - \sigma \lambda_n$. Într-adevar, fie λ este o valoare proprie a matricei A . Atunci

$$\det((I - \sigma A) - (1 - \sigma \lambda)I_n) = 0 \Leftrightarrow \det(A - \lambda I) = 0$$

Avem următoarele echivalențe

$$\rho(I_n - \sigma A) < 1 \Leftrightarrow \max_{i=\overline{1,n}} |1 - \sigma \lambda_i| < 1 \Leftrightarrow -1 < 1 - \sigma \lambda_i < 1, i = \overline{1, n}$$

Deoarece $\lambda_n \geq \lambda_{n-1} \geq \dots \geq \lambda_1 > 0 \Rightarrow$

$$1 > 1 - \sigma \lambda_1 \geq \dots \geq 1 - \sigma \lambda_n > -1 \Rightarrow$$

$$\left\{ \begin{array}{l} 1 > 1 - \sigma \lambda_1 \\ 1 - \sigma \lambda_n > -1 \end{array} \right. \Rightarrow \sigma \in \left(0, \frac{2}{\lambda_n}\right)$$

Astfel se demonstrează prima parte a teoremei.

Se observă că $q = \rho(B_\sigma) = \rho(I_n - \sigma A) < 1$. Pentru a demonstra formula (51) este necesar să demonstrăm, conform Th. II.11. că $\|B_\sigma\|_A = q$.

Deoarece matricea A este simetrică și pozitiv definită, atunci $\exists \mathcal{B} = \{u_1, \dots, u_n\} \subset \mathbb{R}^n$ o bază ortonormată formată din vectorii proprii asociați valorilor proprii $\lambda_i > 0, i = \overline{1, n}$.

În baza vectorilor proprii ortonormați, putem construi o bază A -ortonormată dacă alegem $v_i = \frac{u_i}{\sqrt{\lambda_i}}, i = \overline{1, n}$. Într-adevăr,

$$\begin{aligned} \langle Av_i, v_j \rangle &= \left\langle A \frac{u_i}{\sqrt{\lambda_i}}, \frac{u_j}{\sqrt{\lambda_j}} \right\rangle = \left\langle \lambda_i \frac{u_i}{\sqrt{\lambda_i}}, \frac{u_j}{\sqrt{\lambda_j}} \right\rangle \\ &= \frac{\lambda_i \delta_{ij}}{\sqrt{\lambda_i} \sqrt{\lambda_j}} = \begin{cases} 1, & i = j \\ 0, & i \neq j \end{cases} \end{aligned}$$

Fie $v \in \mathbb{R}^n \setminus \{0\}$. Atunci $\exists \alpha_i, i = \overline{1, n}$ astfel încât $v = \sum_{i=1}^n \alpha_i v_i$. Evaluăm

în continuare $\|v\|_A, \|B_\sigma v\|_A$:

$$\begin{aligned} \|v\|_A^2 &= \langle Av, v \rangle = \left\langle \sum_{i=1}^n \alpha_i Av_i, \sum_{j=1}^n \alpha_j v_j \right\rangle \\ &= \sum_{i,j=1}^n \alpha_i \alpha_j \langle Av_i, v_j \rangle = \sum_{i=1}^n \alpha_i^2 \end{aligned}$$

În mod analog se poate demonstra că

$$\|B_\sigma v\|_A^2 = \sum_{i=1}^n \alpha_i^2 (1 - \sigma \lambda_i)^2 \leq q^2 \sum_{i=1}^n \alpha_i^2 = q^2 \|v\|_A^2 \Rightarrow$$

$$\frac{\|B_\sigma v\|_A}{\|v\|_A} \leq q \Rightarrow \sup_{v \in \mathbb{R}^n \setminus \{0\}} \frac{\|B_\sigma v\|_A}{\|v\|_A} \leq q \Rightarrow$$

$$\|B_\sigma\|_A \leq q \quad (52)$$

Fie k astfel încât $|1 - \sigma \lambda_k| = q$.

$$\begin{aligned} \|B_\sigma v_k\|_A^2 &= \langle AB_\sigma v_k, B_\sigma v_k \rangle = \langle AB_\sigma \frac{u_k}{\sqrt{\lambda_k}}, B_\sigma \frac{u_k}{\sqrt{\lambda_k}} \rangle \\ &= \frac{1}{\lambda_k} \langle A(1 - \sigma \lambda_k) u_k, (1 - \sigma \lambda_k) u_k \rangle = (1 - \sigma \lambda_k)^2 \Rightarrow \\ \frac{\|B_\sigma v_k\|_A}{\|v_k\|_A} &= q \geq q \Rightarrow \|B_\sigma\|_A \geq q \end{aligned} \quad (53)$$

Din inegalitățile (52) și (53) rezultă $\|B_\sigma\|_A = q$.

Definiția (II.20.)

Numim parametru optim de relaxare pentru metoda Jacobi relaxată (îl notăm σ_O) acea valoare a lui σ pentru care $q = \|B_\sigma\|_A$ (îl notăm q_O) are valoare minimă.

Propoziția (II.8.)

Parametrul optim de relaxare σ_O , respectiv q_O se calculează conform relațiilor:

$$\sigma_O = \frac{2}{\lambda_n + \lambda_1}, \quad q_O = \frac{\lambda_n - \lambda_1}{\lambda_n + \lambda_1}$$

ALGORITM (Metoda Jacobi relaxată)

Date de intrare: $A \in \mathcal{M}_n(\mathbb{R})$ - sim. și poz. def.;
 $a \in \mathbb{R}^n$; ε .

Date de ieșire: $x_{\text{approx}} \in \mathbb{R}^n$; N .

STEP 1: Determină: σ_O, q_O ; $b_{ij} = \delta_{ij} - \sigma a_{ij}, i, j = \overline{1, n}$;
 $b_i = \sigma a_i, i = \overline{1, n}$;

STEP 2: Se inițializează: $x^{(0)} = 0$; $k = 0$;

STEP 3: do

$k = k + 1$

$x^{(k)} = B_\sigma x^{(k-1)} + b_\sigma$;

(B_σ, b_σ au fost calculați la STEP 1)

while $\frac{q_O}{1 - q_O} \|x^{(1)} - x^{(0)}\|_A \geq \varepsilon$

STEP 4: $x_{\text{approx}} = x^{(k)}$; $N = k$.

II.4.5. Metoda Gauss - Seidel relaxată.

Fie $A \in \mathcal{M}_n(\mathbb{R})$ o matrice simetrică și pozitiv definită, $a \in \mathbb{R}^n$ și $\sigma > 0$ parametru de relaxare. Descompunem matricea $A = L + D + R$. Matricea L este partea inferioară a matricei A , i.e. $l_{ij} = a_{ij}$, $i > j$, $l_{ij} = 0$ în rest. Matricea R este partea superioară matricei A , i.e. $r_{ij} = a_{ij}$, $i < j$, $r_{ij} = 0$ în rest. Matricea $D = \text{diag}(A)$, i.e. $d_{ii} = a_{ii}$, $d_{ij} = 0$, $i \neq j$.

Avem următoarele sisteme echivalente

$$\begin{aligned} Ax &= a \Leftrightarrow \sigma Ax = \sigma a \Leftrightarrow \sigma(L + D + R)x = \sigma a \Leftrightarrow \\ (\sigma L + D + (\sigma - 1)D + \sigma R)x &= \sigma a \Leftrightarrow \\ (\sigma L + D)x &= ((1 - \sigma)D - \sigma R)x + \sigma a \Rightarrow \end{aligned}$$

$$x = (\sigma L + D)^{-1}((1 - \sigma)D - \sigma R)x + (\sigma L + D)^{-1}\sigma a \Leftrightarrow x = B_\sigma x + b_\sigma$$

unde $B_\sigma = (\sigma L + D)^{-1}((1 - \sigma)D - \sigma R)$, $b_\sigma = (\sigma L + D)^{-1}\sigma a$

Teorema (II.15.)

Metoda Gauss - Seidel relaxată este convergentă dacă și numai dacă

$$\sigma \in (0, 2) \quad (54)$$

Dacă $q = \|B_\sigma\|_A$, atunci $q < 1$ și are loc următoarea estimare

$$\|x^{(k)} - x\|_A \leq \frac{q^k}{1 - q} \|x^{(1)} - x^{(0)}\|_A, \forall k \in \mathbb{N} \quad (55)$$

Componentele $x_i^{(k)}$ se pot calcula evitând calculul inversei matricei $\sigma L + D$. Avem

$$\begin{aligned} x^{(k)} &= B_\sigma x^{(k-1)} + b_\sigma \\ \Leftrightarrow (\sigma L + D)x^{(k)} &= ((1 - \sigma)D - \sigma R)x^{(k-1)} + \sigma a \Rightarrow \\ Dx^{(k)} &= -\sigma Lx^{(k)} + ((1 - \sigma)D - \sigma R)x^{(k-1)} + \sigma a \\ &= (1 - \sigma)Dx^{(k-1)} - \sigma Rx^{(k-1)} - \sigma Lx^{(k)} + \sigma a \Rightarrow \\ x^{(k)} &= (1 - \sigma)x^{(k-1)} + \sigma D^{-1}(a - Rx^{(k-1)} - Lx^{(k)}) \end{aligned}$$

Relația de mai sus scrisă pe componente este:

$$x_i^{(k)} = (1 - \sigma)x_i^{(k-1)} + \frac{\sigma}{a_{ii}} \left(a_i - \sum_{j=i+1}^n a_{ij}x_j^{(k-1)} - \sum_{j=1}^{i-1} a_{ij}x_j^{(k)} \right) \quad (56)$$

ALGORITHM (Metoda Gauss-Seidel relaxată) (Temă)