

Concepte și aplicații în Vederea Artificială

Bogdan Alexe

bogdan.alexe@fmi.unibuc.ro

Cursul 8

anul III, Opțional Informatică, semestrul I, 2018-2019



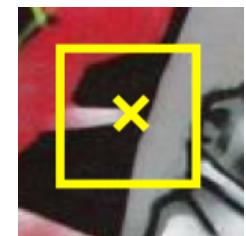
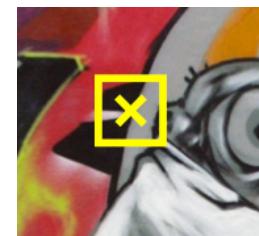
- compania WorldQuant organizează competiția "Alphathon Bucharest"
- premii în bani destinate studenților și absolvenților UB + UPB
- participanții vor trebui să construiască propriile modele matematice predictive.
- detalii pe worldquantvrc.com

Organizare

- următoarele 2 cursuri (28 nov, 5 dec)le ține Paul Irofti
- miercuri **14-16**, sala Google
- laborator **16-18**, sala 309
- pe 12 dec revenim la programul normal

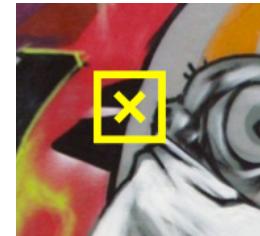
Cursul trecut

- trăsături locale: detectare + descriere
- detectorul Harris
- detectorul Harris Laplace

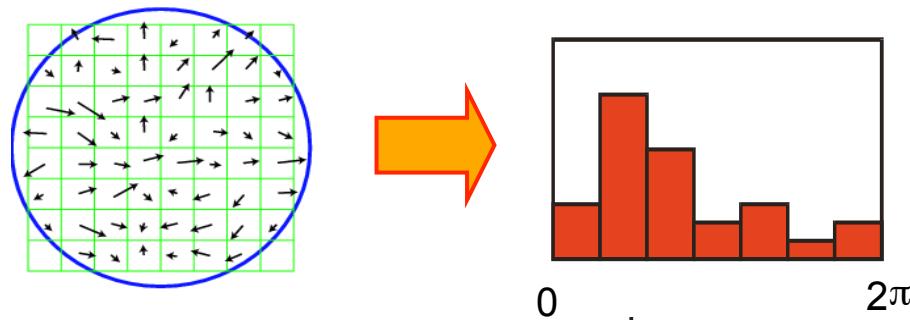


Cursul de azi

- detectorul Harris Laplace



- descriptorul SIFT



- concepte de bază în învățarea automată



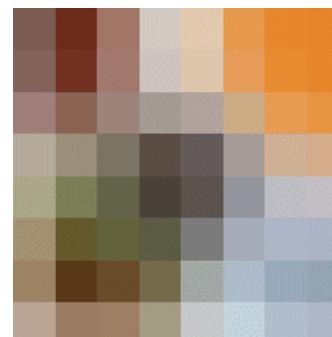
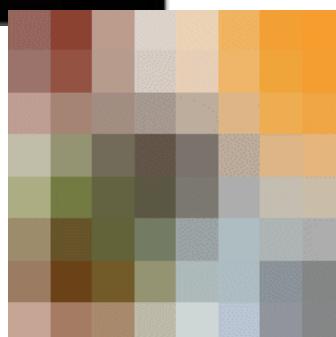
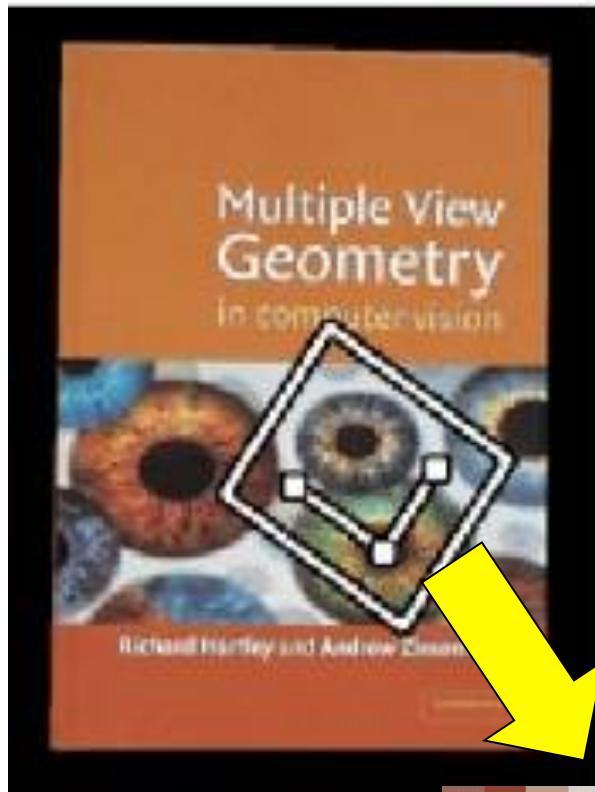
Learning machine

Trăsături locale

- trăsătură locală = o regiune din imagine cu proprietăți speciale, în sensul că poate fi detectată dacă imaginea suferă transformări geometrice sau fotometrice (nu foarte mari)

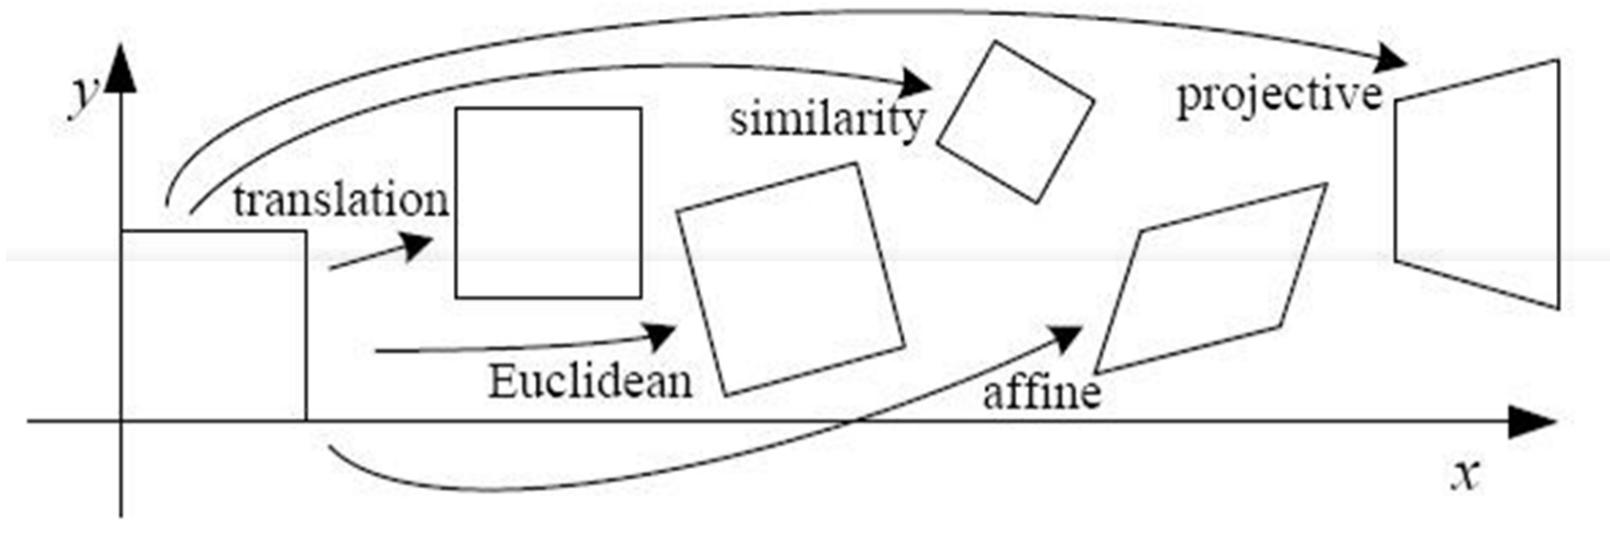


Transformări geometrice



Exemplu:
translație +
rotație +
scalare

Transformări geometrice



Transformări fotometrice



Detectorul de colțuri Harris

- 1) Calculează derivate parțiale I_x și I_y la fiecare pixel (x,y)
- 2) Calculează matricea M pentru o fereastră W centrată în fiecare pixel (x,y) din imagine
- 3) Calculează funcția cornerness R la fiecare pixel (x,y)
- 4) Găsește punctele pentru care R are valori foarte mari ($> \text{threshold}$).
- 5) Găsește maximele locale ale funcției, realizează suprimarea maximelor (non-maximum suppression)

Nu e invariant la scală -> pot rula detectorul la mai multe scale

Rezultate detector Harris



- localizare precisa;
- repetabilitate crescută;
- aceeași scală

Detectare de caracteristici locale

- puncte interesante detectate în două imagini



- vreau să găsesc perechile de puncte corespondente
- am nevoie de o descriere a unei regiuni din jurul punctului
- ideal, definesc o regiune invariantă la scală: pentru două puncte corespunzătoare din două imagini de zoom diferit le corespund aceleasi regiuni

Abordarea exhaustivă

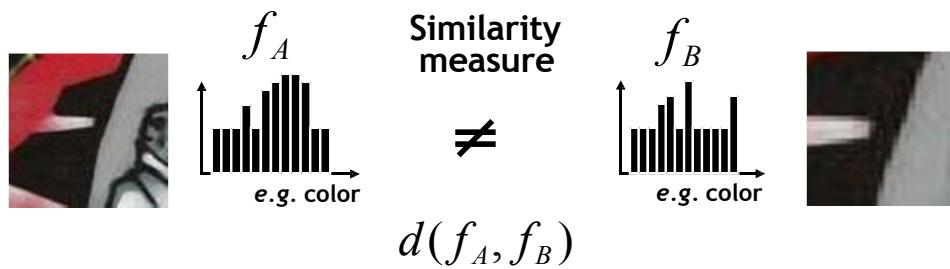
- algoritm multi-scale naiv de a compara două regiuni



- variez dimensiunea unei regiuni (cealaltă rămâne fixă), extrag din ambele regiuni descriptorul corespunzător (spre exemplu o histogramă de culori) și compar descriptorii

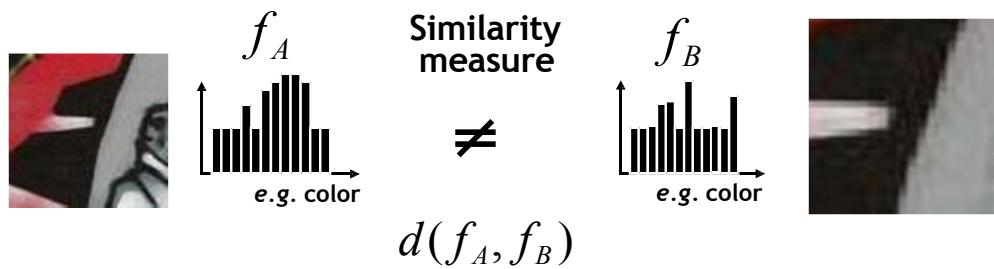
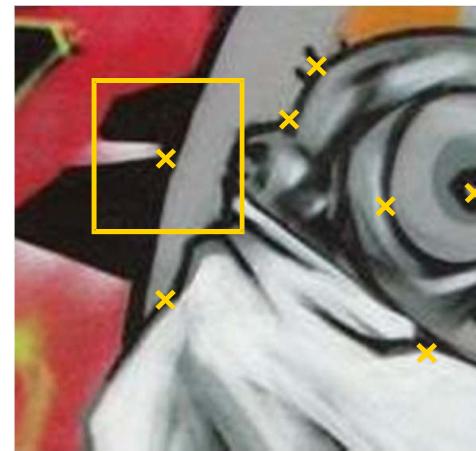
Abordarea exhaustivă

- algoritm multi-scale naiv de a compara două regiuni
- compar descriptori pentru regiuni scalate



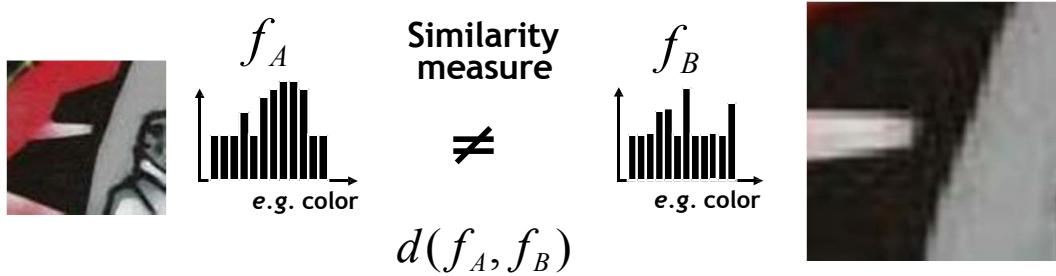
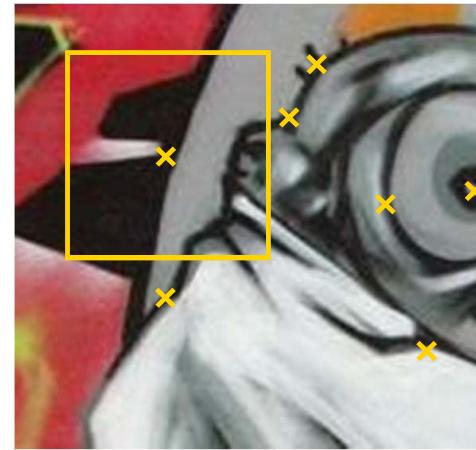
Abordarea exhaustivă

- algoritm multi-scale naiv de a compara două regiuni
- compar descriptori pentru regiuni scalate



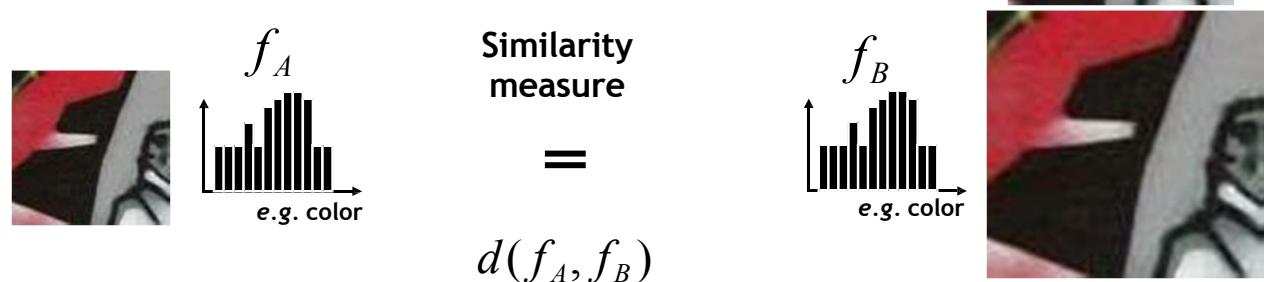
Abordarea exhaustivă

- algoritm multi-scale naiv de a compara două regiuni
- compar descriptori pentru regiuni scalate



Abordarea exhaustivă

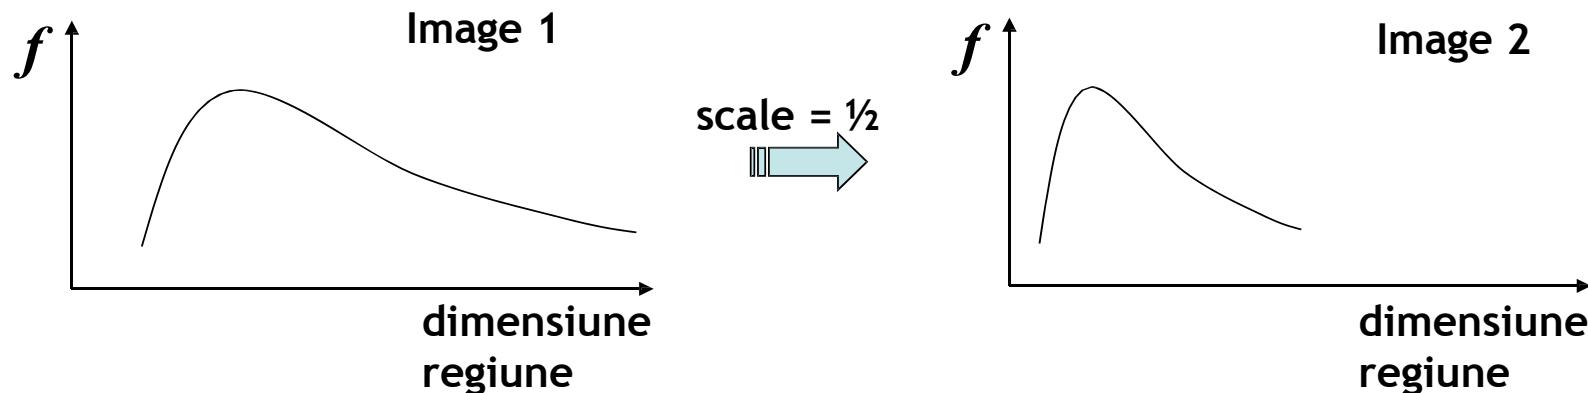
- algoritm multi-scale naiv de a compara două regiuni
- compar descriptori pentru regiuni scalate
- computațional inefficient
- pentru baze de date foarte mari nu se poate aplica pentru regăsire de obiecte



Selectia automată a scalei

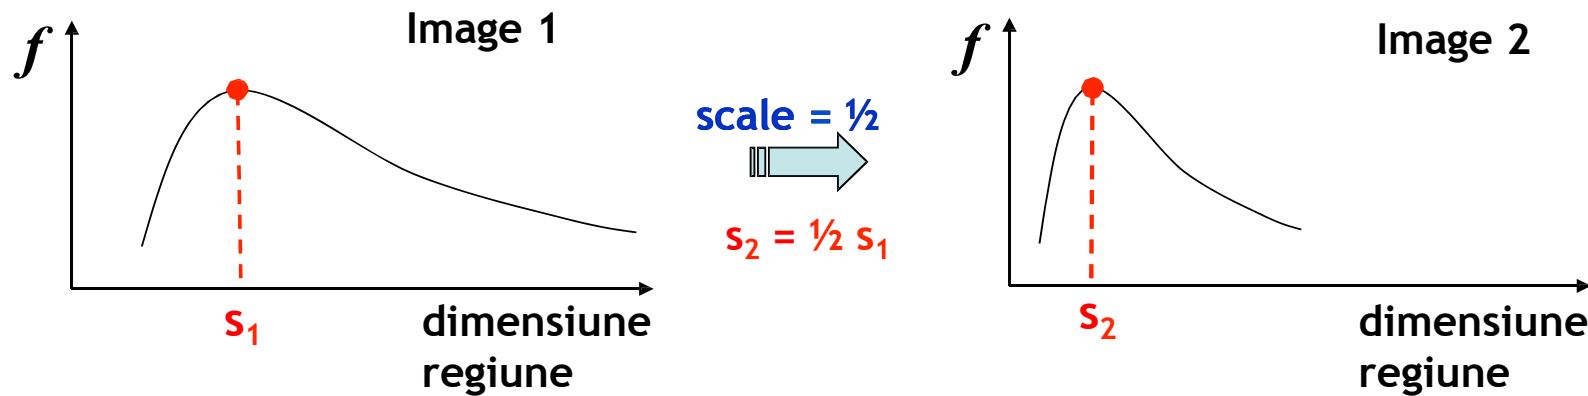
- soluție:
 - găsește o funcție pentru regiuni care este “scale invariant”
(arată la fel pentru regiuni corespondente, chiar dacă sunt la scale/mărimi diferite)

Exemplu: intensitatea medie. Pentru regiuni corespondente (chiar dacă sunt de mărimi diferite) funcția arată la fel



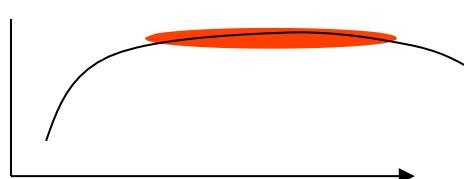
Selectia automată a scalei

- soluție:
 - găsește maximul local al acestei funcții (vrem funcții cu un singur maxim local) –dimensiunea regiunii pentru care răspunsul e maxim
 - dimensiunea regiunii covariază cu zoom-ul
 - dimensiunea regiunii este găsită în fiecare imagine independent

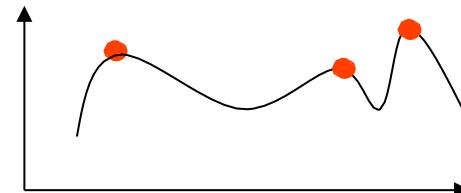


Selectia automată a scalei

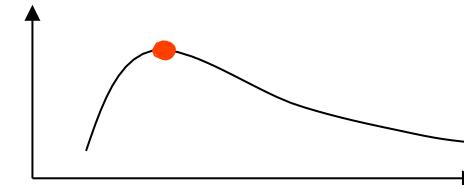
- soluție:
 - găsește o funcție pentru regiuni care este “scale invariant”
(arată la fel pentru regiuni corespondente, chiar dacă sunt la scale/mărimi diferite). O funcție “bună” are un singur maxim!



dimensiune
regiune



dimensiune
regiune



dimensiune
regiune



Selectia automată a scalei



$$f(I_{i_1 \dots i_m}(x, \sigma)) = f(I_{i_1 \dots i_m}(x', \sigma'))$$

x, x' – coordonatele punctelor de interes în cele două imagini

σ, σ' – dimensiunile regiunilor = laturile ferestrelor centrate în x, x'

Cum să găsim scalele cele mai bune σ, σ' ?

Selectia automată a scalei



$$f(I_{i_1 \dots i_m}(x, \sigma)) = f(I_{i_1 \dots i_m}(x', \sigma'))$$

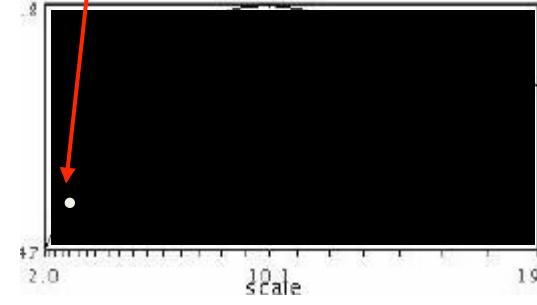
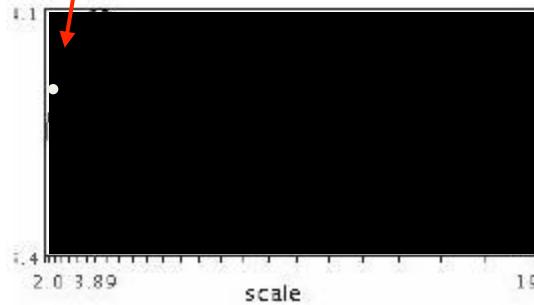
x, x' – coordonatele punctelor de interes în cele două imagini

σ, σ' – dimensiunile regiunilor = laturile ferestrelor centrate în x, x'

Cum să găsim scalele cele mai bune σ, σ' ?

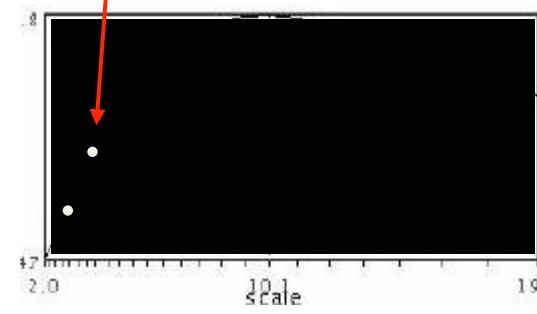
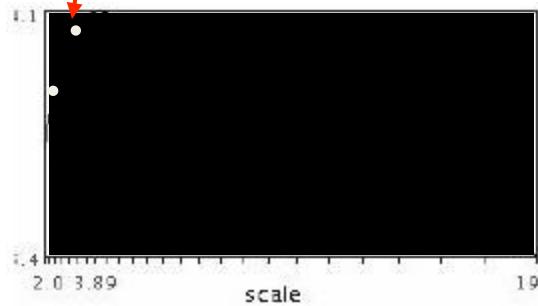
Selectia automată a scalei

- valoarea funcției f pentru fiecare scală



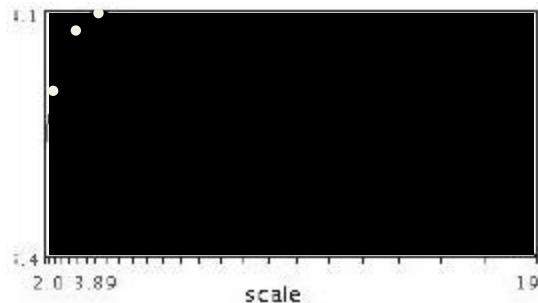
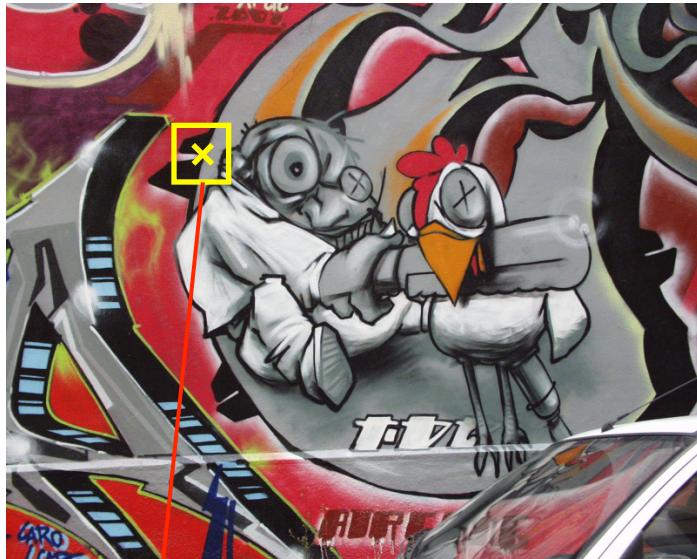
Selectia automată a scalei

- valoarea funcției f pentru fiecare scală

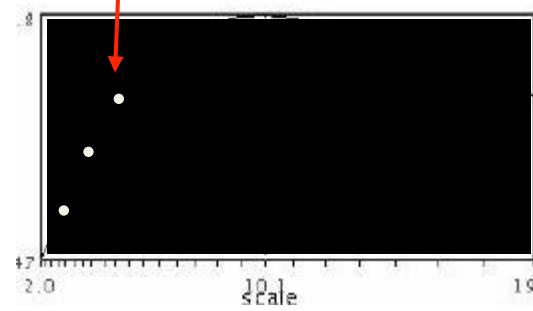


Selectia automată a scalei

- valoarea funcției f pentru fiecare scală



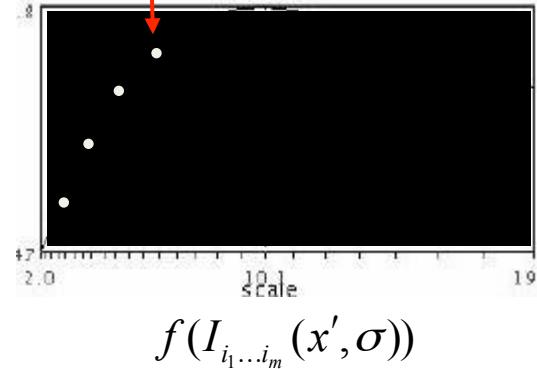
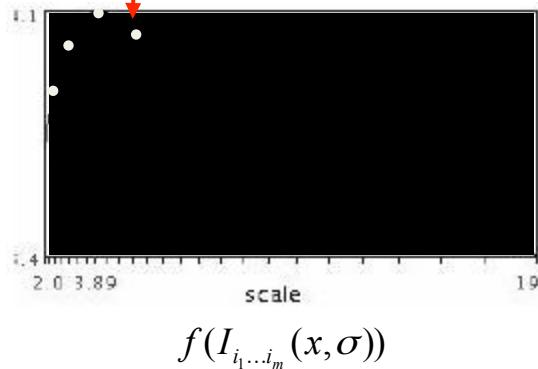
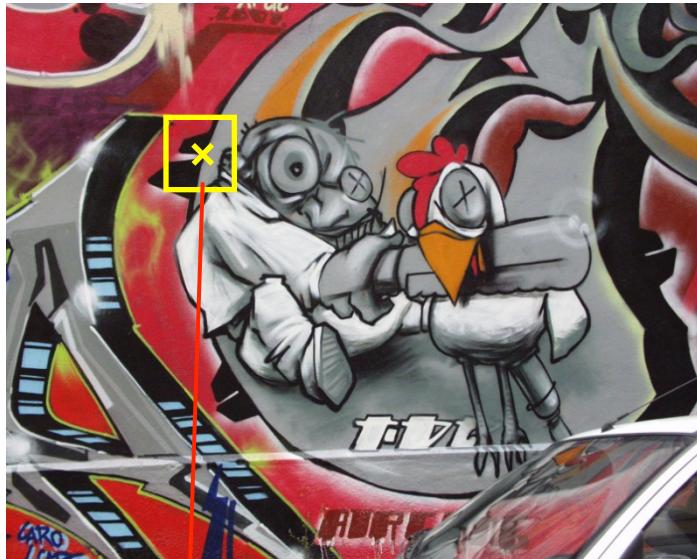
$$f(I_{i_1 \dots i_m}(x, \sigma))$$



$$f(I_{i_1 \dots i_m}(x', \sigma))$$

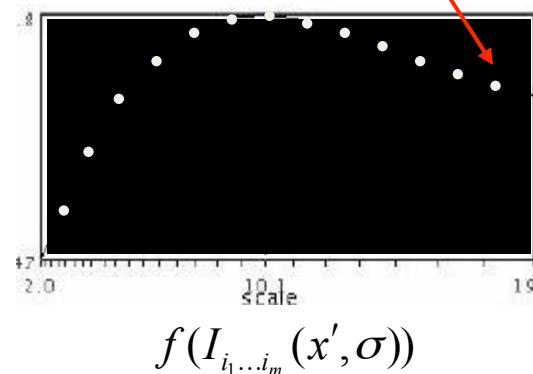
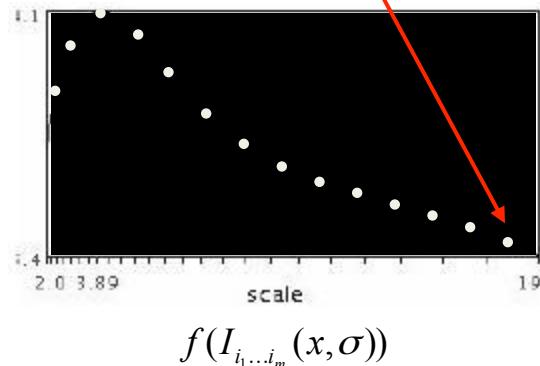
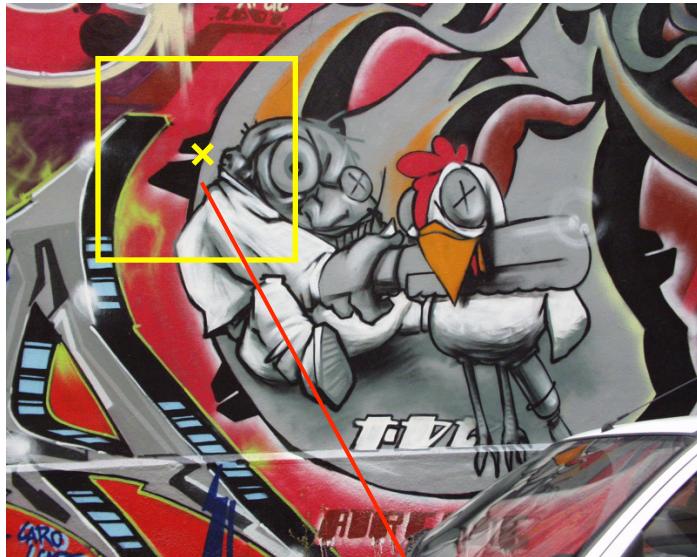
Selectia automată a scalei

- valoarea funcției f pentru fiecare scală



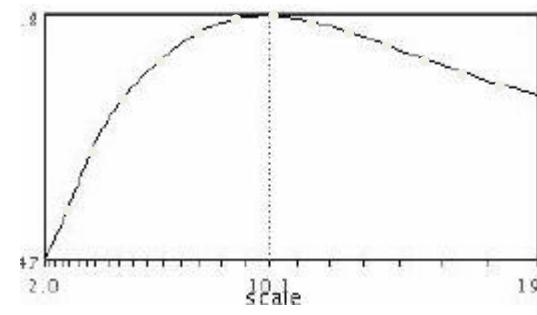
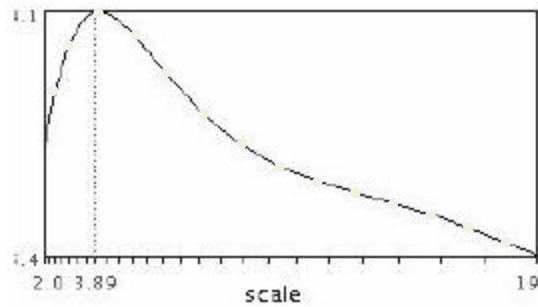
Selectia automată a scalei

- valoarea funcției f pentru fiecare scală



Selectia automată a scalei

- valoarea funcției f pentru fiecare scală

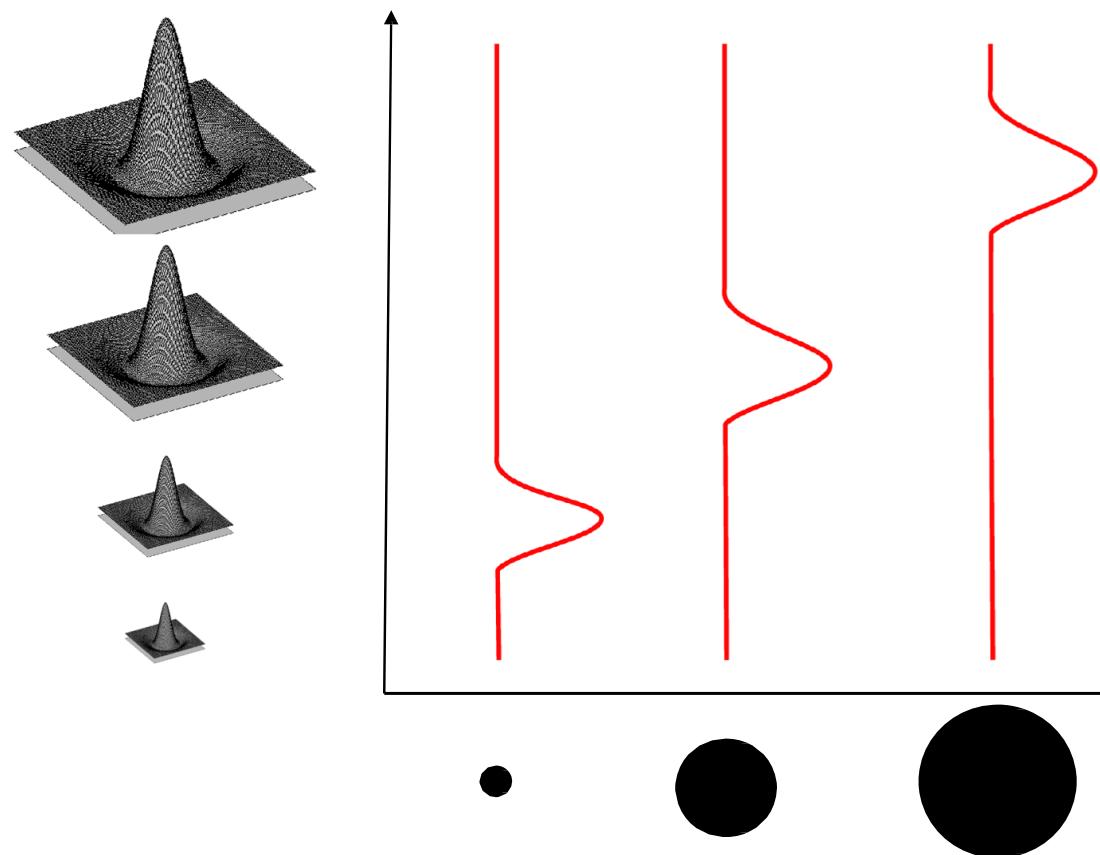


Cum găsim o astfel de funcție f cu proprietățile dorite?

Slide adaptat după K. Graumann

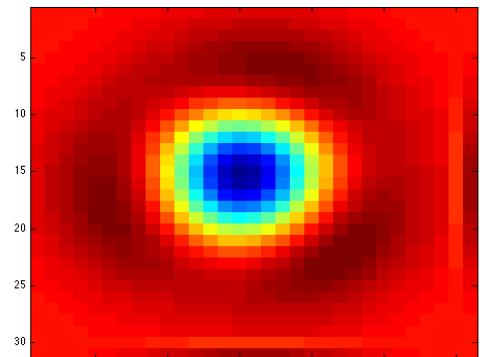
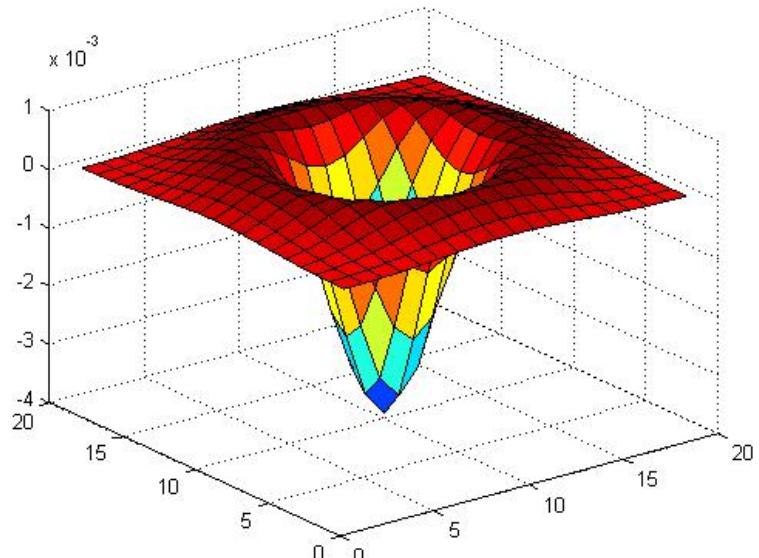
Selectia automată a scalei

Folosim $f =$ filtrul Laplacian = detector de “blob-uri”



Selectia automată a scalei

Folosim $f = \text{filtrul Laplacian}$

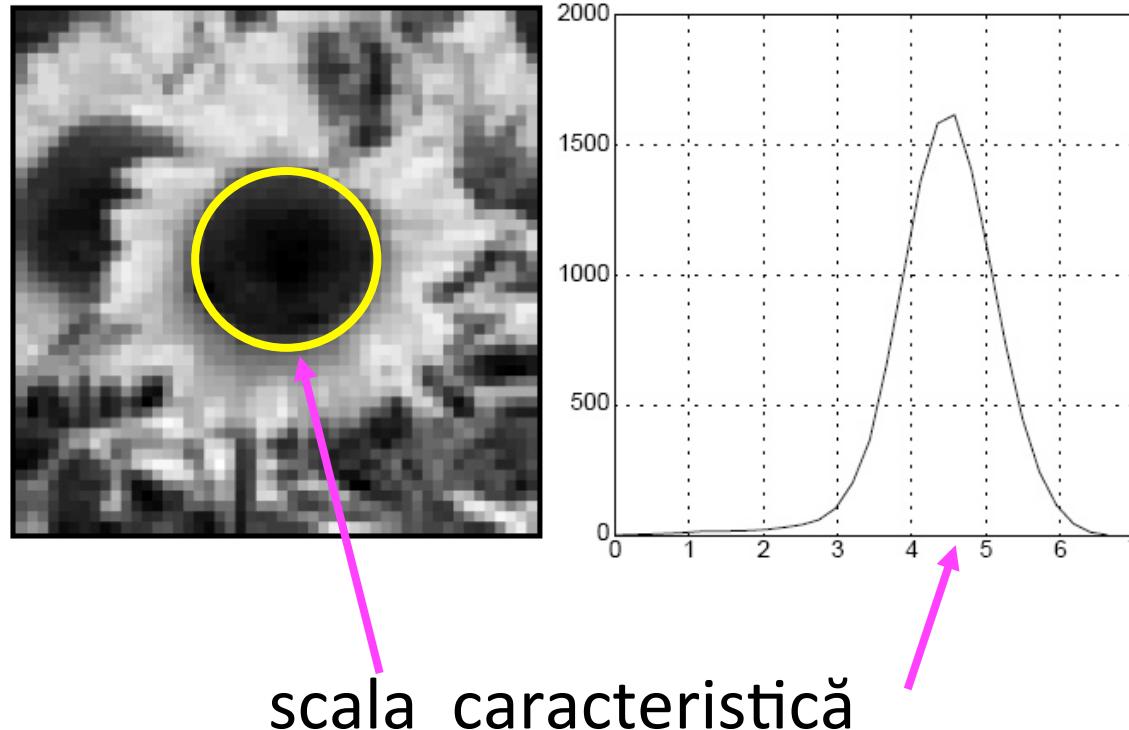


$$\nabla^2 h = \frac{\partial^2 h}{\partial x^2} + \frac{\partial^2 h}{\partial y^2}$$

Magnitudinea răspunsului imaginii filtrare cu **filtrul Laplacian** atinge valoarea maximă pentru centrul regiunii când scala **filtrului Laplacian** corespunde cu scala optimă a regiunii de detectat = regiune circulară (blob)

Scala caracteristică

- definim scala caracteristică a unui punct de interes ca fiind scala pentru care se obține valoarea maximă în imaginea filtrată cu filtrul Laplacian



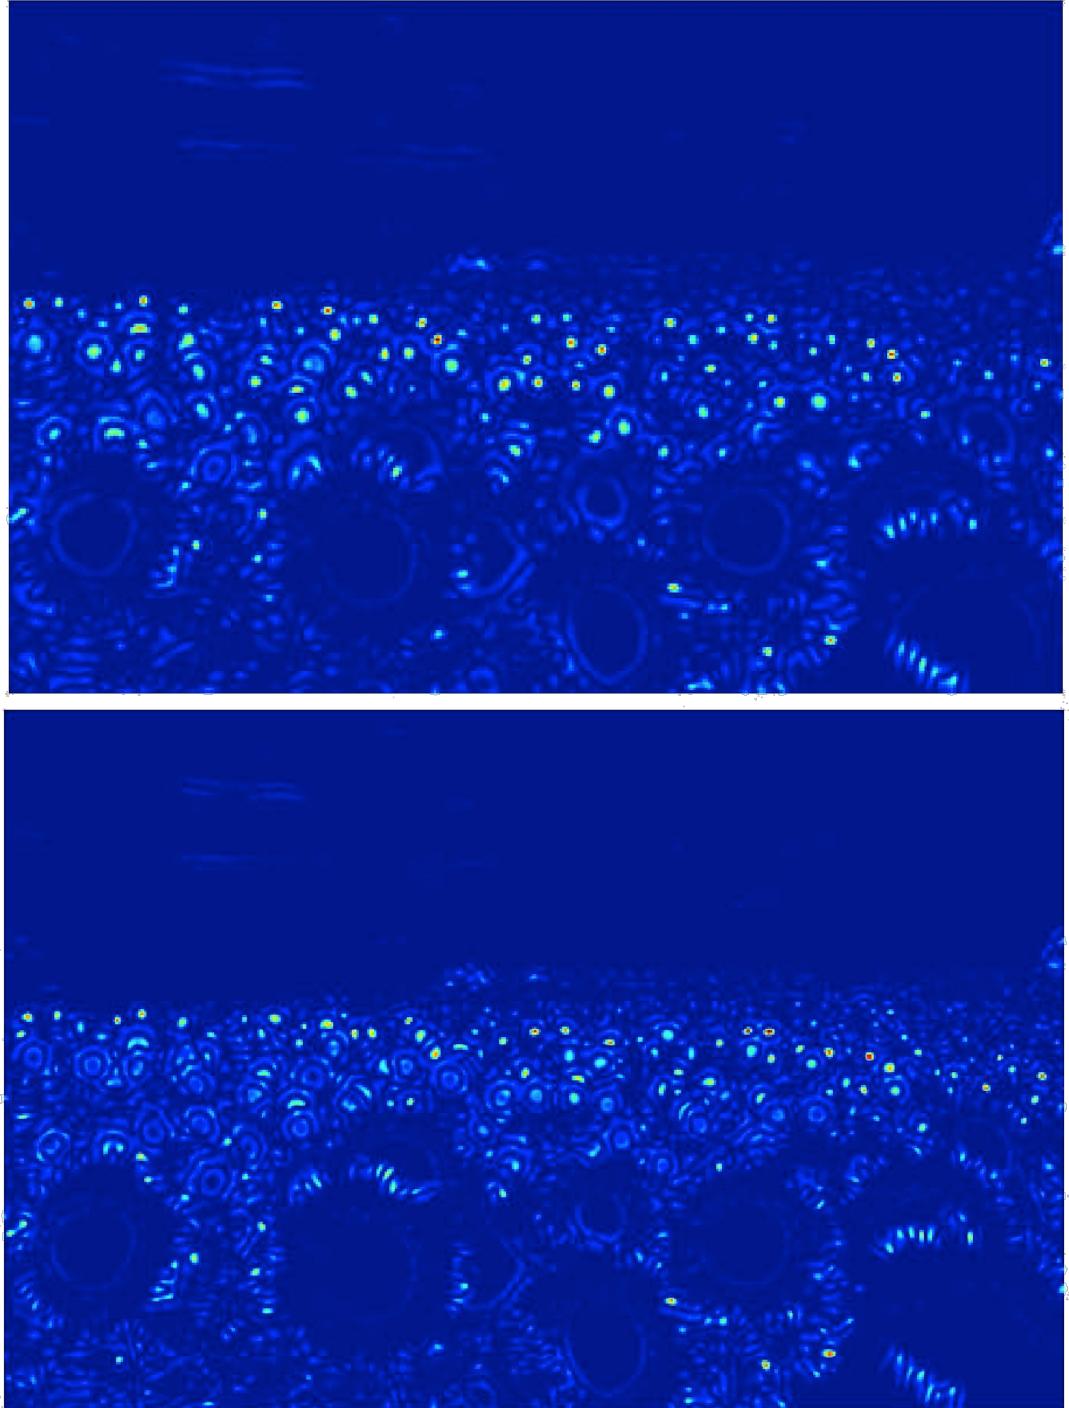
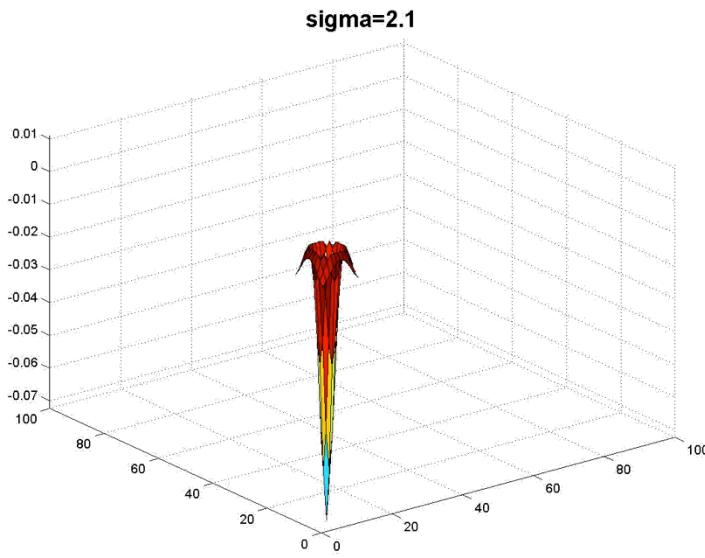
Exemplu

Imagine cu
dimensiunile $\frac{3}{4}$
din cea inițială



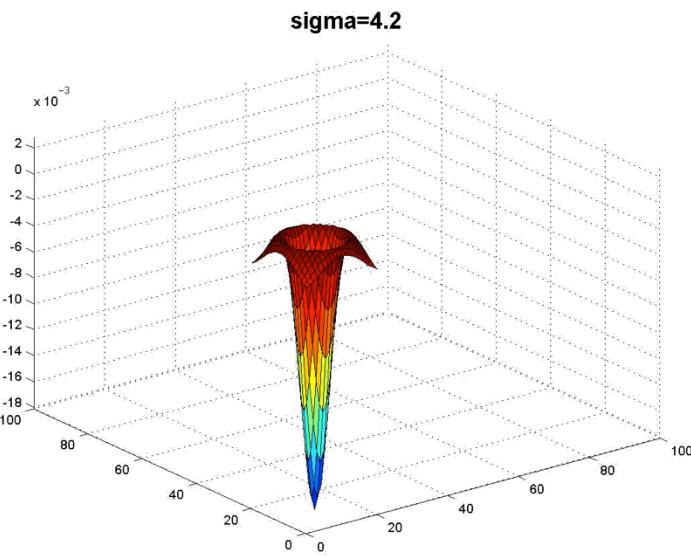
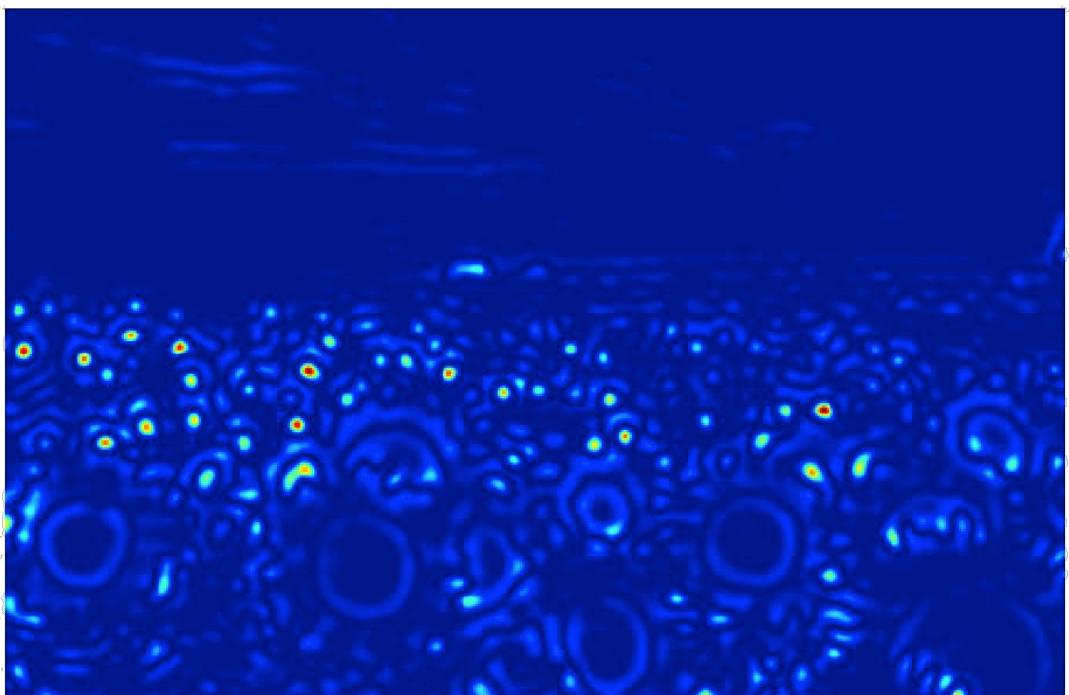
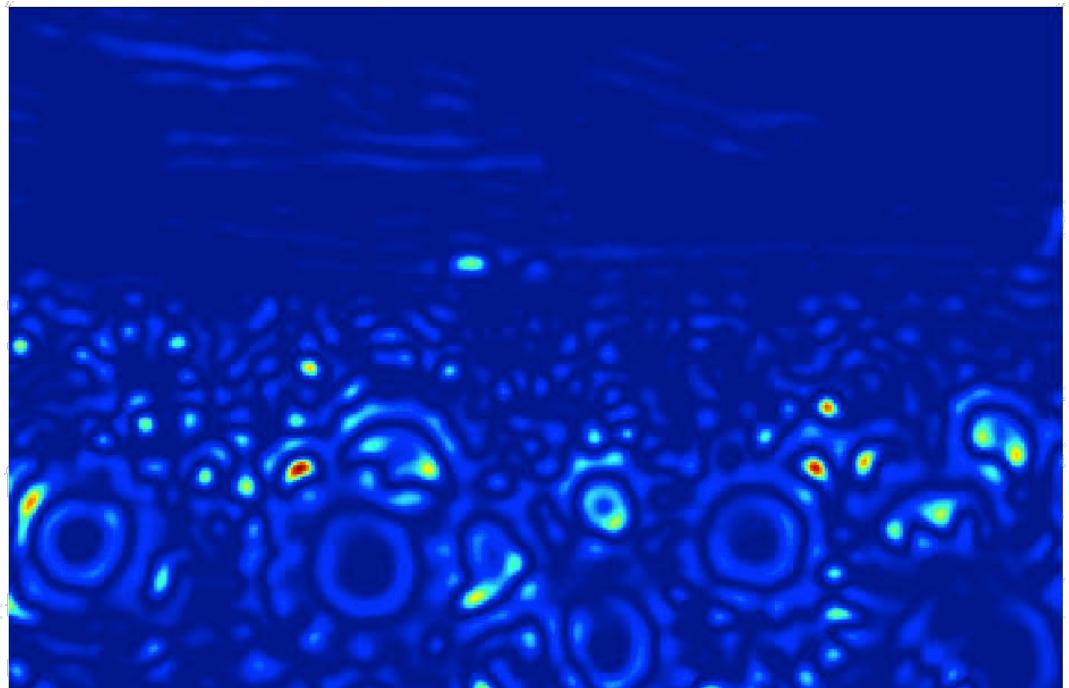
Exemplu

Imagine cu
dimensiunile $\frac{3}{4}$
din cea inițială



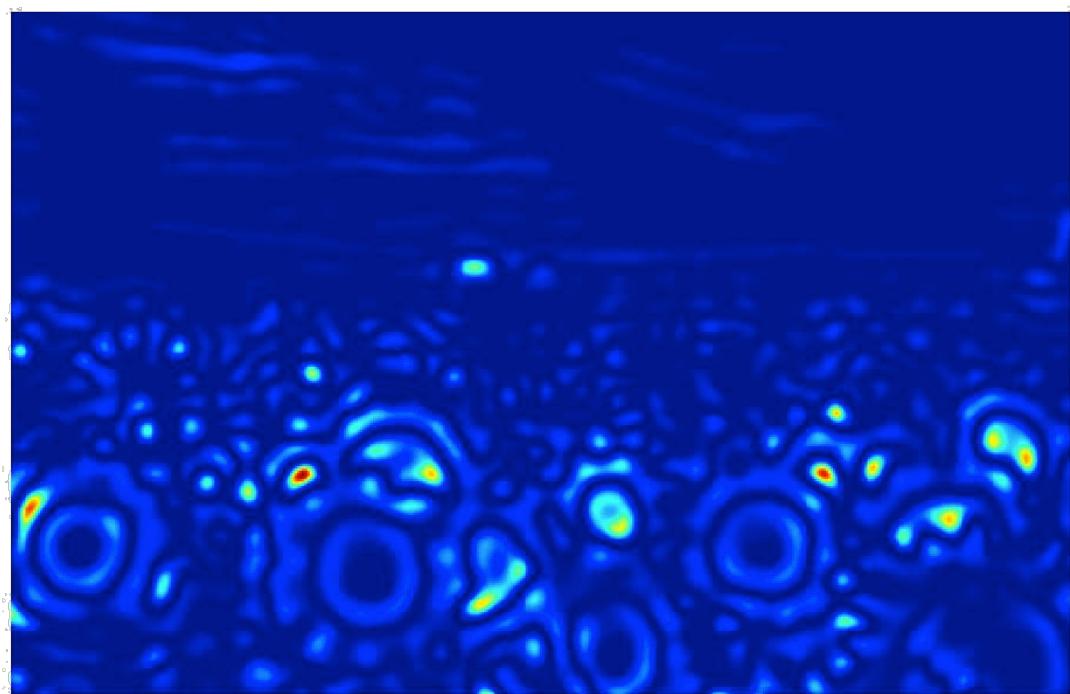
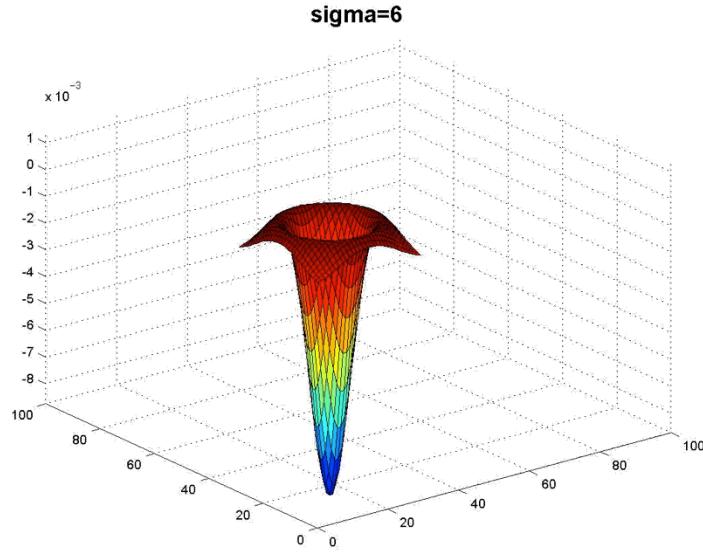
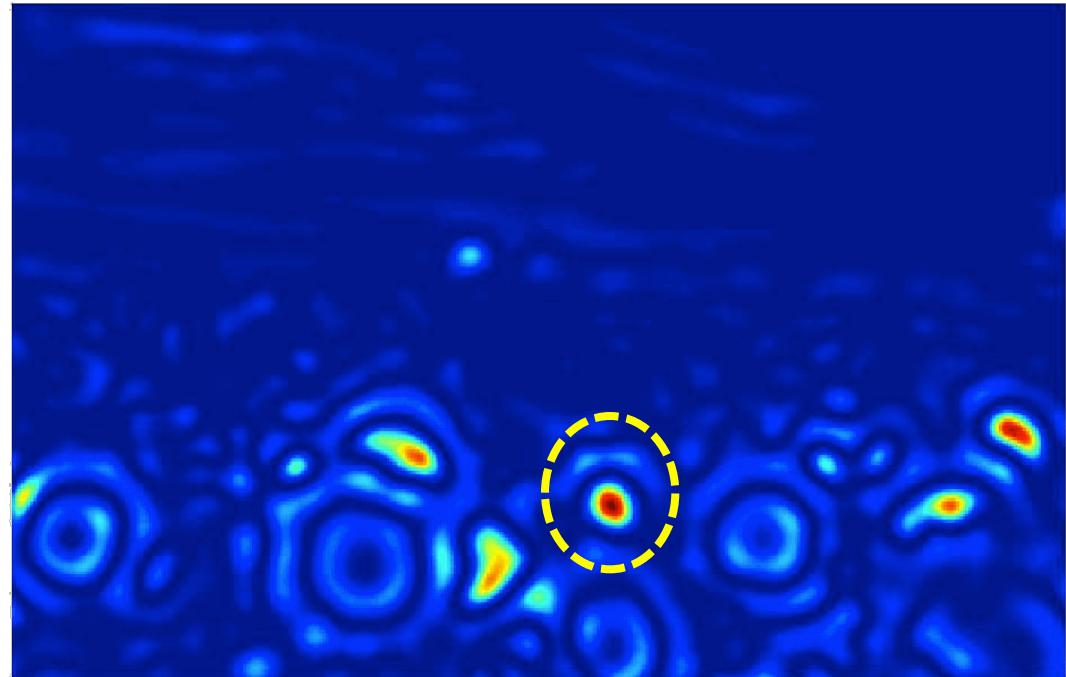
Exemplu

Imagine cu
dimensiunile $\frac{3}{4}$
din cea inițială



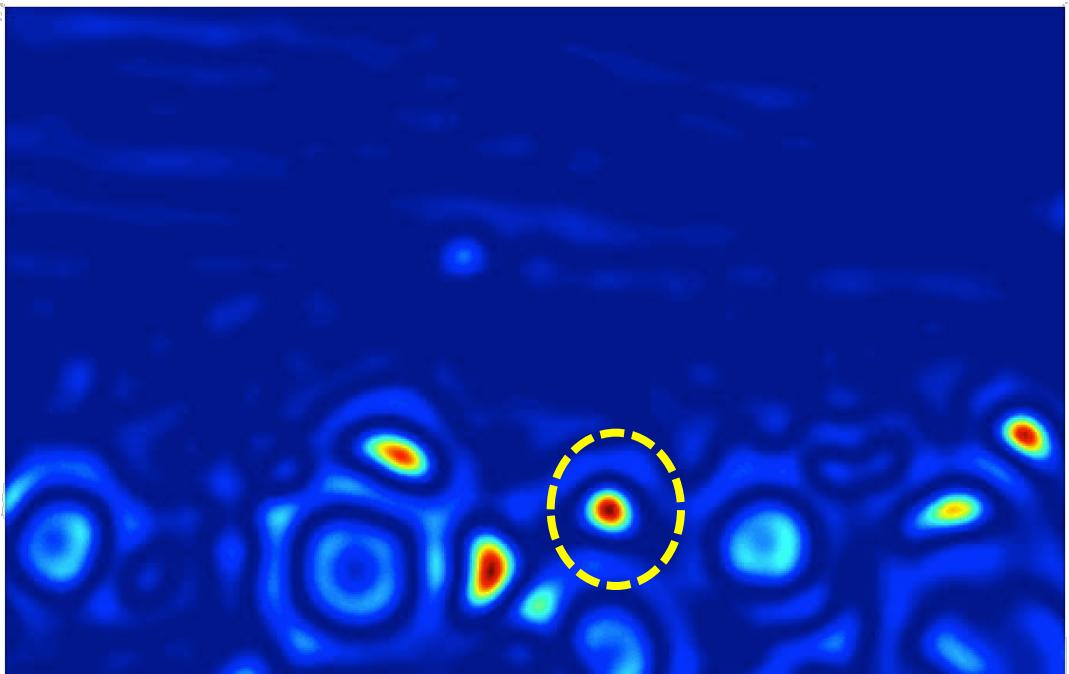
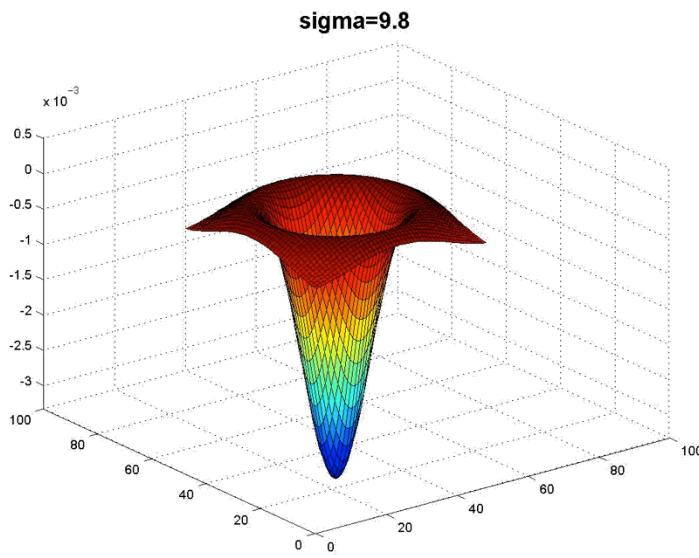
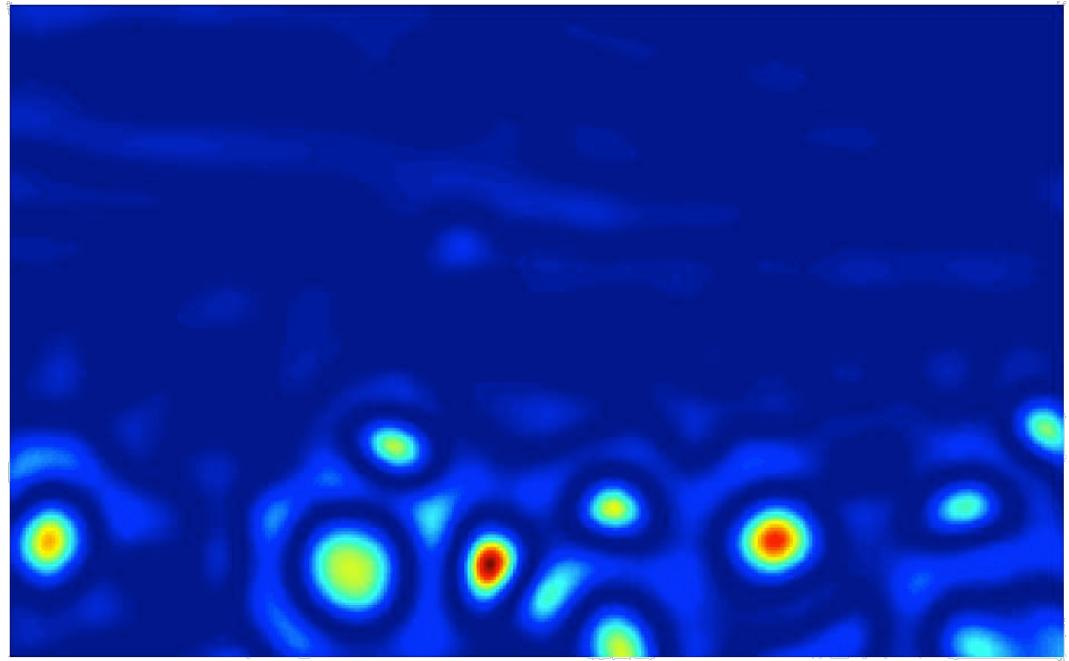
Exemplu

Imagine cu
dimensiunile $\frac{3}{4}$
din cea inițială



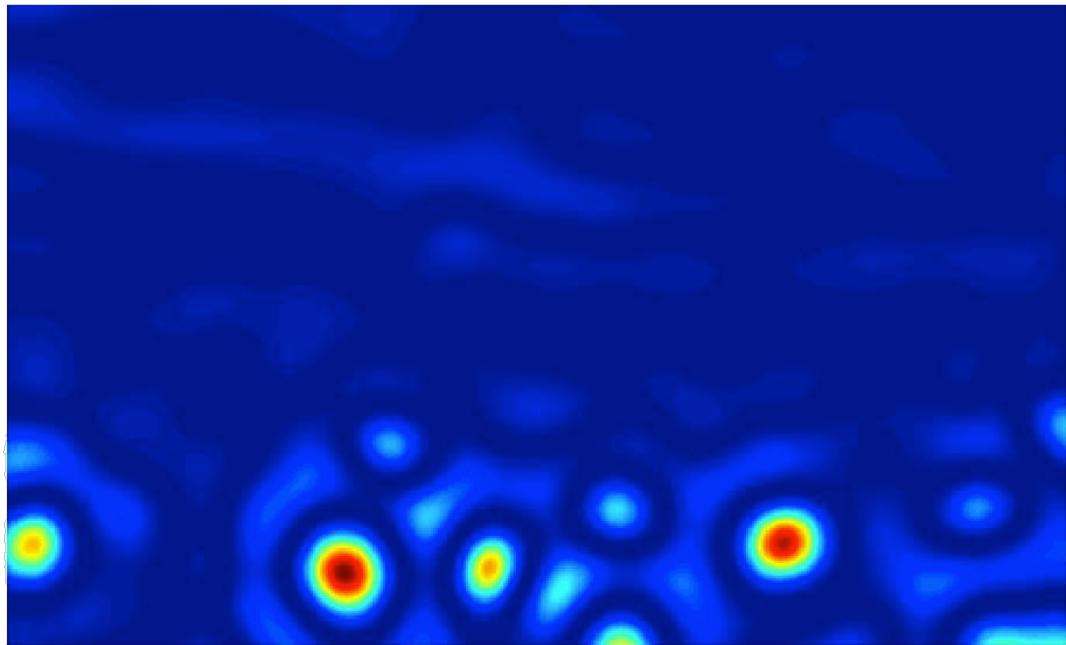
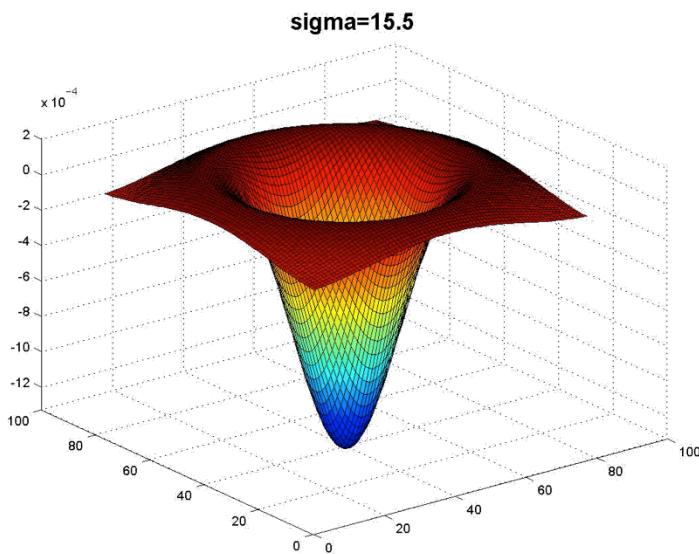
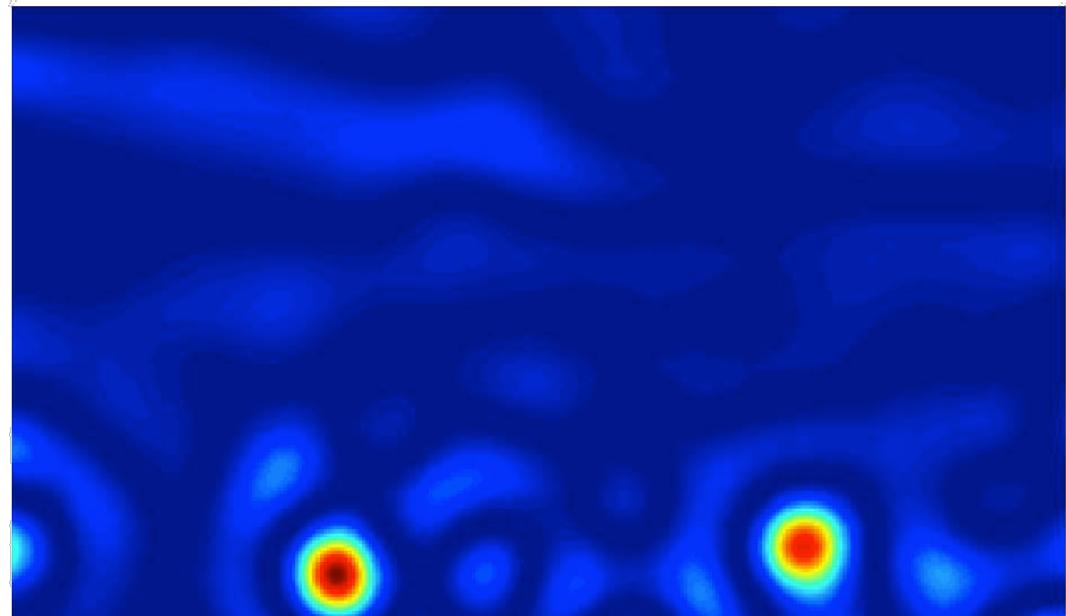
Exemplu

Imagine cu
dimensiunile $\frac{3}{4}$
din cea inițială



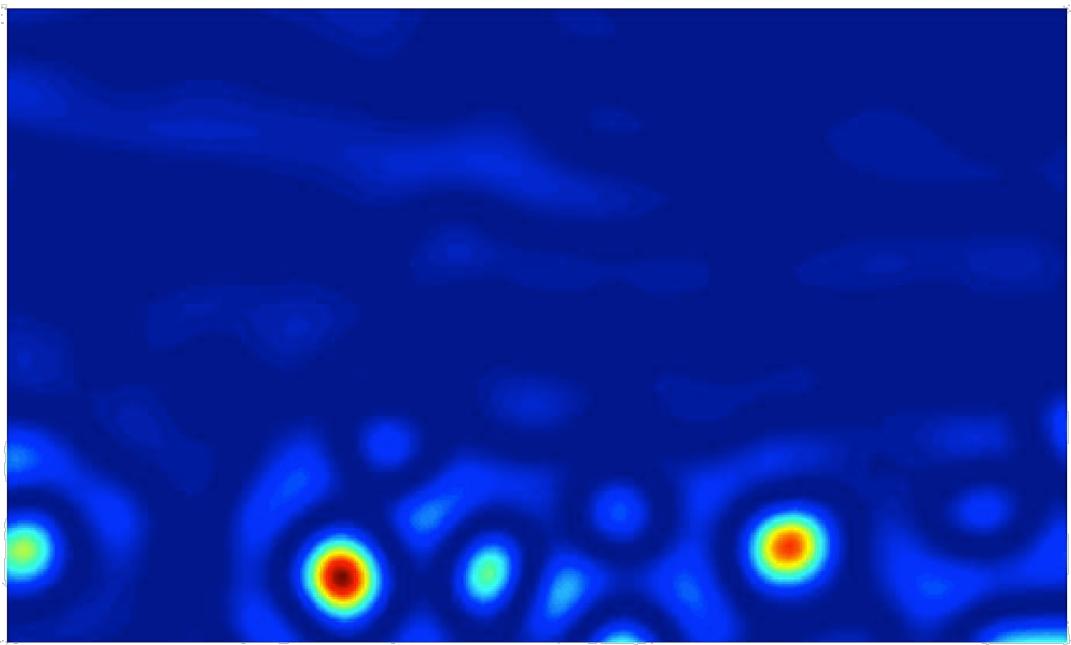
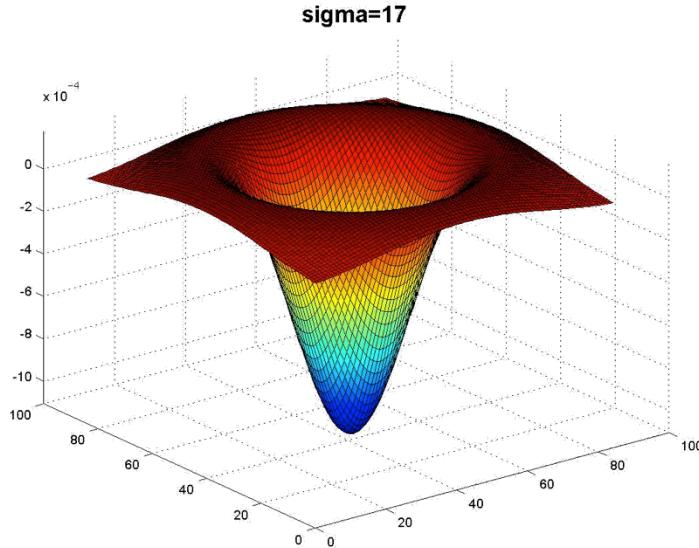
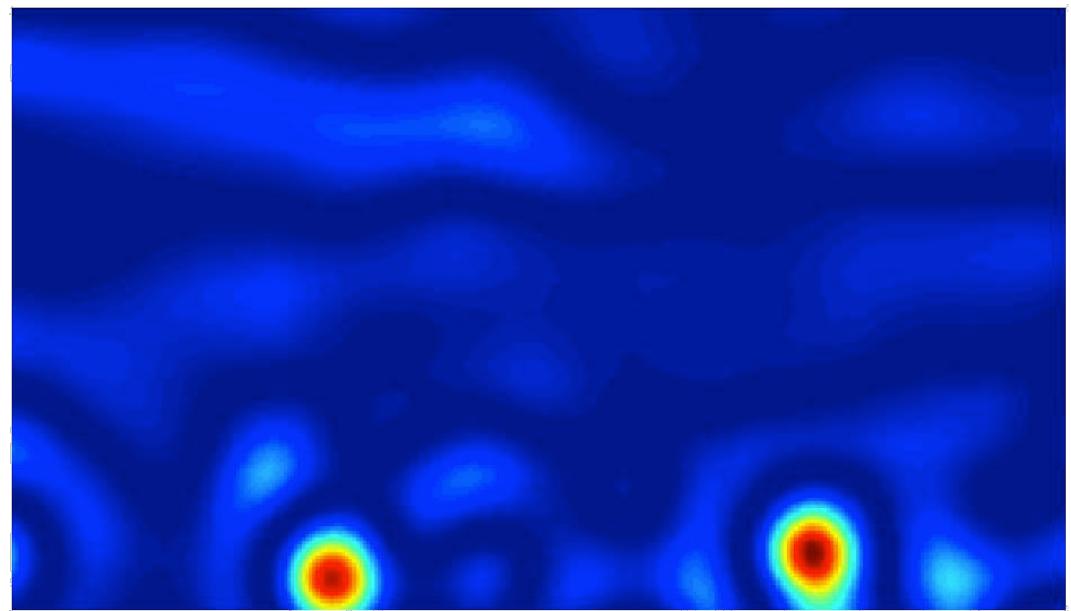
Exemplu

Imagine cu
dimensiunile $\frac{3}{4}$
din cea inițială



Exemplu

Imagine cu
dimensiunile $\frac{3}{4}$
din cea inițială



Puncte de interes invariante la scală

Punctele de interes sunt maxime locale în poziție și scală



$$L_{xx}(\sigma) + L_{yy}(\sigma) \rightarrow \sigma_3$$

σ_1

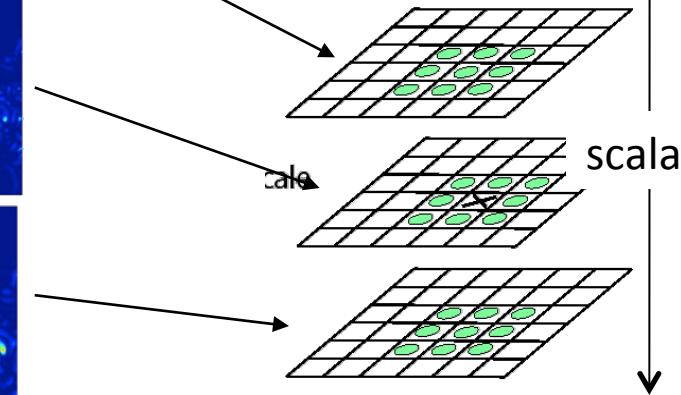
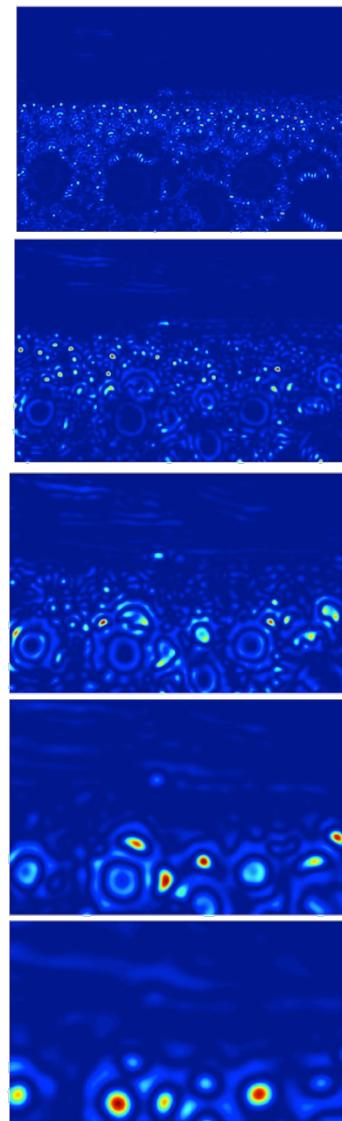
σ_2

σ_3

σ_4

σ_5

A series of five arrows pointing from left to right, each labeled with a scale value σ_i . The first arrow points from the input image to a heatmap labeled σ_3 . Subsequent arrows point to heatmaps labeled σ_1 , σ_2 , σ_4 , and σ_5 respectively, showing increasing levels of scale-space processing.



⇒ Lista punctelor de interes = regiuni detectate (x, y, s)

Detectorul LoG

