

# Concepte și aplicații în Vederea Artificială

Bogdan Alexe

[bogdan.alexe@fmi.unibuc.ro](mailto:bogdan.alexe@fmi.unibuc.ro)

Cursul 11

anul III, Opțional Informatică, semestrul I, 2018-2019

# Organizare

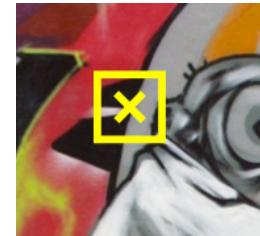
- următoarele 2 laboratoare (12 dec, 19 dec) le  
țin eu
- laborator **14-16**, sala 201
- tema 4

# Studenti care au trimis tema 3

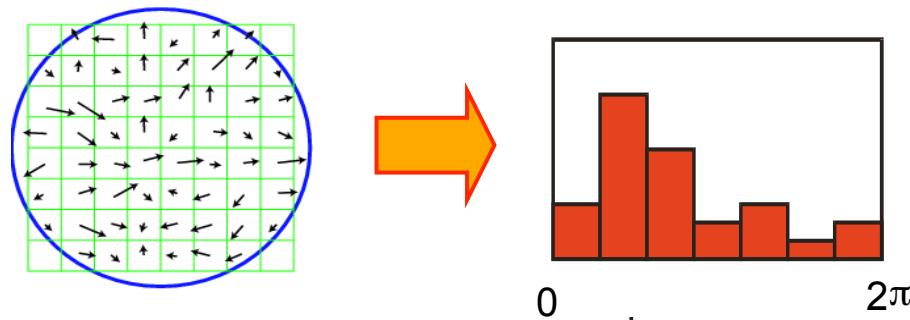
	Nume	Grupa
1	Dranca Constantin	334
2	Botezatu Daniel Andrei	342
3	Avram Andrei-Alexandru	
4	Zugravu Andrei	331
5	Jitca David	
6	Uta Stefana	344
7	Valentin Calinescu	
8	Robert Stancu	343
9	Lupascu Marian	
10	Radu Muntean	
11	Poesina Eduard Gabriel	334
12	Mare Tudor	
13	Belcineanu Alexandru-Ioan	344
14	Nedelcu Andreea	344
15	Dumitrescu Gabriel Horia	333
16	Caluian Iulian	343

# Cursul trecut (Bogdan)

- detectorul Harris Laplace



- descriptorul SIFT



- concepte de bază în învățarea automată



Learning machine

# Cursul trecut (Paul)

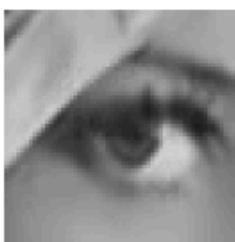
Exemplu: eliminarea zgomotului



Original



Noisy



Cleaned



Overlapping Patches

# Cursul trecut (Paul)

*Inpainting: Exemplu 30% pixeli disponibili*

**Original**



**Missing**



**Inpainted**

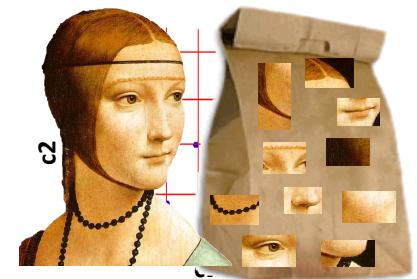


# Cursul de azi

- Recunoașterea claselor de obiecte
  - privire de ansamblu
  - ce este o clasă de obiecte?

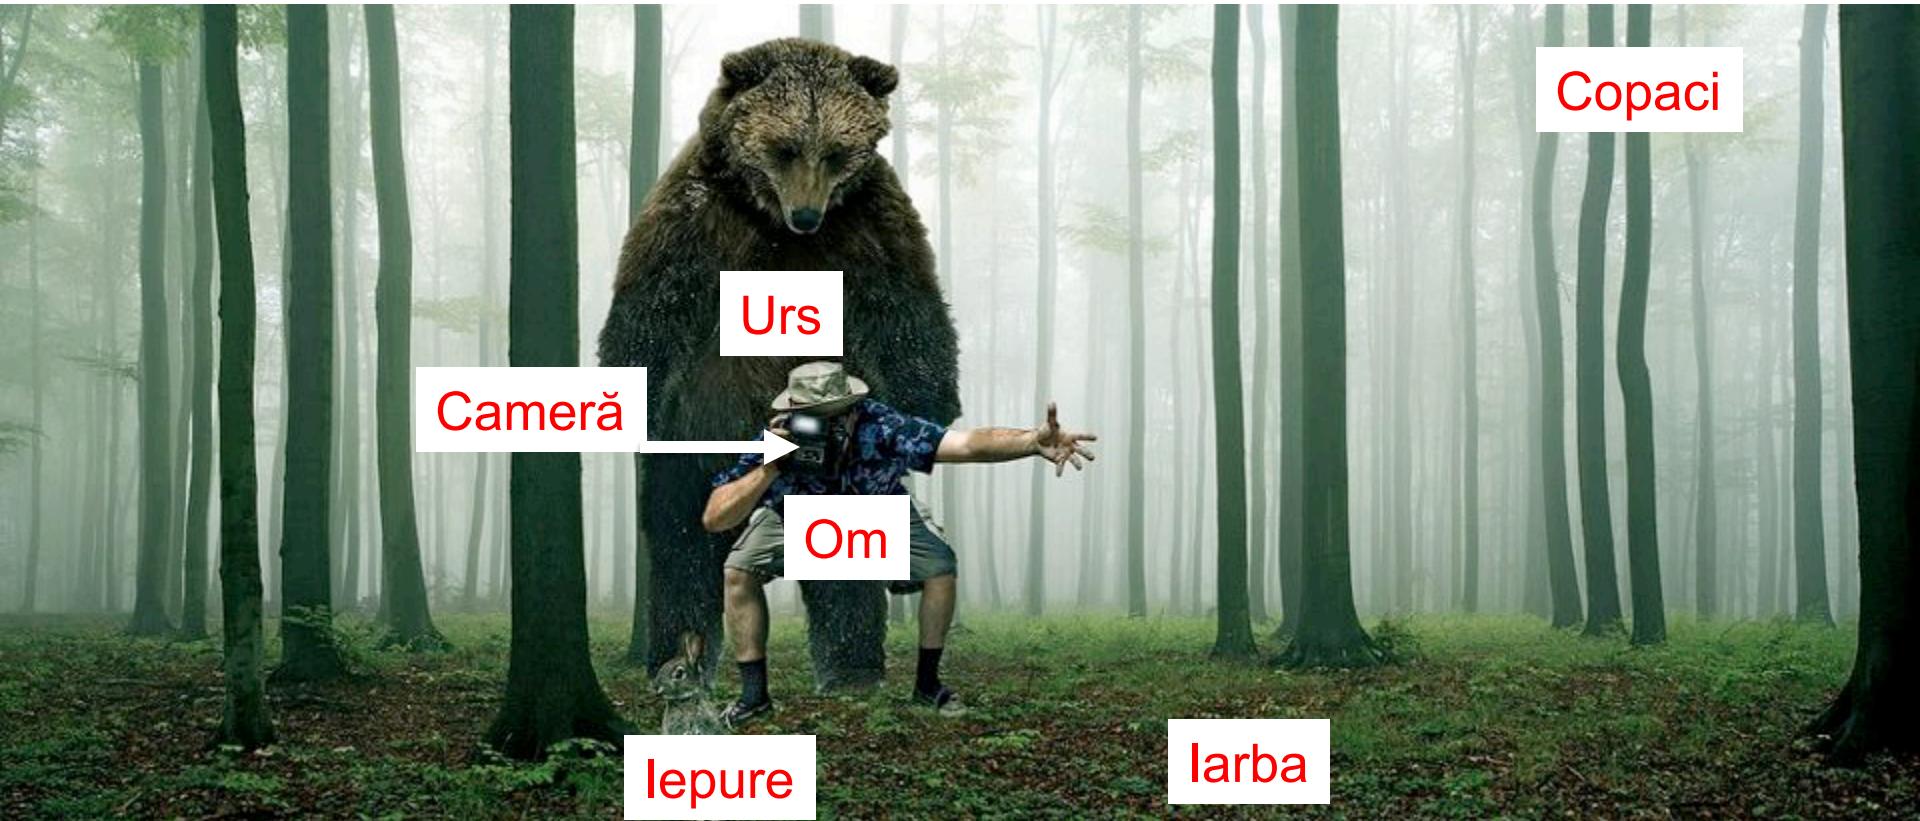


- Clasificarea imaginilor
  - reprezentarea caracteristicilor prin histograme
  - modelul Bag of Visual Words

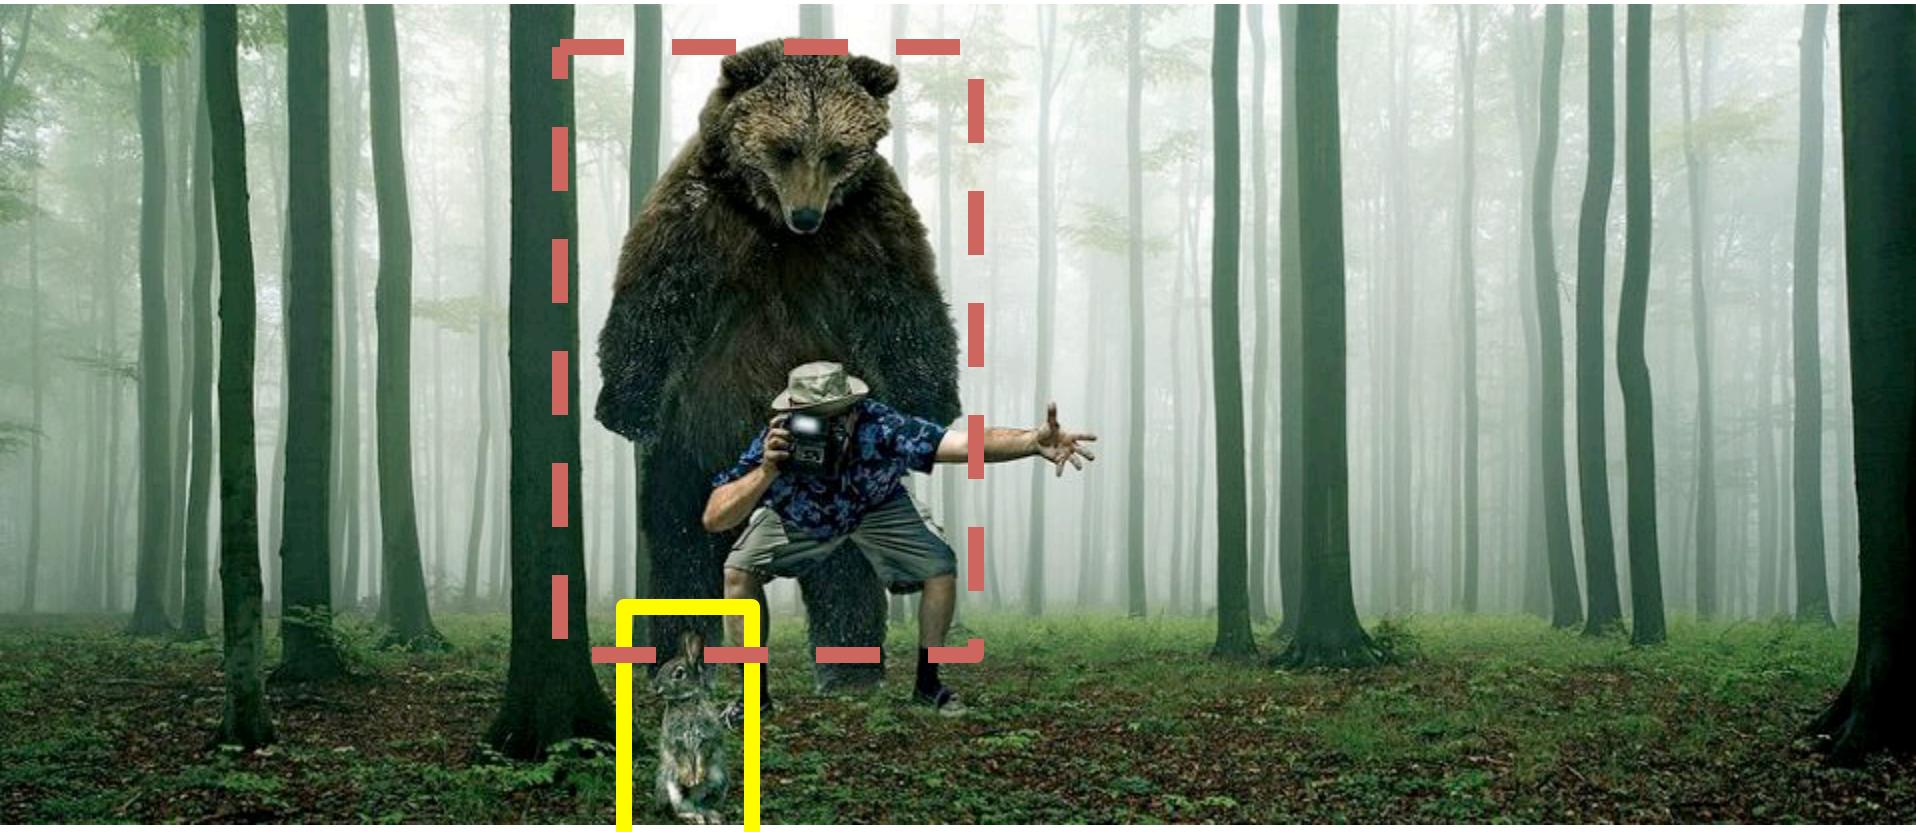


# Recunoașterea claselor de obiecte

# Ce vedeți în această imagine?



Pădure



Este **periculos**?

Este **viu**?

Cât de **repede** aleargă?

Are **coadă**?

# Recunoașterea vizuală a claselor de obiecte



**Clasificare:** este vreun felinar în imagine? **Da/Nu**



**Detectare:** unde este felinarul?

**Localizare**



# Recunoaștere: care palat?

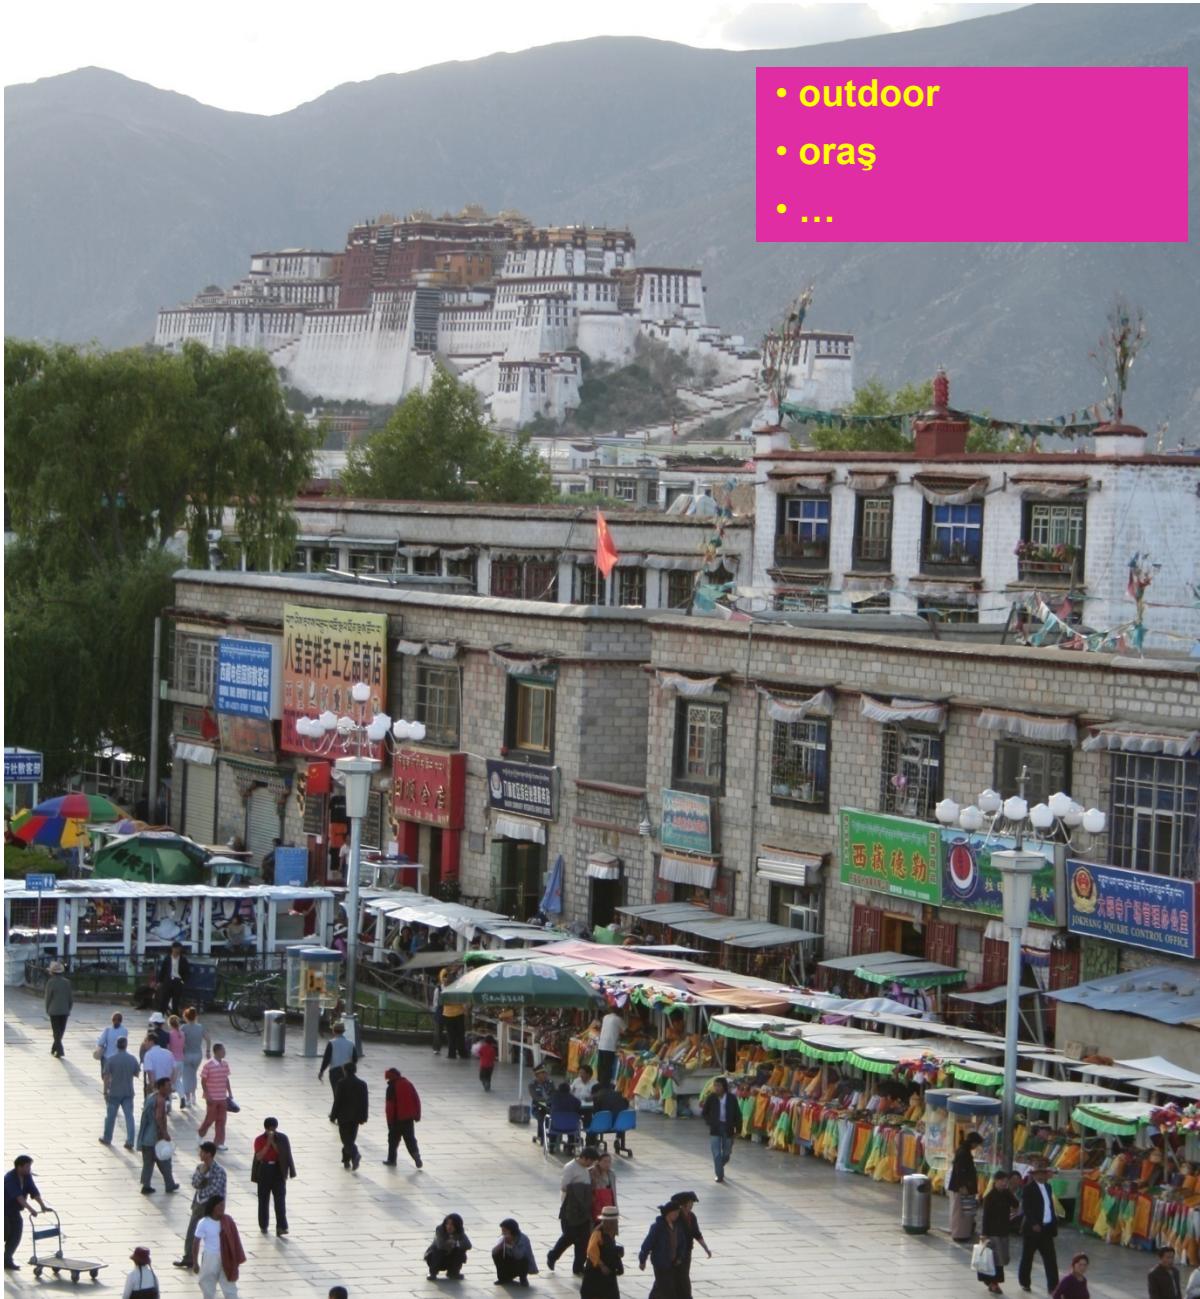
# Instantiere



# Clasificarea regiunilor din imagine



# Clasificarea întregii scene



- outdoor
- oraș
- ...

# Recunoașterea claselor de obiecte la nivel de instanță



mașina lui Mihai

# Recunoașterea claselor de obiecte la nivel generic



Vrem să recunoștem toate instanțierile unei clase de obiecte

# Recunoașterea claselor de obiecte

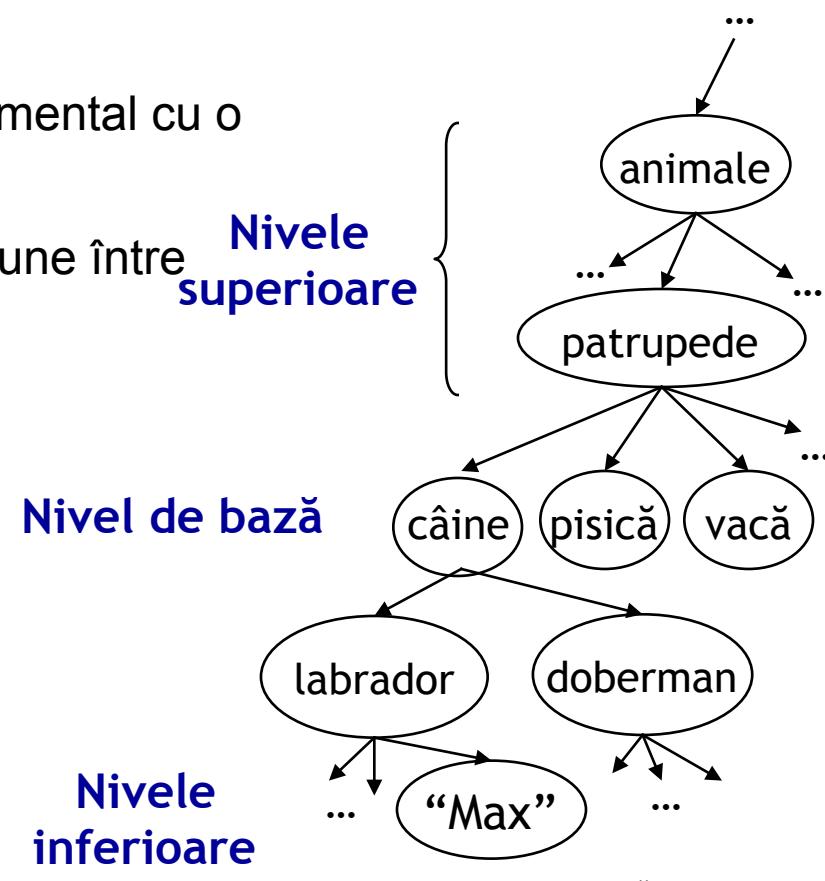
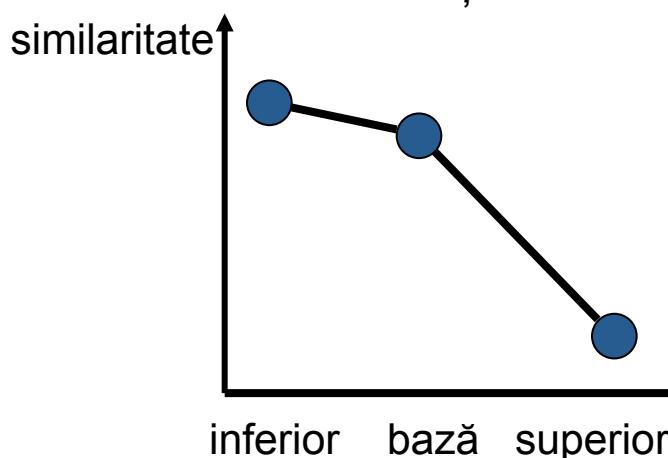
- Descrierea problemei:
  - “Fiind dat un număr mic de imagini de antrenare ale unei clase de obiecte, recunoașteți instanțieri ale clasei de obiecte asignând eticheta corespunzătoare clasei de obiecte.”
- Pentru care clasă de obiecte puteți asocia repede o imagine?



# Organizarea ierarhică a claselor de obiecte (Rosch, 1976)

Nivelul de bază:

- clasele de obiecte la nivel de bază sunt clasele de nivel cel mai înalt pentru care membrii lor au forme percepute similare.
- nivelul cel mai înalt pentru care reprezentăm mental cu o singură imagine întreaga clasă de obiecte
- există un număr seminificativ de atribute comune între perechi de membri
- primul nivel numit și înțeles de copii

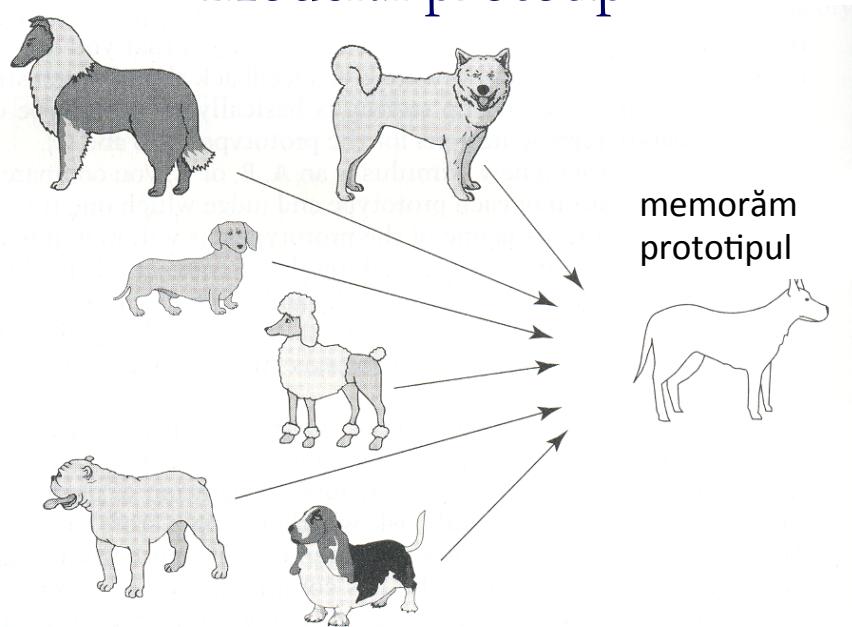


# Organizarea ierarhică a claselor de obiecte (Rosch, 1976)

- Rosch a găsit următoarele:
  - oamenii clasifică clasele de obiecte mult mai repede la nivel de bază
  - tendință de a clasifica după nivelul de bază ('câine') înainte de nivelul superior ('animal') sau nivelul inferior ("golden retriever")
  - mai întâi clasificare la nivel de bază iar apoi recunoaștere
  - acord la nivel de bază (de cele mai multe ori)
    - desktop, laptop, tablete, pc, mac – nivel de bază
    - calculator – nivel de bază
      - desktop, laptop, tablete, pc, mac – nivel inferior
      - ține de nivelul de expertiză

# Recunoașterea claselor de obiecte

## Modelul prototip



Realizăm clasificarea într-o clasă de obiecte prin compararea unui nou exemplu cu prototipul

# Clase de obiecte - exemple



# Cât de multe clase de obiecte există?



# Recunoașterea claselor de obiecte în Vederea Artificială - ce funcționează bine

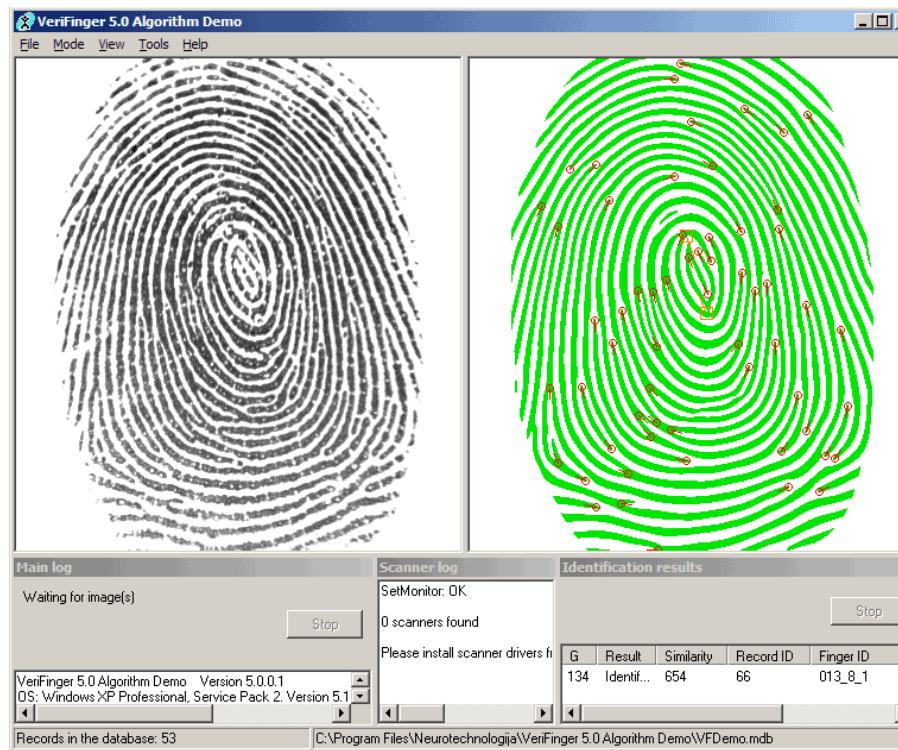
- OCR – plăcuțe de înmatriculare, coduri poștale, etc.

A collection of handwritten digits arranged in ten rows. The digits are written in a cursive style and vary in orientation and size. Some digits are bolded or highlighted with a red outline. The digits in each row are separated by spaces.

3	6	8	/	7	9	6	6	9	1
6	7	5	7	8	6	3	4	8	5
2	1	7	9	7	1	2	8	4	6
4	8	1	9	0	1	8	8	9	4
7	6	1	8	6	4	1	5	6	0
7	5	9	2	6	5	8	1	9	7
2	2	2	2	2	3	4	4	8	0
0	2	3	8	0	7	3	8	5	7
0	1	4	6	4	6	0	2	4	3
7	1	2	8	1	6	9	8	6	1

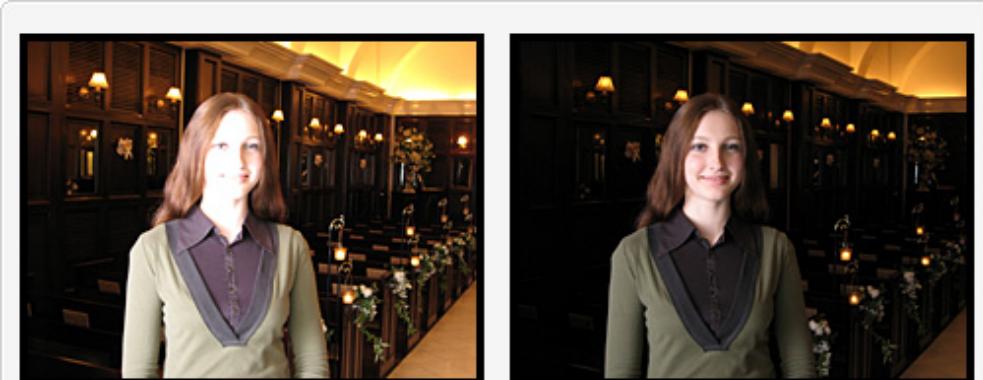
# Recunoașterea claselor de obiecte în Vederea Artificială - ce funcționează bine

- OCR – plăcuțe de înmatriculare, coduri poștale, etc.
- Recunoașterea amprentei



# Recunoașterea claselor de obiecte în Vederea Artificială - ce funcționează bine

- OCR – plăcuțe de înmatriculare, coduri poștale, etc.
- Recunoașterea amprentei
- Detectarea facială



[Face priority AE] When a bright part of the face is too bright

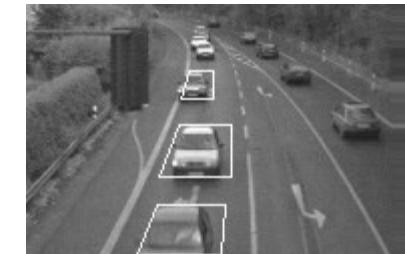
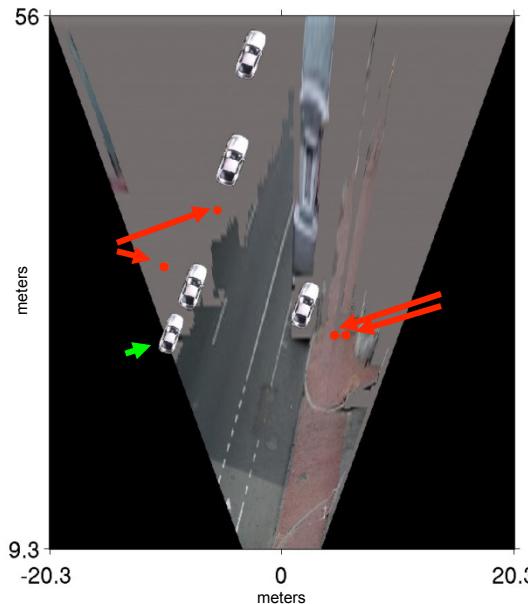
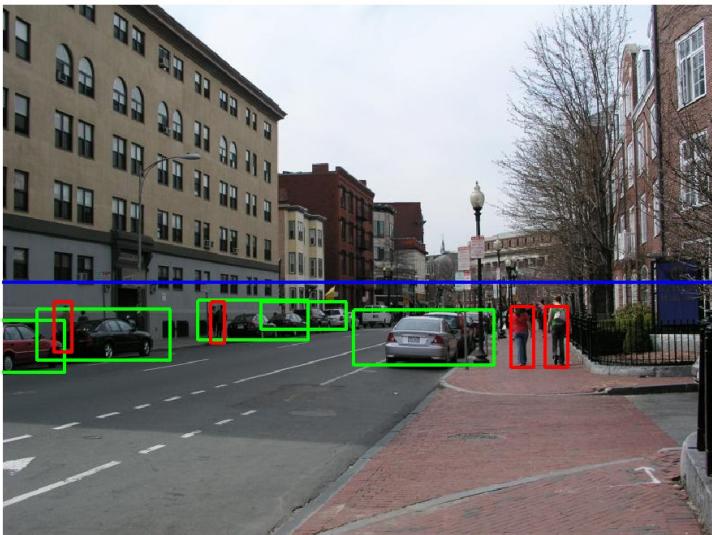
# Recunoașterea claselor de obiecte în Vederea Artificială - ce funcționează bine

- OCR – plăcuțe de înmatriculare, coduri poștale, etc.
- Recunoașterea amprentei
- Detectarea facială
- Recunoașterea obiectelor cu textură (coperți CD)

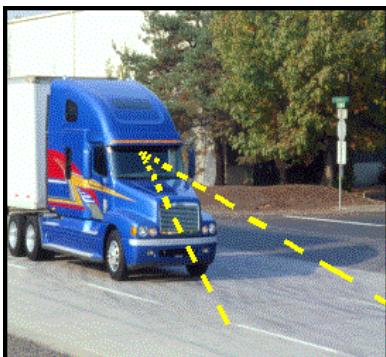


# Alte aplicații: conducere asistată

Detectarea mașinilor și a pietonilor



Detectarea liniilor de marcaj



# Găsirea obiectelor vizual similare

like visual shopping alpha

My Like List | NewsLetter | Blog

ALL SHOES BAGS WOMEN'S APPAREL MEN'S APPAREL KIDS ACCESSORIES JEWELRY & WATCHES HOLIDAY FOR THE HOME

IN Women's Shoes Search

Refine by Style Refine by Color Refine by Brand

Pumps Sandals Flats Par crimson taupe scarlet Clarks Sofft

Why is Like.com Different?  
Like is a visual shopping engine that lets you find items by color, shape and pattern.  
Click on Likeness Search to get started

All Products > Shoes > Women's Shoes > Cole Haan > Cole Haan - Carma OT Air Pump

Results 1 - 20 of 140,207

Sort By Likeness™ Price Change Your View: 1 2 3 4 5 6 7 NEXT >

**Natural Comfort - LV58**  
\$99.95  
Shop at Zappos.com  
Free Shipping Available  
Shop for more items like this: Likeness Search

**Cole Haan 'Carma Air' Patent Leather Open Toe Pump**  
\$275.00  
Shop at NORDSTROM.com  
Shop for more items like this: Likeness Search

**rsvp - Caitlyn**  
\$89.95  
Shop at Zappos.com  
Free Shipping Available  
Shop for more items like this: Likeness Search

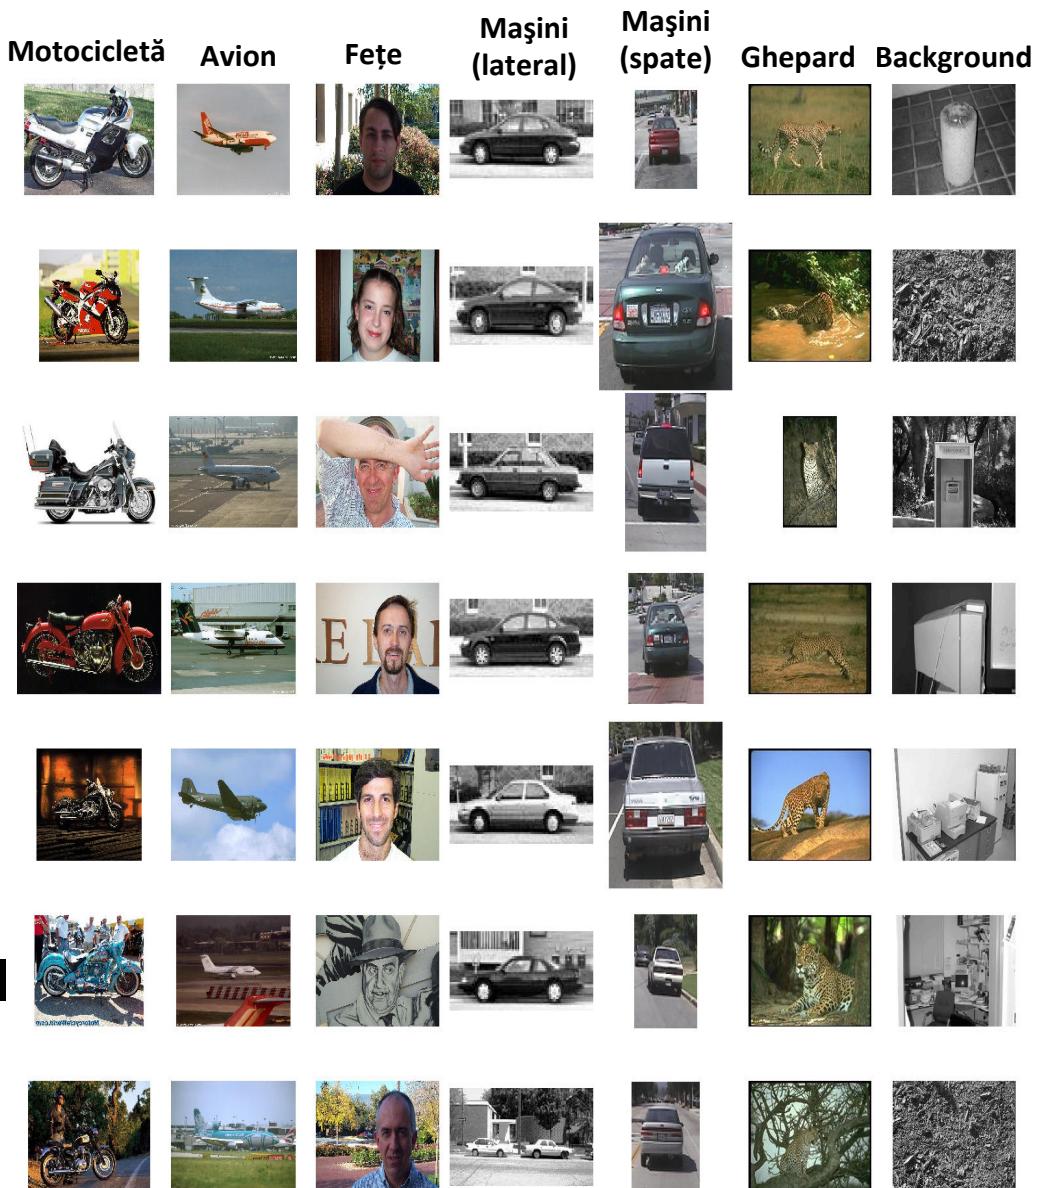
Cole Haan - Carma OT Air Pump  
\$278.95  
More Details + Save to LikeList  
Shop at Zappos.com

Slide adaptat după K. Grauman

# Recunoaștere în Vederea Artificială

Dificultăți:

- Variabilitatea intra-clasă
- Clase de obiecte ce arată similar (mașină, camion, dubă)
- Variabilitate în mărime a obiectelor
- Confuzia cu backgroundul



# Clasificarea imaginilor

- Conține o imagine test instantieri ale unei clase de obiecte/categorii ?
  - răspuns binar: DA/NU
- Exemplu: clasificator de imagini pentru ‘câine’

DA

NU

DA



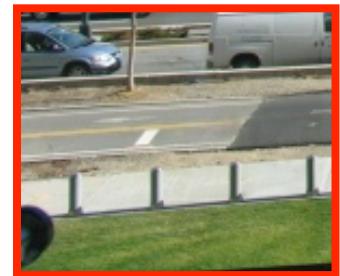
# Clasificarea imaginilor

Învățăm un clasificator al imaginilor pe bază de exemple

**Exemple pozitive: imagini care conțin câini**



**Exemple negative: imagini care NU conțin câini**



# Alt exemplu: 2 clase - indoor/outdoor

## Indoor – exemple



## Outdoor - exemple



Clasificare = asocierea unei etichete (indoor, outdoor) pentru exemple noi

outdoor



outdoor

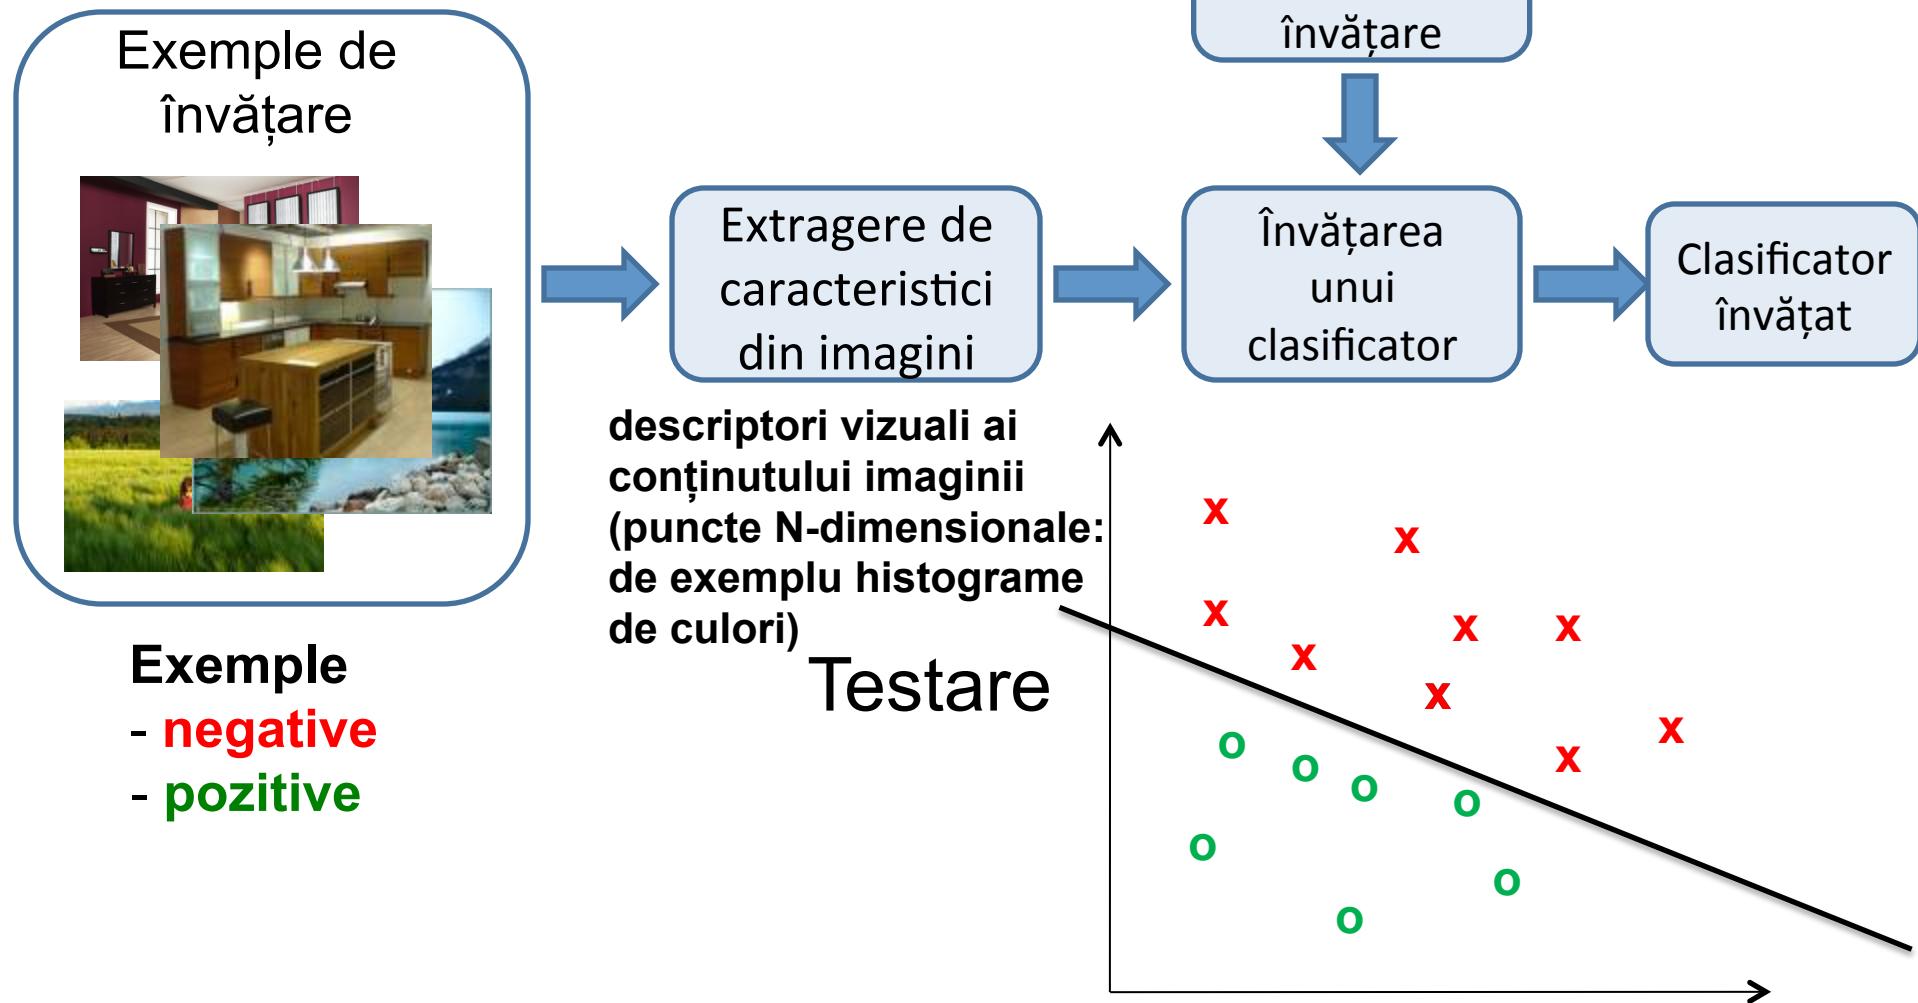


indoor

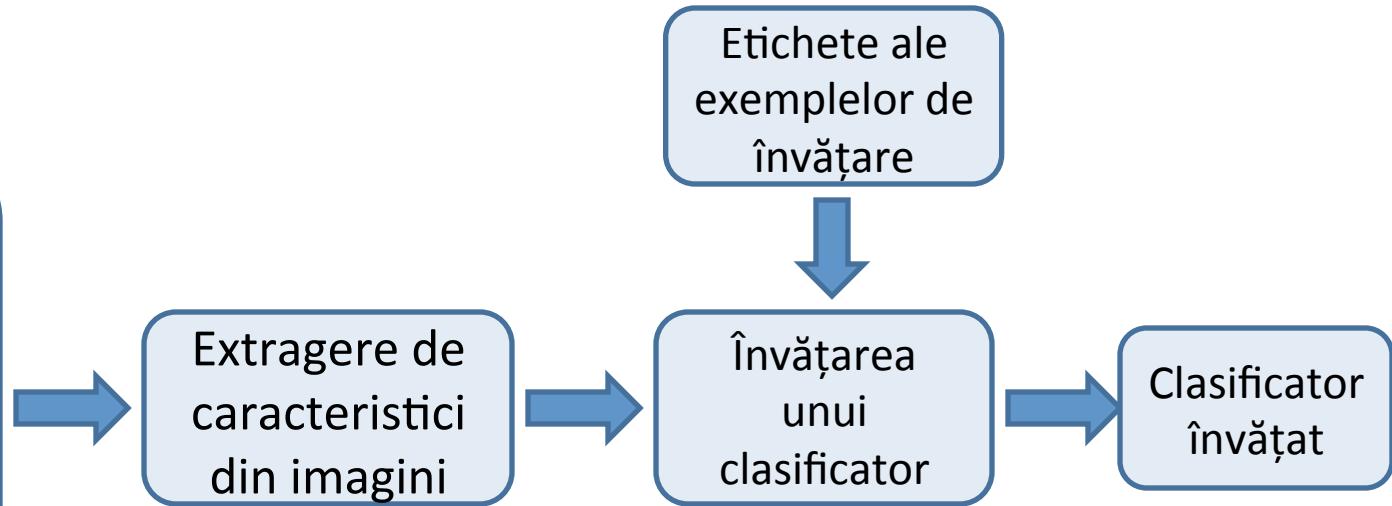


Imagini test:

# Învățarea supervizată



# Etapa de testare

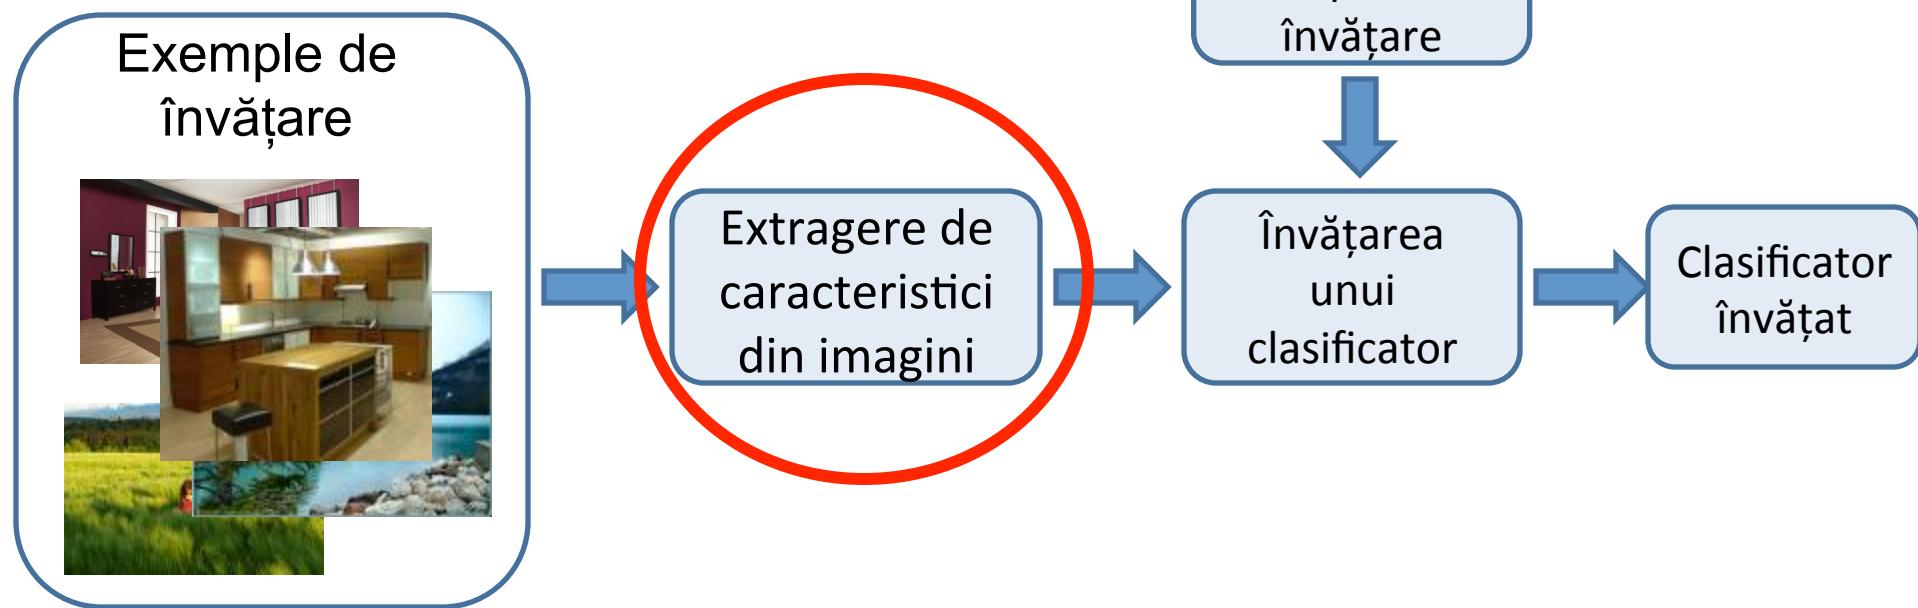


Imagine test

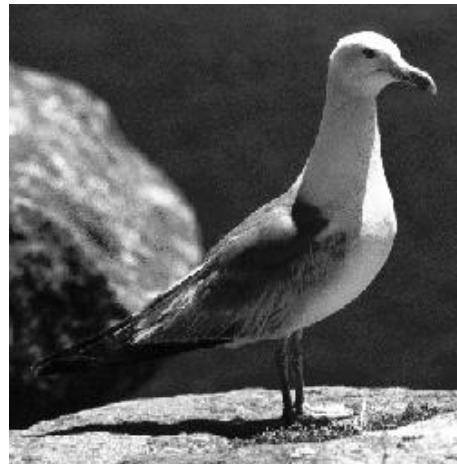
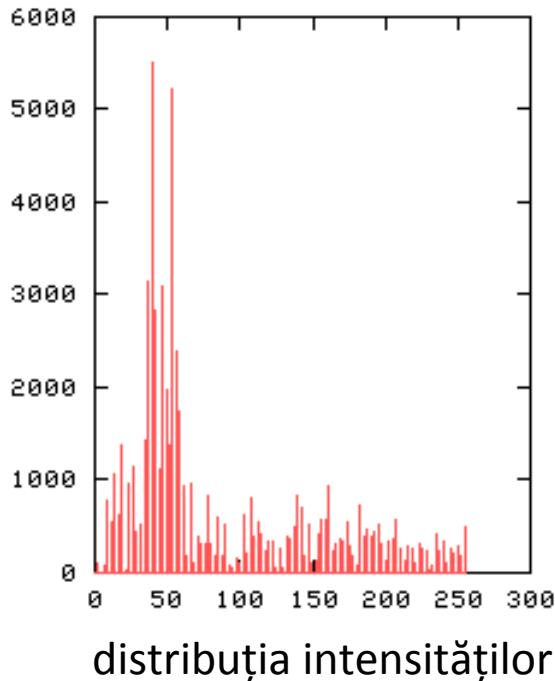
## Testare



# Extragere de caracteristici din imagini



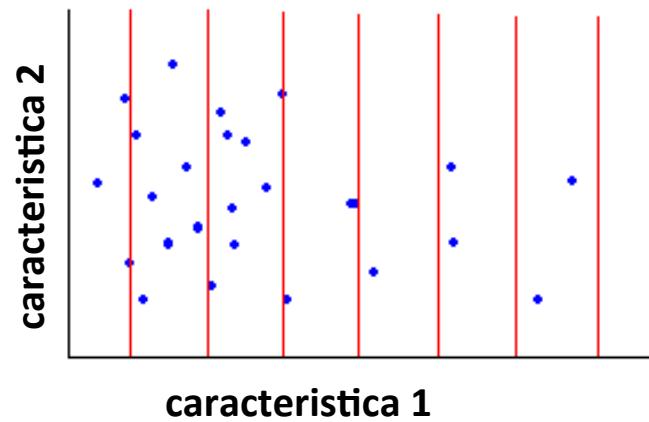
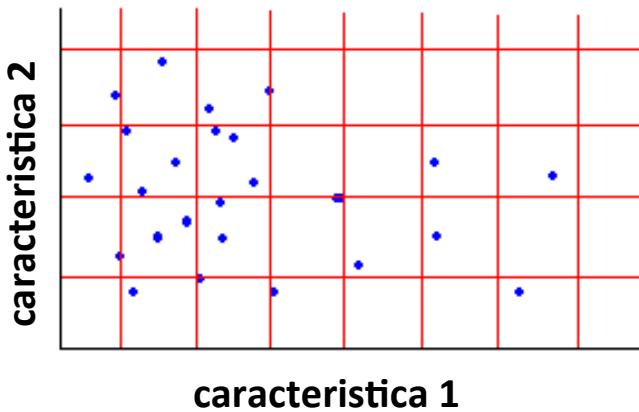
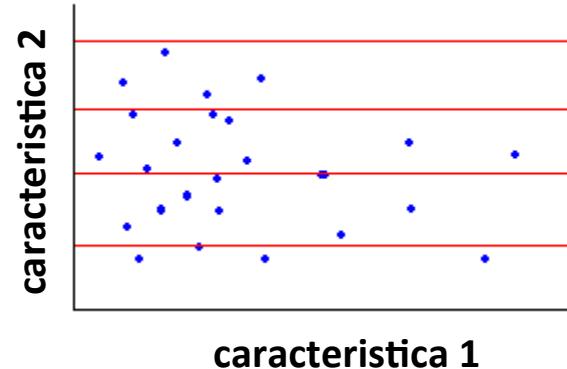
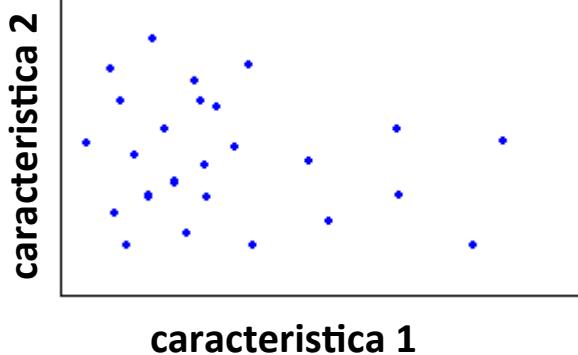
# Histograme pentru o caracteristică



Măsoară distribuția caracteristicilor (intensitate, culoare , textură):

- grupează datele în intervale și numără câte puncte “pică” în fiecare interval
- normalizează histograma ( suma elementelor = 1)

# Histograme pentru mai multe caracteristici



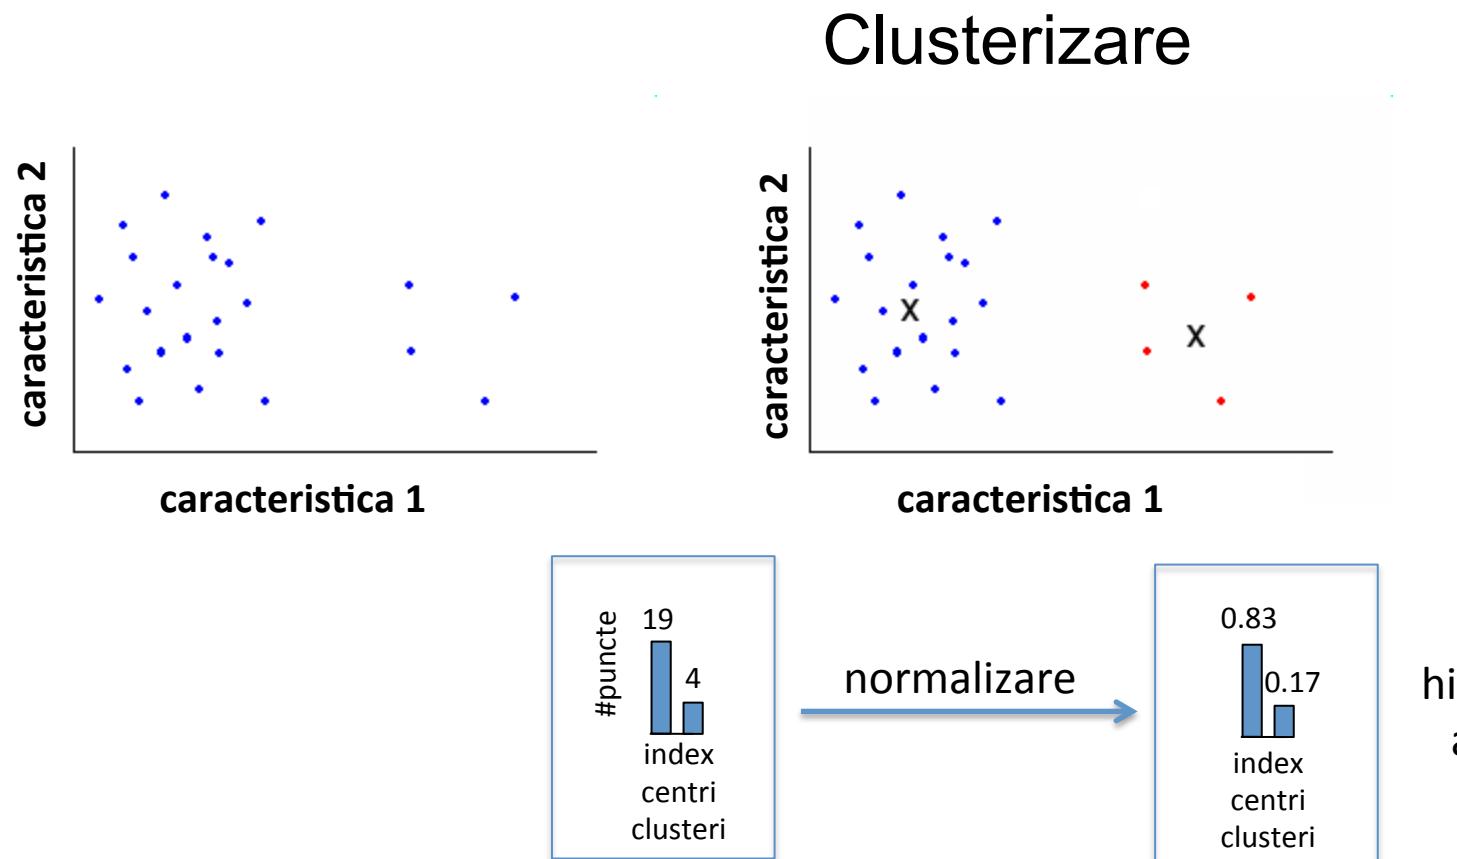
## Histograma comună

- necesită multe date pentru o aproximare bună a distribuției
- $\#intervale1 * \#intervale2$

## Histograma individuală

- necesită caracteristici independente
- mai multe puncte/interval decât în cazul histogramei comune

# Histograme pe baza clusterizării



Folosește aceeași centri ai clusterilor pentru toate imaginile

# Calculul distanței între histograme

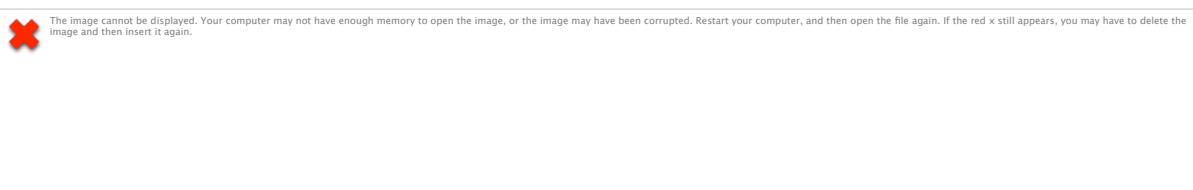
- Distanța Euclidină (L2)

$$d^2(h_i, h_j) = \sum_{m=1}^K (h_i(m) - h_j(m))^2$$

- Distanța Chi-pătrat

$$\chi^2(h_i, h_j) = \frac{1}{2} \sum_{m=1}^K \frac{(h_i(m) - h_j(m))^2}{h_i(m) + h_j(m)}$$

- Distanța dată de intersecția histogramelor



Histograme de culori cele mai apropiate (distanța Chi-pătrat)

# Histograme: detalii de implementare

- Gruparea datelor
  - Intervale: rapidă, dar aplicabilă pentru #dimensiuni mic
  - Clusterizare: înceată, dar aplicabilă pentru #dimensiuni mare



## Puține Intervale

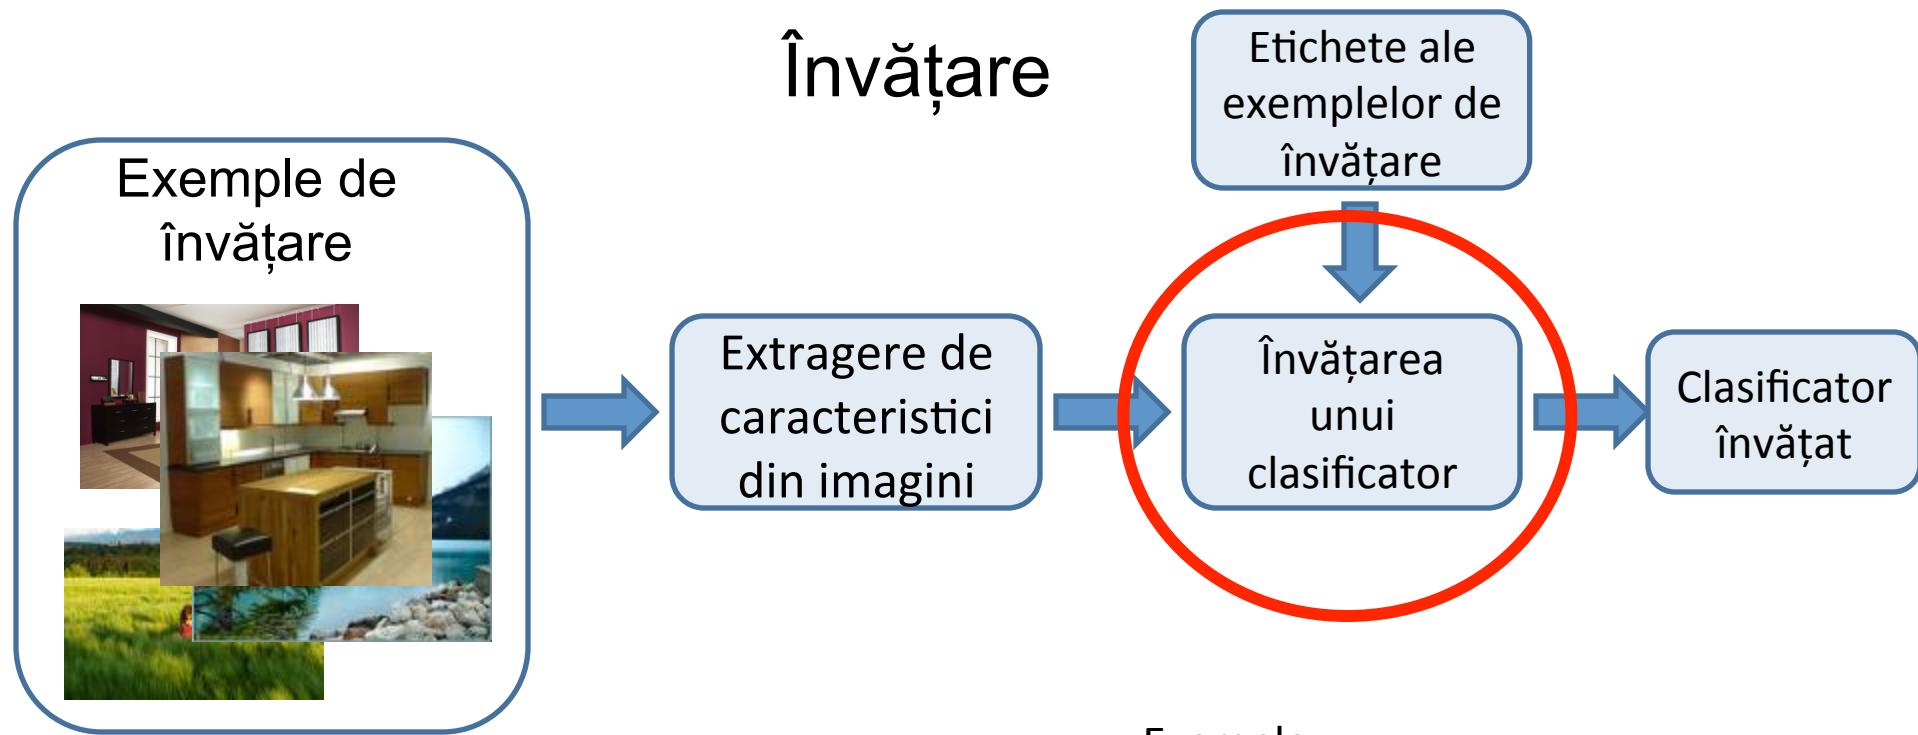
Puține puncte pentru estimare  
Reprezentare la nivel general

## Multe Intervale

Multe puncte pentru estimare  
Reprezentare detaliată

- Distanțe între histograme
  - Distanța Euclidiană + intersecția – rapid de calculat
  - Chi-pătrat – rezultate experimentale mai bune
  - alte distanțe

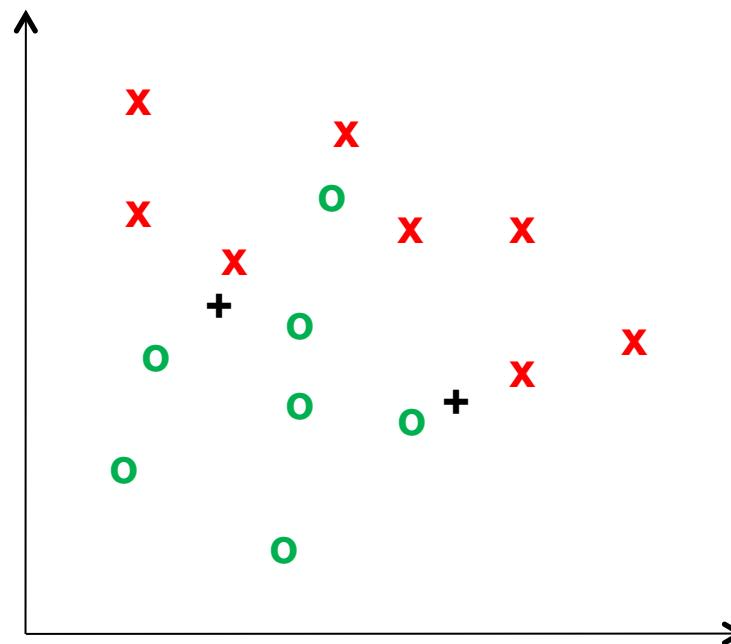
# Învățarea unui clasificator



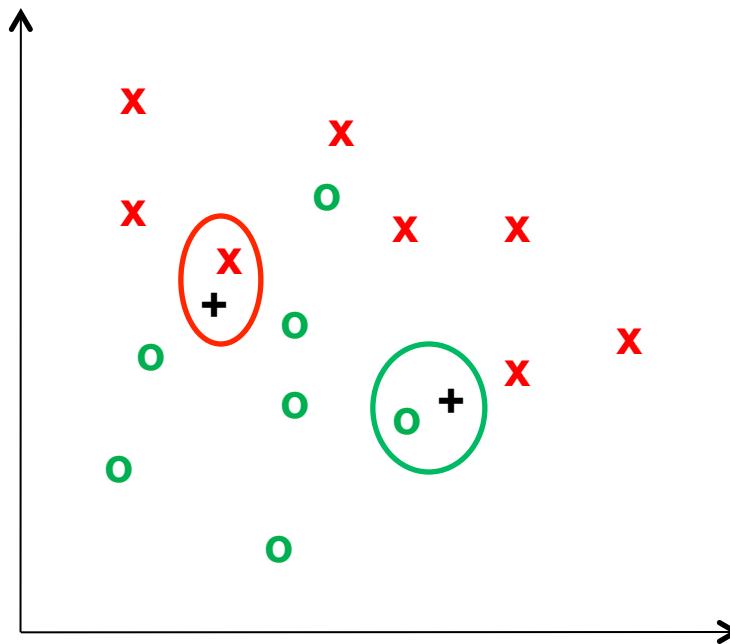
Exemple:

- cei mai apropiati K-vecini
- clasificator liniar

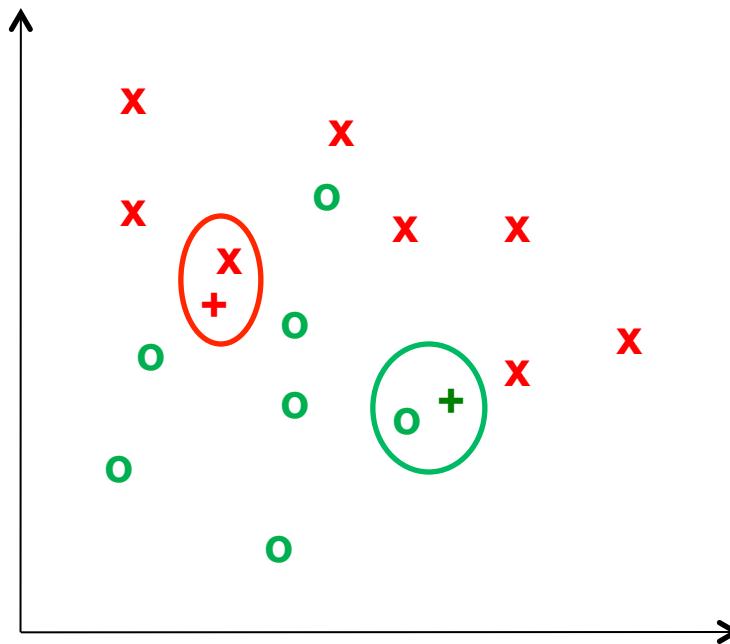
# Clasificatorul bazat pe cei apropiati K -vecini



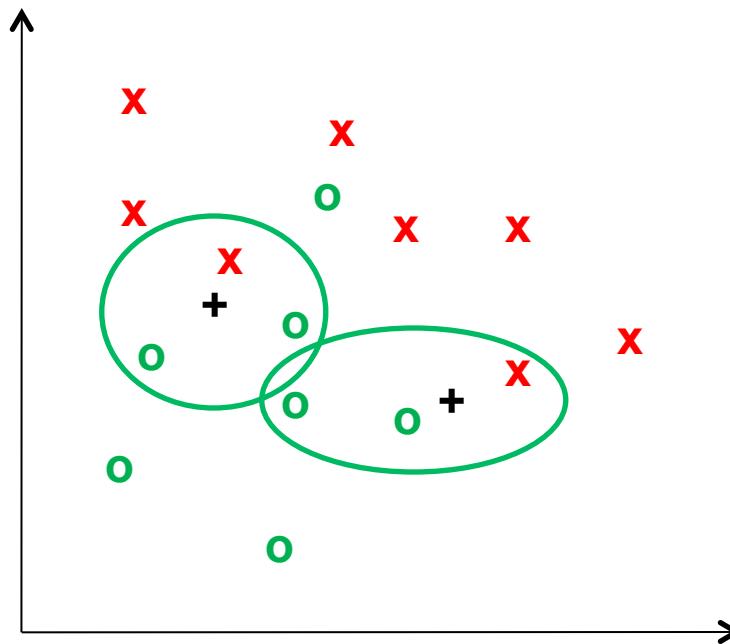
# K=1: cel mai apropiat vecini



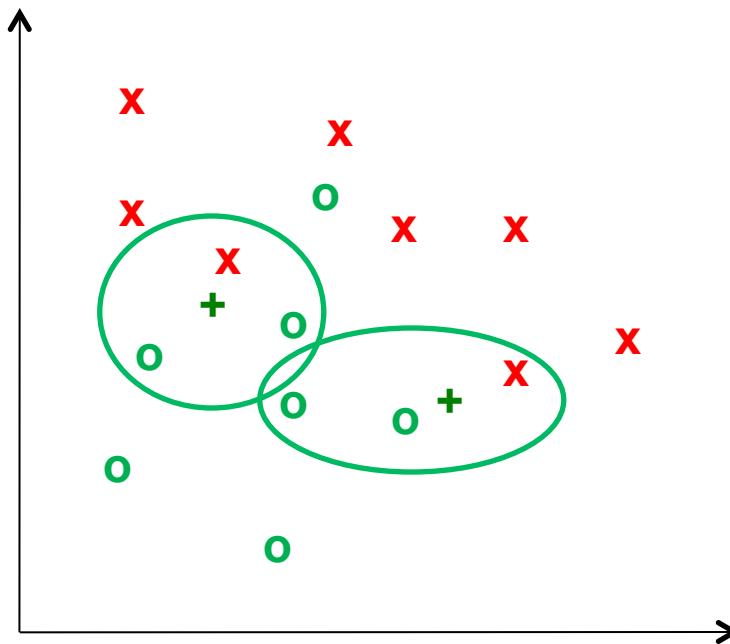
# K=1: cel mai apropiat vecini



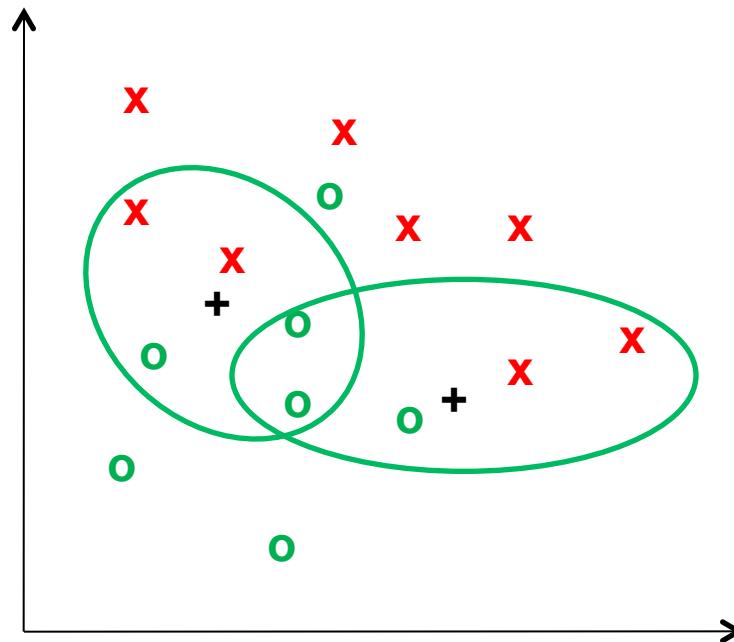
# K=3: cei mai apropiati 3 vecini



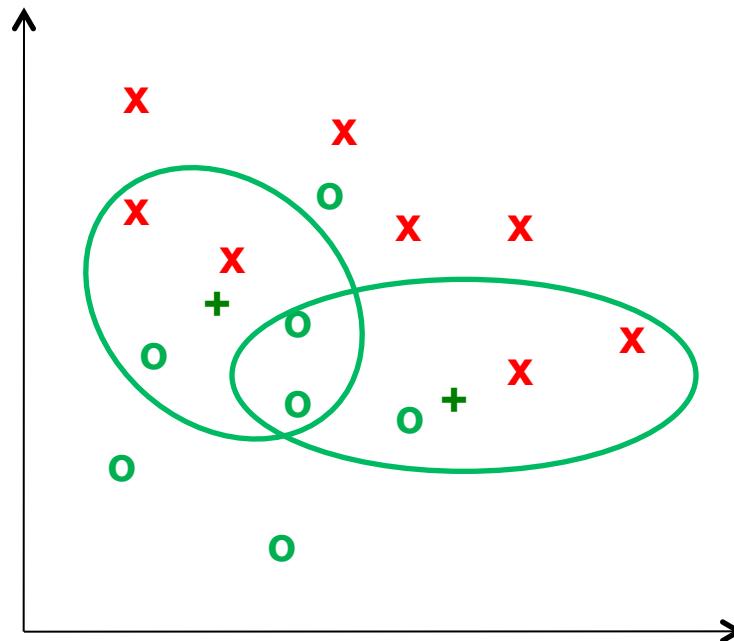
# K=3: cei mai apropiati 3 vecini



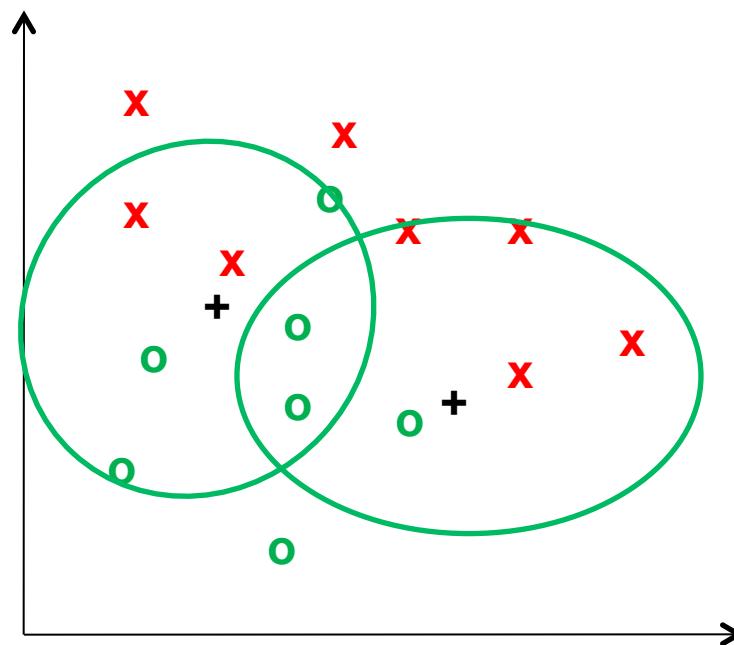
# K=5: cei mai apropiati 5 vecini



# K=5: cei mai apropiati 5 vecini



# Cei mai apropiati K-vecini

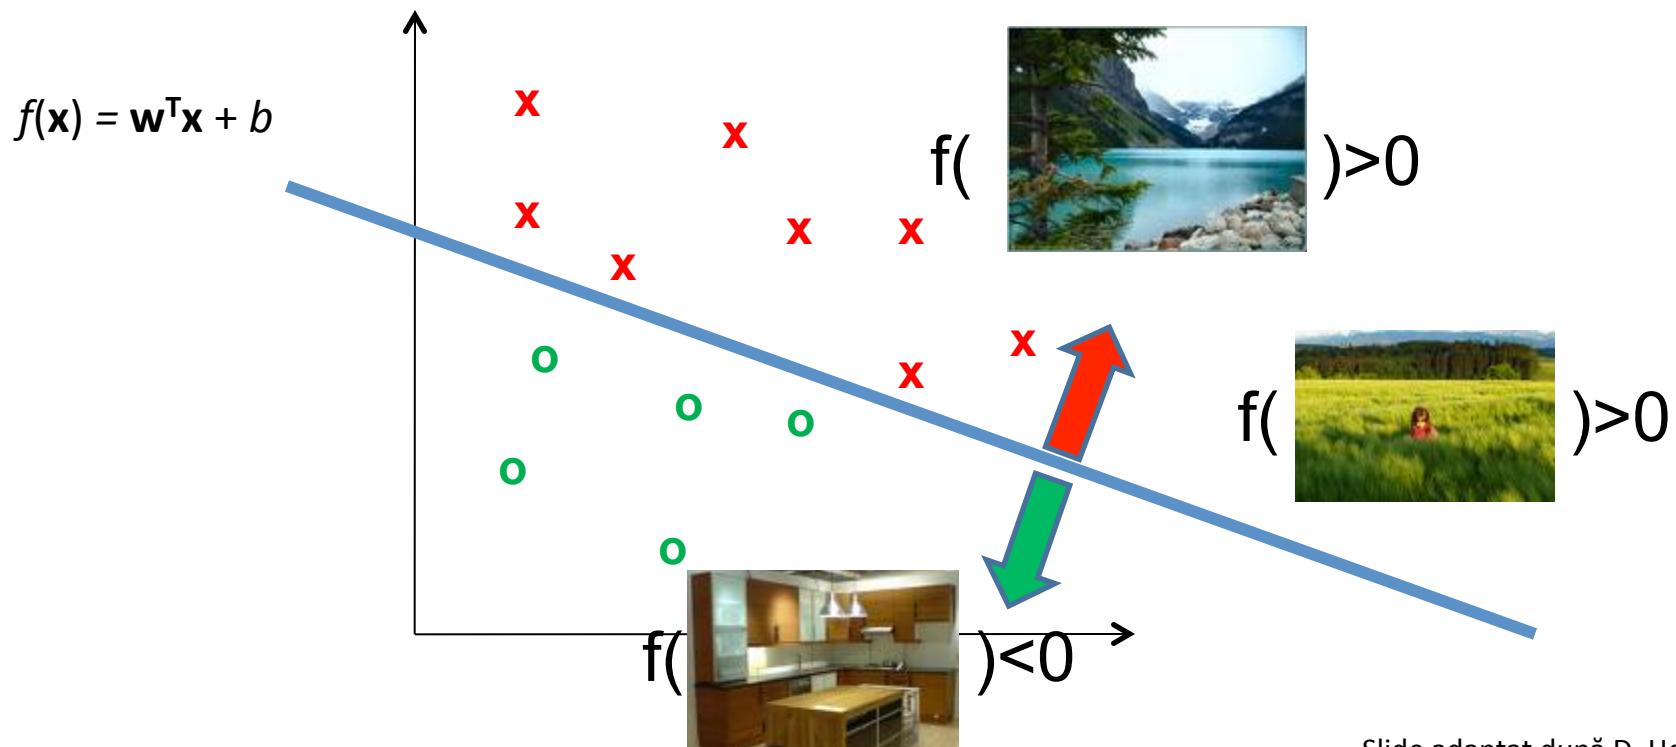


# Clasificatorul bazat pe cei apropiati K -vecini

- Foarte simplu, de încercat întotdeauna la început
- K-mare -> clasificator care nu variază abrupt
- Nu e nevoie de învățare

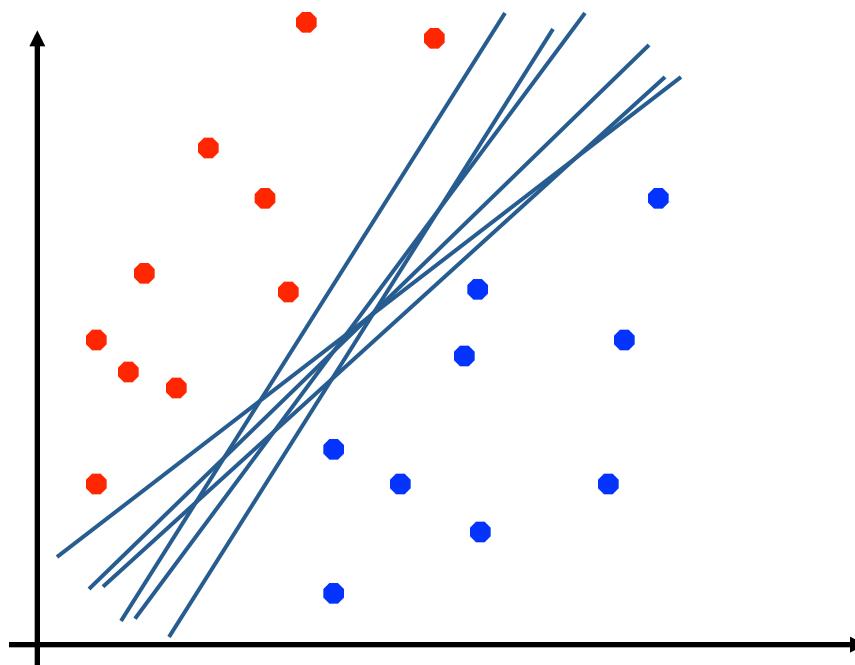
# Clasificatorul liniar

Găsește hiperplanul care separă exemplele din clase diferite



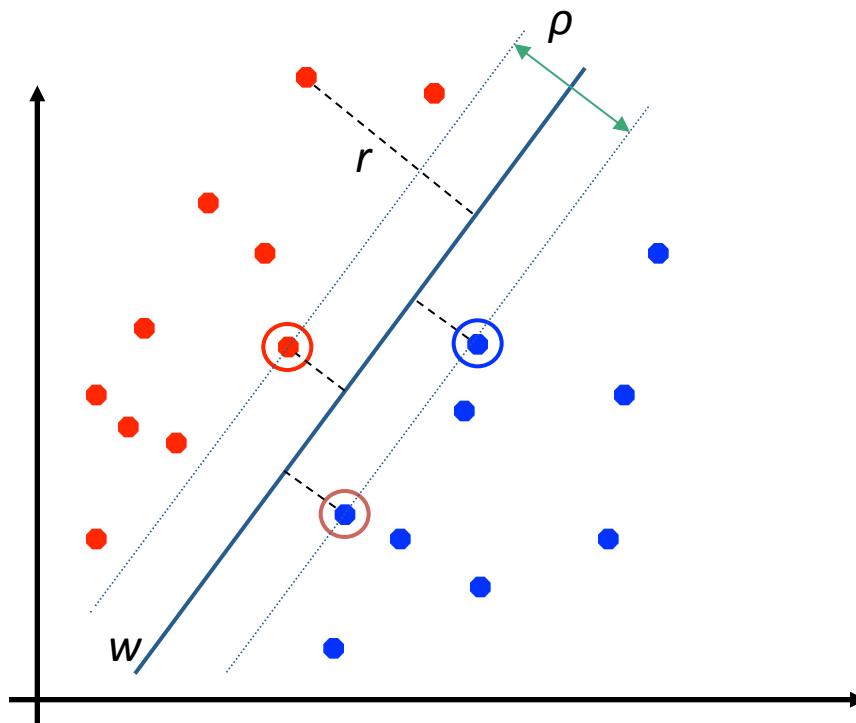
# Clasificatorul liniar

Care dintre clasificatorii liniari este optim?



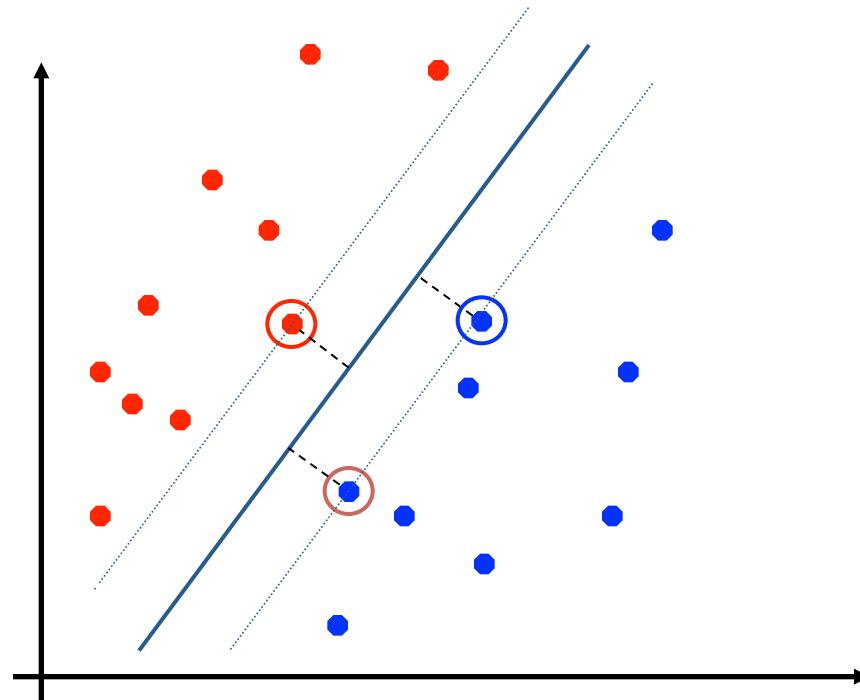
# Marginea de clasificare

- Distanța dintre exemplul  $\mathbf{x}_i$  și hiperplanul de separare este  $r = \frac{\mathbf{w}^T \mathbf{x}_i + b}{\|\mathbf{w}\|}$
- Examplele cele mai aproape de hiperplan se numesc **vectori suport**.
- **Marginea**  $\rho$  dintre cele două clase = distanța dintre vectorii suport.



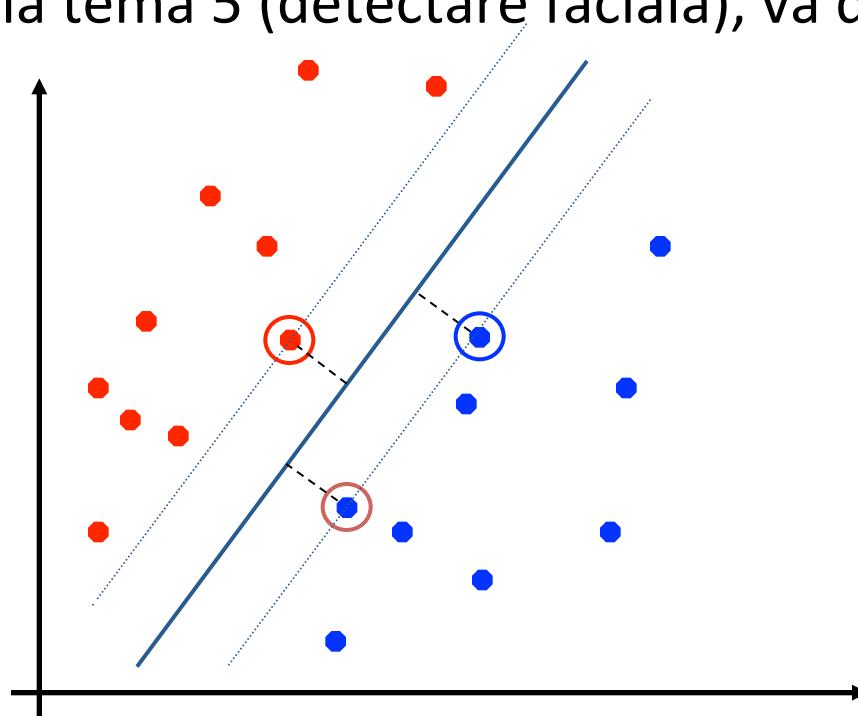
# Clasificatorul de margine maximă

- Numai vectorii suport contează; celealte exemple de învățare sunt ignore.
- Găsește clasificatorul pentru care *marginea ρ e maximă*



# Clasificatorul de margine maximă

- Formulare matematică riguroasă
- [https://en.wikipedia.org/wiki/Support\\_vector\\_machine#Definition](https://en.wikipedia.org/wiki/Support_vector_machine#Definition)
- Puțin cam complicată pentru nivelul vostru
- O să folosim la tema 5 (detectare facială), vă dăm noi codul



**Imagine**

**Bag of ‘visual words’**

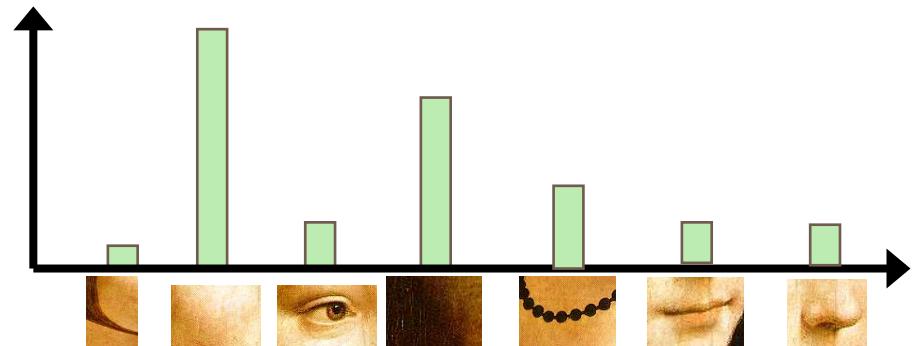
(sac de cuvinte vizuale)



**Imagine**

**Bag of ‘visual words’**

(sac de cuvinte vizuale)



Idee de bază: reprezentăm o imagine ca o histogramă de pattern-uri prototip (cuvinte vizuale)

**Imagine**

**Bag of ‘visual words’**

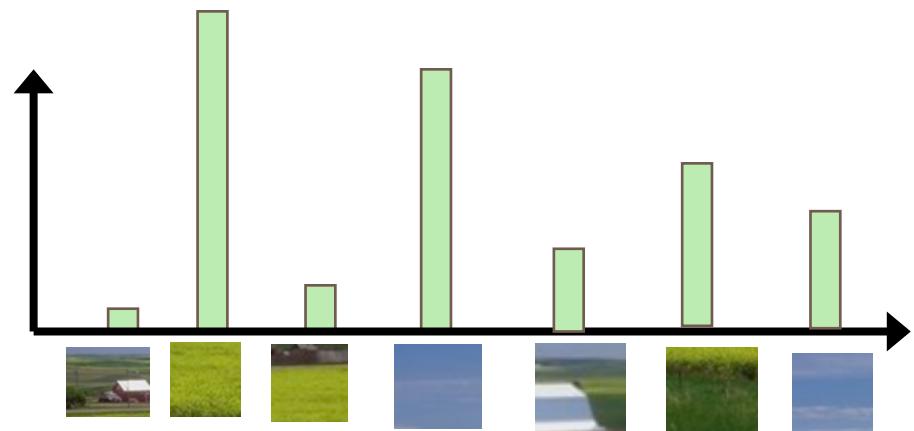
(sac de cuvinte vizuale)



**Imagine**

**Bag of ‘visual words’**

(sac de cuvinte vizuale)



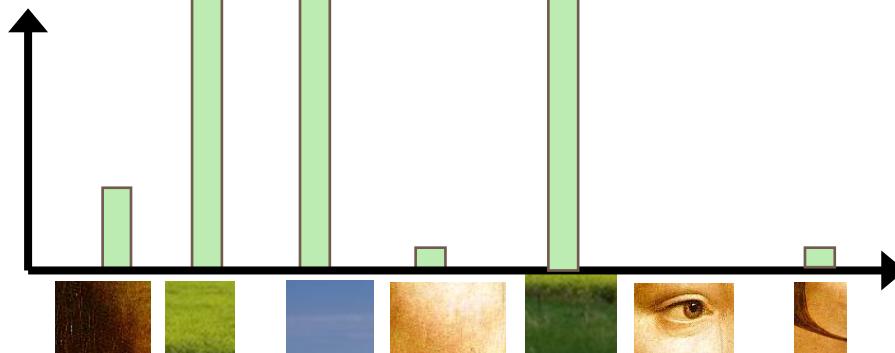
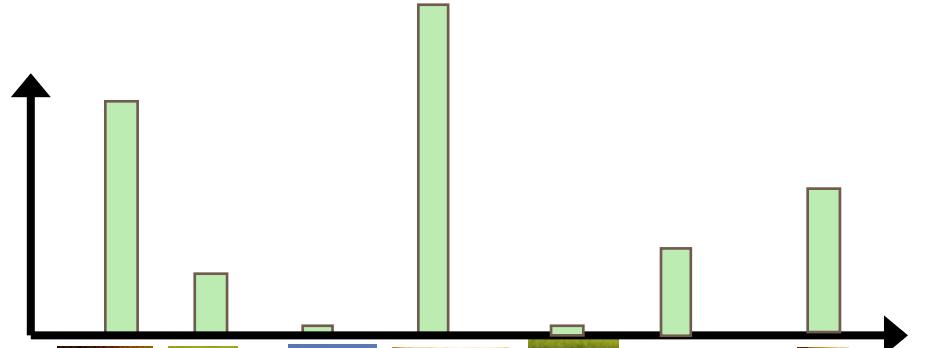
Idee de bază: reprezentăm o imagine ca o histogramă de pattern-uri prototip (cuvinte vizuale)

# Imagine

## Bag of ‘visual words’

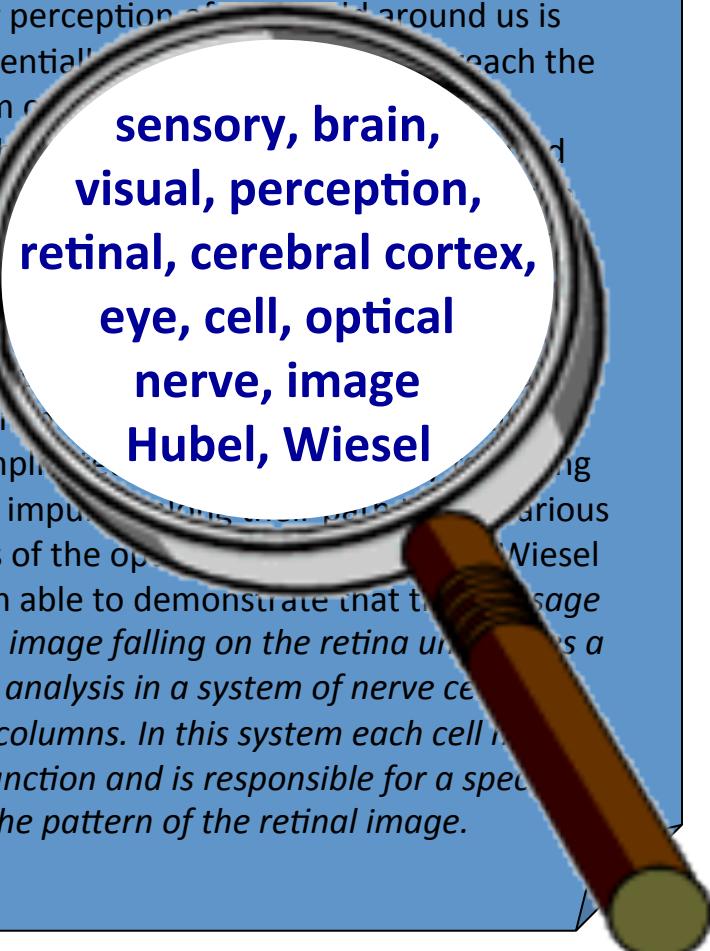
(sac de cuvinte vizuale)

Dacă vreau să compar imagini între ele nu pot să am pattern-uri prototip specifice pentru fiecare imagine. Vreau să am aceleasi pattern-uri prototip pentru toate imaginile astfel încât comparația să fie posibilă.



# Modele de tip bag-of-words: reprezentarea documentelor

Of all the sensory impressions proceeding to the brain, the visual experiences are the dominant ones. Our perception of the world around us is based essentially upon what reaches the brain from our eyes. We have thought that the point by which the cerebrum receives information upon what it sees is the optic nerve. Through now known that perception is a more complicated process than was at first imagined. The visual impulses pass through various cell layers of the optic nerve, and Wiesel and Hubel have been able to demonstrate that the message about the image falling on the retina undergoes a step-wise analysis in a system of nerve cells stored in columns. In this system each cell has a specific function and is responsible for a specific detail in the pattern of the retinal image.



Care este domeniul (sport, politică, divertisment, medicină, economie, etc.) despre care se face referire în document?

MEDICINĂ

# Modele de tip bag-of-words: reprezentarea documentelor

Of all the sensory impressions proceeding to the brain, the visual experiences are the dominant ones. Our perception of the world around us is based essentially on the visual system. Light reaches the brain from our eyes through the optic nerve and is processed by the cerebral cortex. We have thought that the visual system worked in this way since the point by which the optic nerve enters the brain was identified. Through the work of Hubel and Wiesel we now know that the visual system is much more complex than this. By stimulating various points on the retina and analysing the responses of the various cell layers of the optic nerve, Hubel and Wiesel have been able to demonstrate that the message about the image falling on the retina undergoes a step-wise analysis in a system of nerve cells stored in columns. In this system each cell has a specific function and is responsible for a specific detail in the pattern of the retinal image.

**sensory, brain,  
visual, perception,  
retinal, cerebral cortex,  
eye, cell, optical  
nerve, image  
Hubel, Wiesel**

China is forecasting a trade surplus of \$90bn (£51bn) to \$100bn this year, a threefold increase on 2004's \$32bn. The Commerce Ministry said the surplus would rise further next year, as it predicted 30% jump in exports and 15% in imports, with a 18% rise in imports. The ministry also predicted a further a 10% increase in exports next year. China's deliberations over the surpluses have been one factor behind the recent Xiaochuan's decision to allow more to be printed. The central bank stayed within its mandate of keeping the value of the yuan stable against the US dollar. It allowed the yuan to appreciate 0.2% in July and permitted it to fluctuate within a narrow band, but the US wants the yuan to be allowed to trade freely. However, Beijing has made clear that it will take its time and tread carefully before allowing the yuan to rise further in value.

**China, trade,  
surplus, commerce,  
exports, imports, US,  
yuan, bank, domestic,  
foreign, increase,  
trade, value**

# Modele de tip bag-of-words: reprezentarea documentelor

- Reprezentarea documentelor pe baza frecvențelor cuvintelor dintr-un dicționar



Cuvintele cu frecvența cea mai mare: Iraq, terrorists, economy, ...

Salton & McGill (1983)

# Modele de tip bag-of-words: reprezentarea documentelor

- Reprezentarea documentelor pe baza frecvențelor cuvintelor dintr-un dicționar

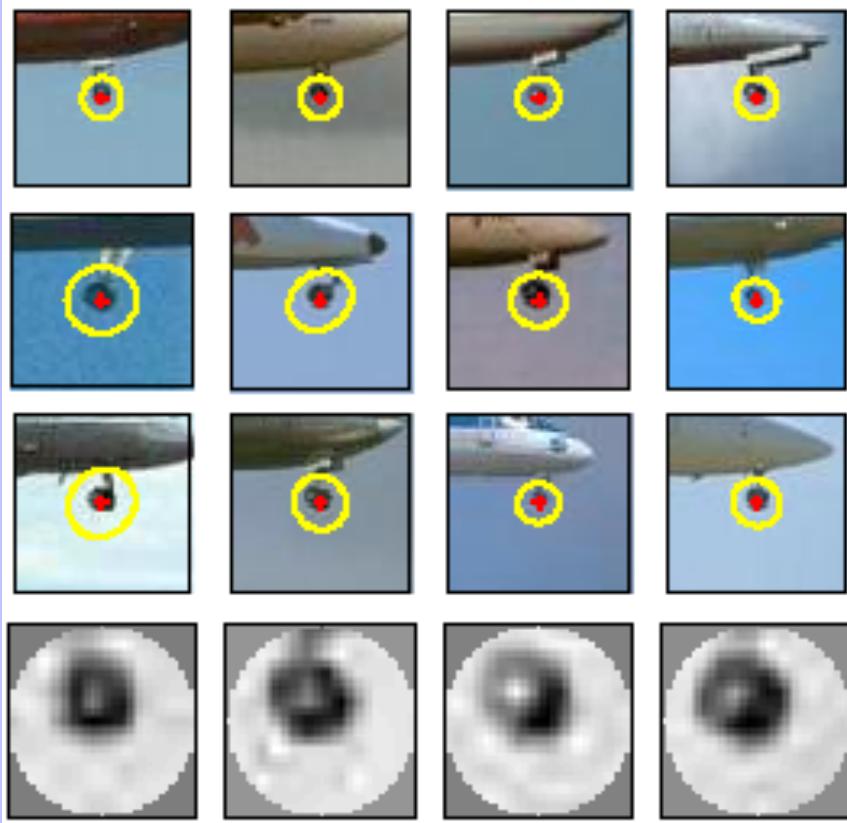


# Modele de tip bag-of-words: reprezentarea documentelor

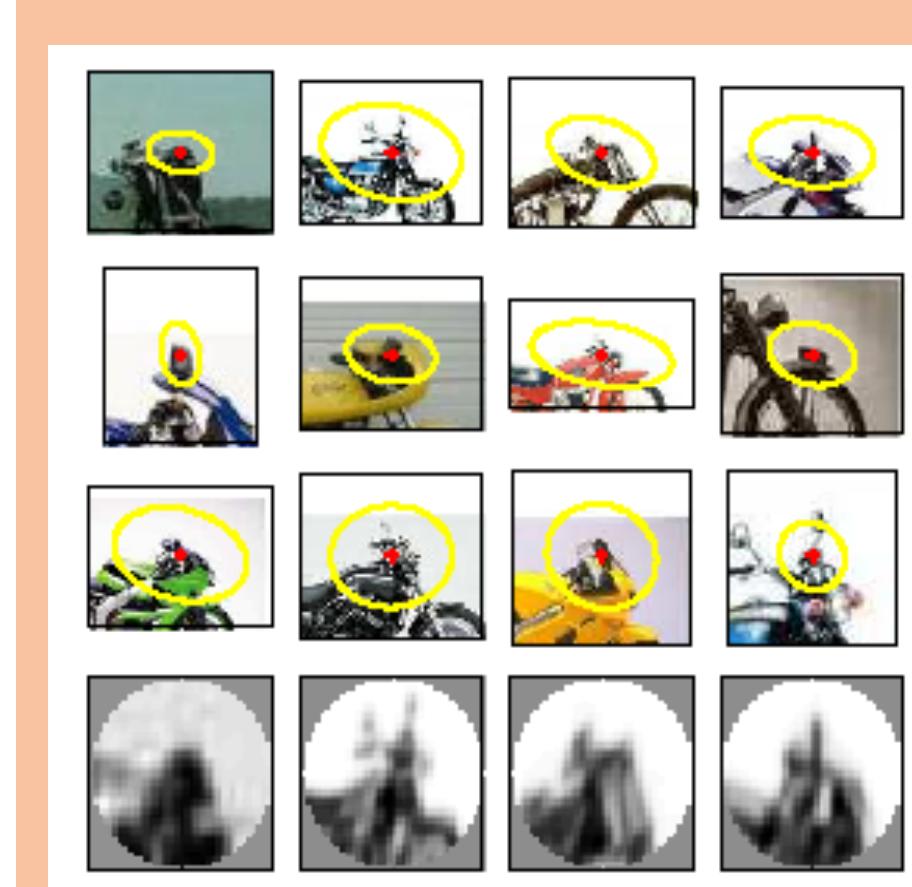
- Reprezentarea documentelor pe baza frecvențelor cuvintelor dintr-un dicționar



# Visual words = cuvinte vizuale



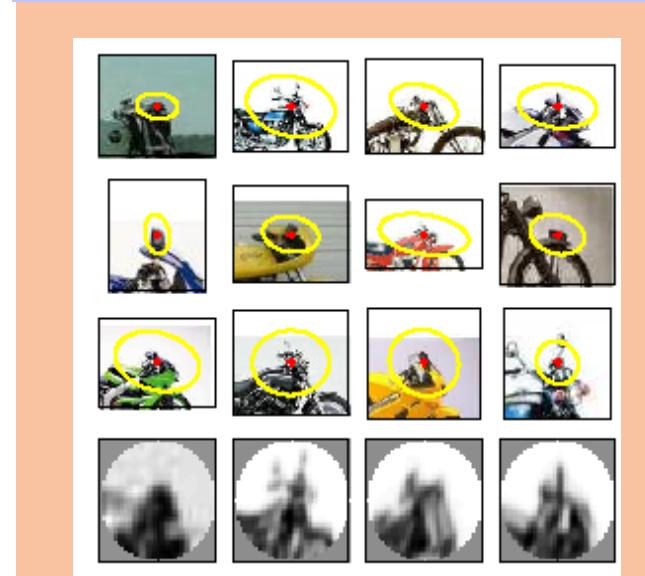
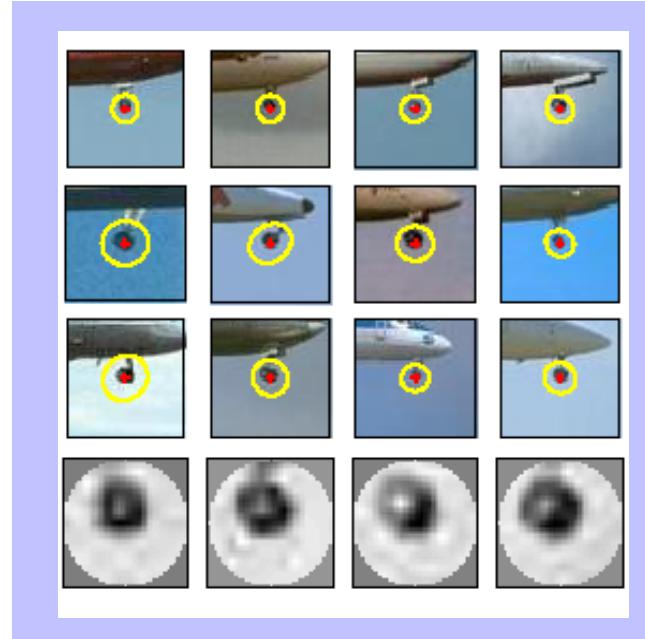
Subimaginea (patch-ul) care conține roata unui avion este diferită în fiecare imagine, dar foarte asemănătoare.



Subimaginea (patch-ul) care conține ghidonul unei motociclete este diferită în fiecare imagine, dar foarte asemănătoare.

# Visual words = cuvinte vizuale

- Descriem cu ajutorul lor înfățișarea obiectelor
- Înfățișarea obiectelor variază foarte mult chiar și pentru aceeași clasă de obiecte
- Înfățișarea locală a părților componente variază mai puțin
- **Ideal: cuvânt vizual = parte a unui obiect**
- **Descriem imaginile ca histograme de cuvinte vizuale**



# Modelul ‘bag of visual words’

## 1. Multime de imagini

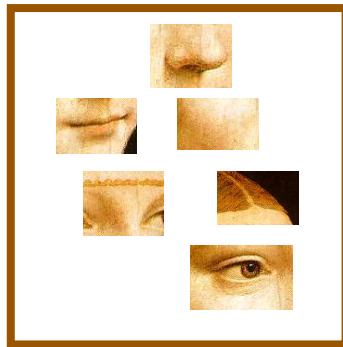


# Modelul ‘bag of visual words’

1. Multime de imagini



2. Extragem caracteristici din fiecare imagine



# Modelul ‘bag of visual words’

1. Multime de imagini



2. Extragem caracteristici din fiecare imagine
3. Învățăm un vocabular vizual = dicționar



# Modelul ‘bag of visual words’

1. Multime de imagini



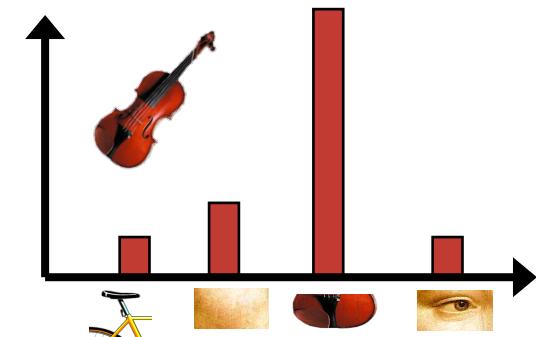
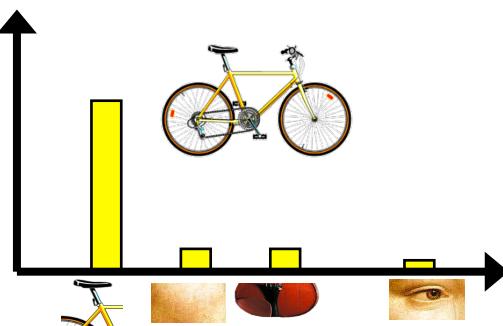
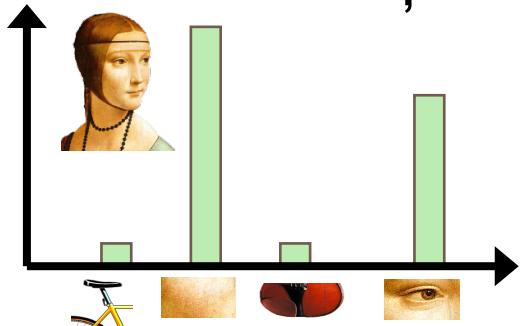
2. Extragem caracteristici din fiecare imagine
3. Învățăm un vocabular vizual = dicționar
4. Fiecare caracteristică este asignată ‘cuvântului vizual’ din dicționar cel mai apropiat

# Modelul ‘bag of visual words’

1. Multime de imagini



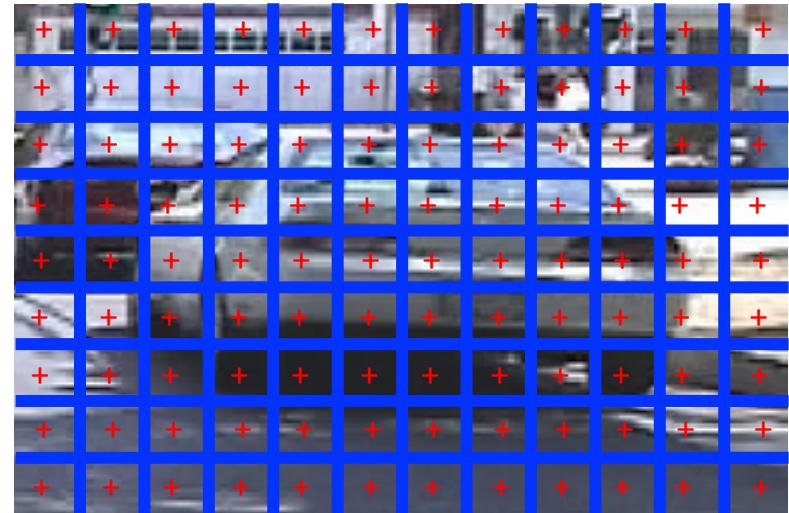
2. Extragem caracteristici din fiecare imagine
3. Învățăm un vocabular vizual = dicționar
4. Fiecare caracteristică este asignată ‘cuvântului vizual’ din dicționar cel mai apropiat
5. Reprezentăm imaginile pe baza unei histograme de frecvențe a ‘cuvintelor vizuale’



# 2. Extragerea de caracteristici

Puncte pe un caraoj, puncte ‘interesante’, puncte alese aleator în imagine

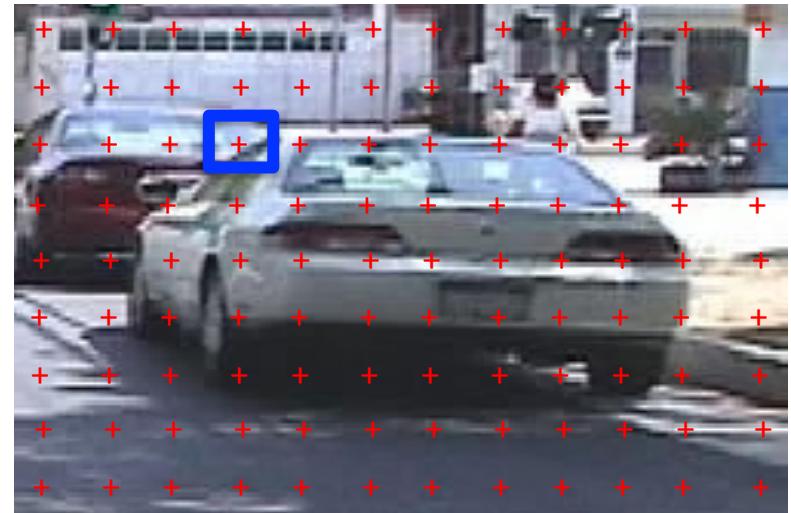
Descriem un **patch** (portiune mică din imagine) centrată pentru fiecare **punct ales**



# 2. Extragerea de caracteristici

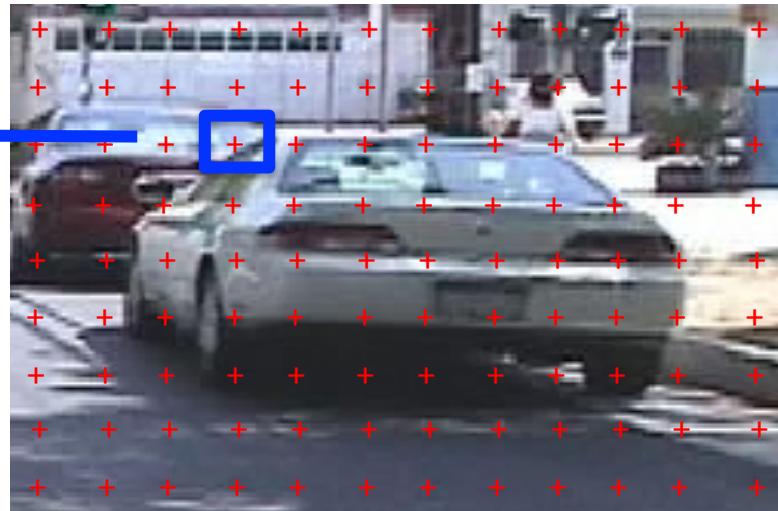
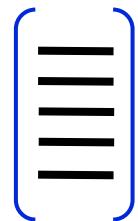
Puncte pe un caraoj, puncte ‘interesante’, puncte alese aleator în imagine

Descriem un **patch** (portiune mică din imagine) centrată pentru fiecare **punct ales**



Imaginea 1

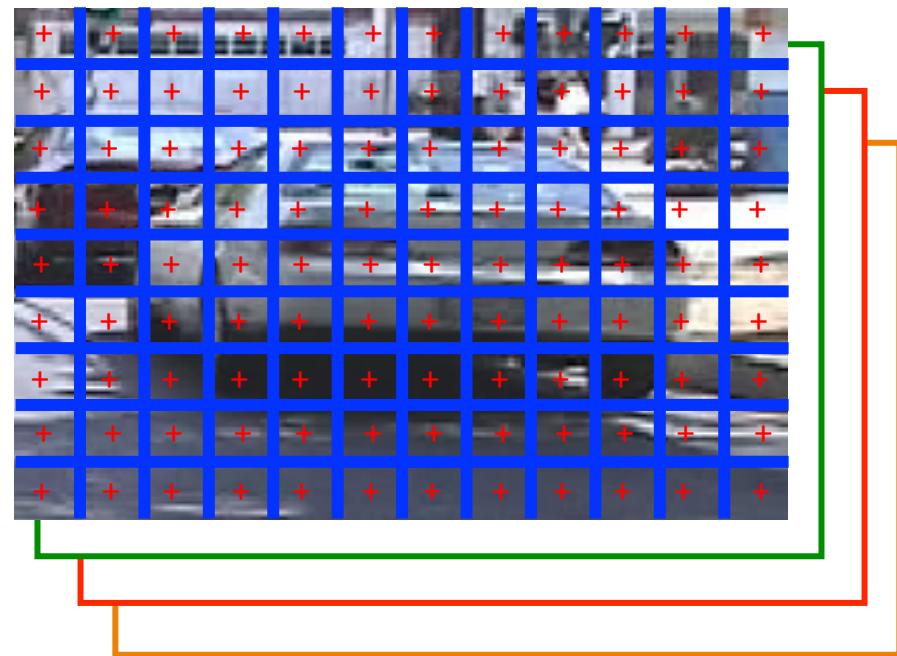
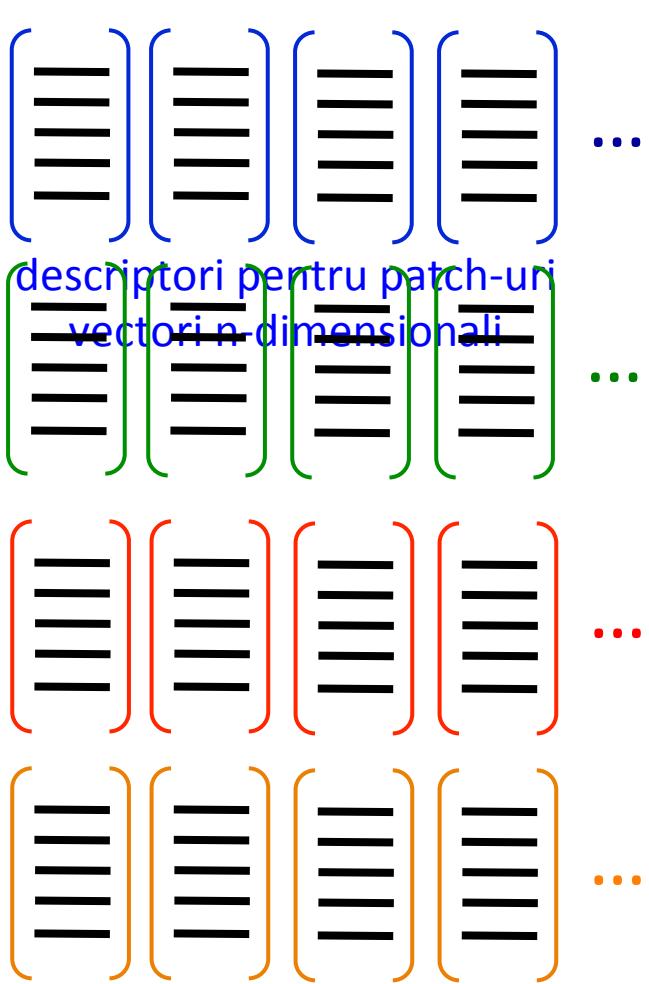
## 2. Extragerea de caracteristici



Calculează  
descriptor

Imaginea 1

## 2. Extragerea de caracteristici



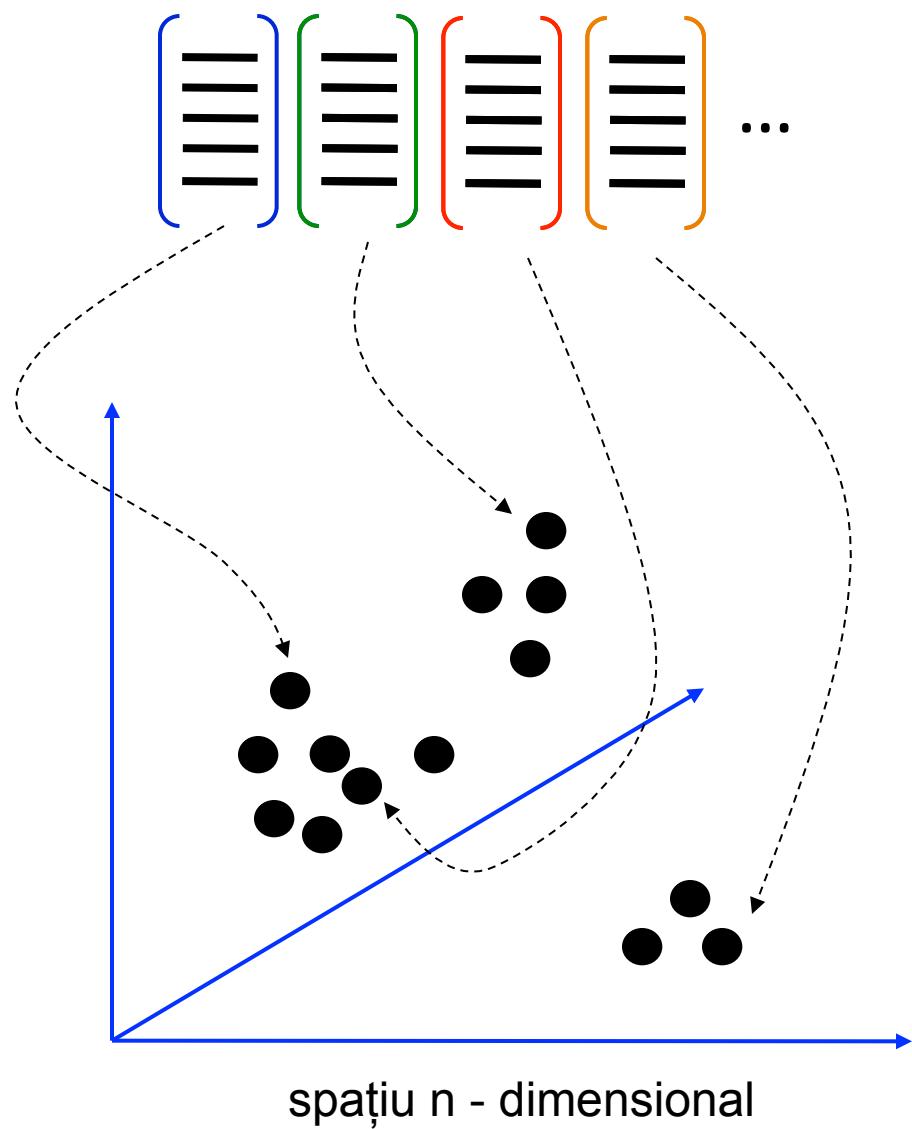
Imaginea 1

Imaginea 2

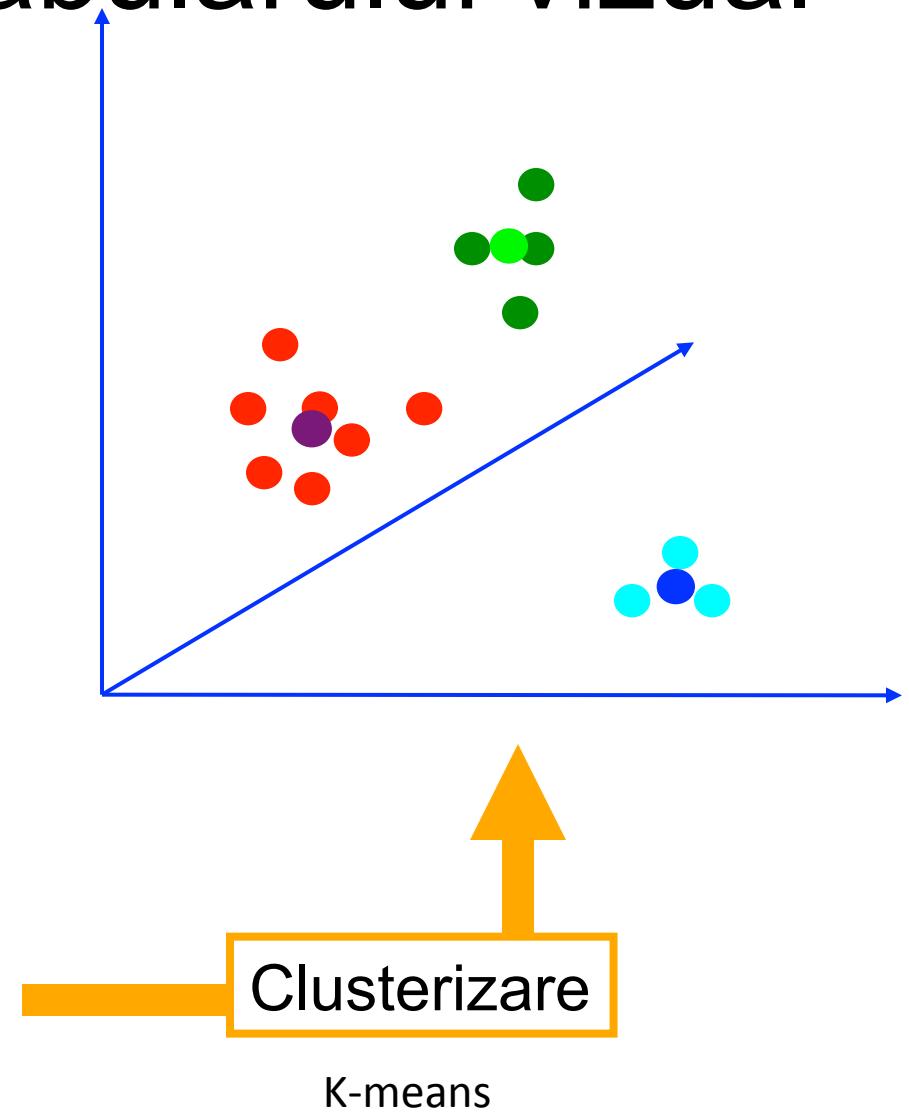
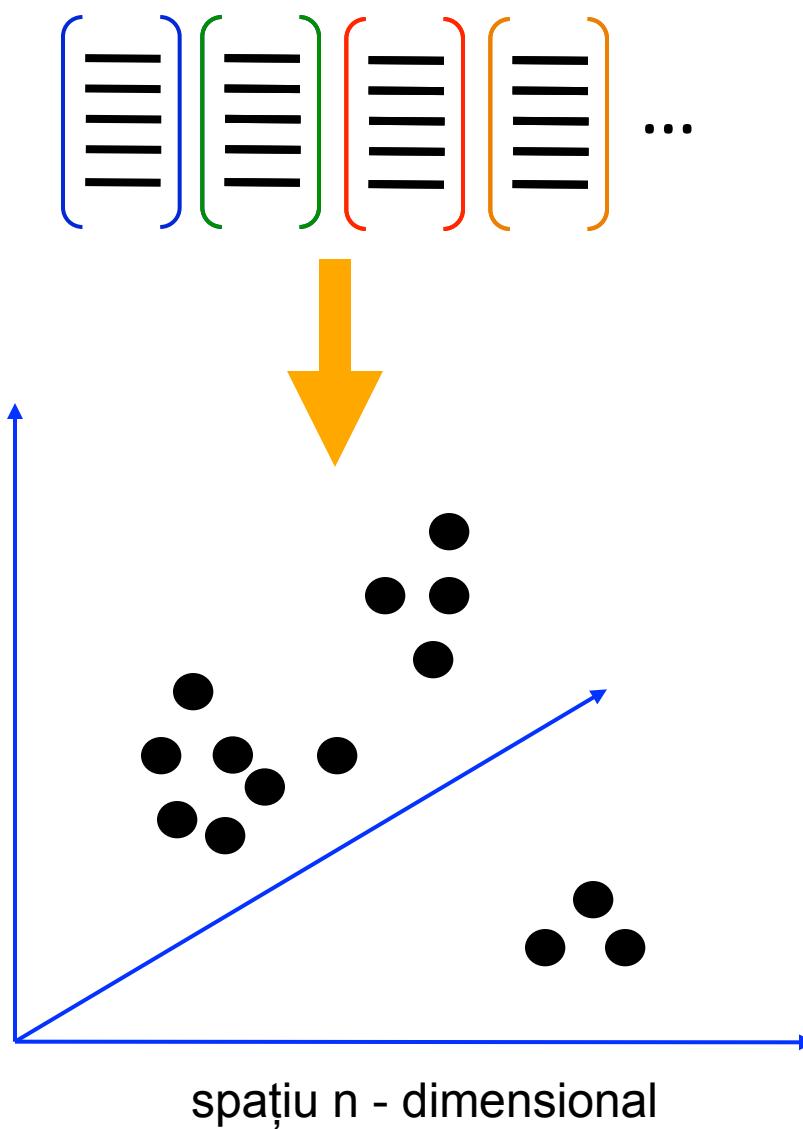
Imaginea 3

Imaginea 4

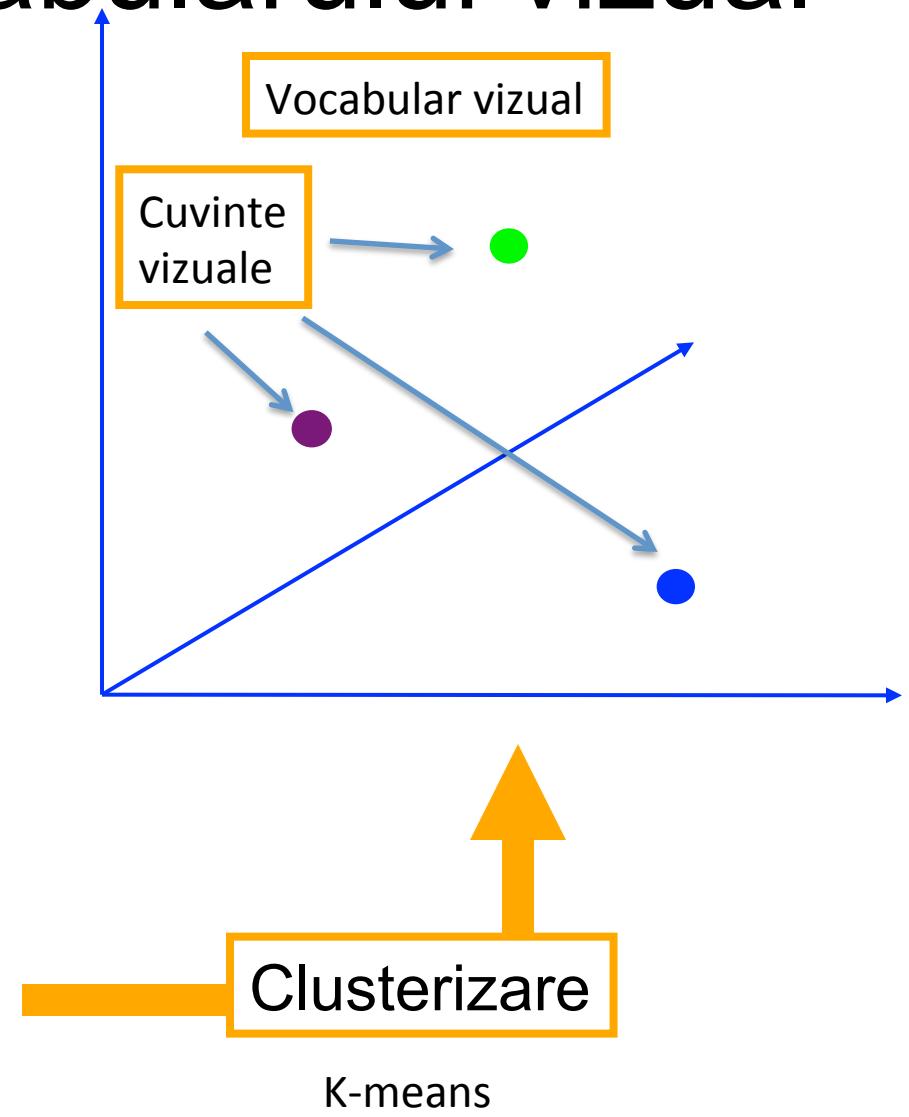
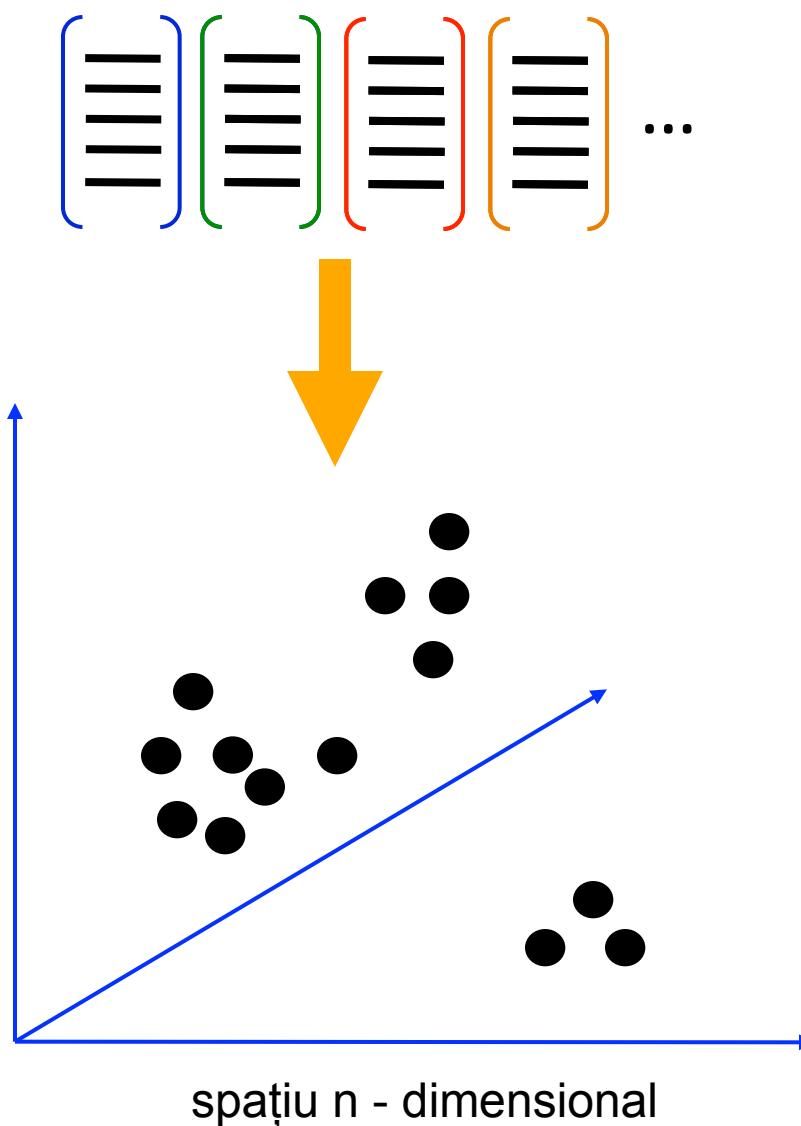
# 3. Învățarea vocabularului vizual



# 3. Învățarea vocabularului vizual



# 3. Învățarea vocabularului vizual



# Clusterizarea K-means

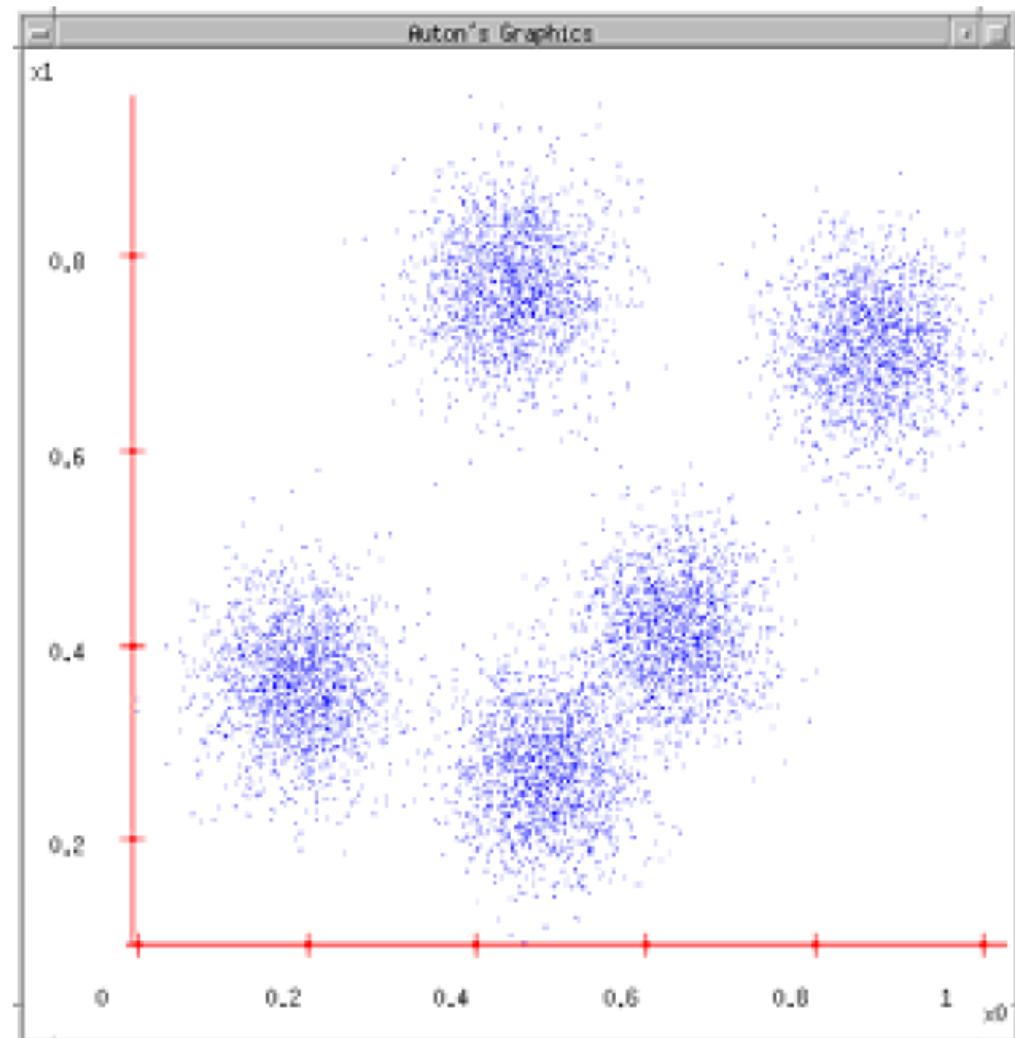
- Vrem să minimizăm suma pătratelor distanțelor Euclidiene dintre caracteristicile  $\mathbf{x}_i$  și cei mai apropiati centri ai clusterilor  $\mathbf{m}_k$

$$D(X, M) = \sum_{\text{clusterul } k} \sum_{\substack{\text{punctul } i \text{ în} \\ \text{clusterul } k}} (\mathbf{x}_i - \mathbf{m}_k)^2$$

- Algoritm:
  - inițializăm aleator cei K centri ai clusterilor
  - iterăm până la convergență:
    1. etichetăm fiecare caracteristică în funcție de cel mai apropiat centru al unui cluster
    2. recalculăm centrul fiecărui cluster = media tuturor caracteristicilor cu aceeași etichetă

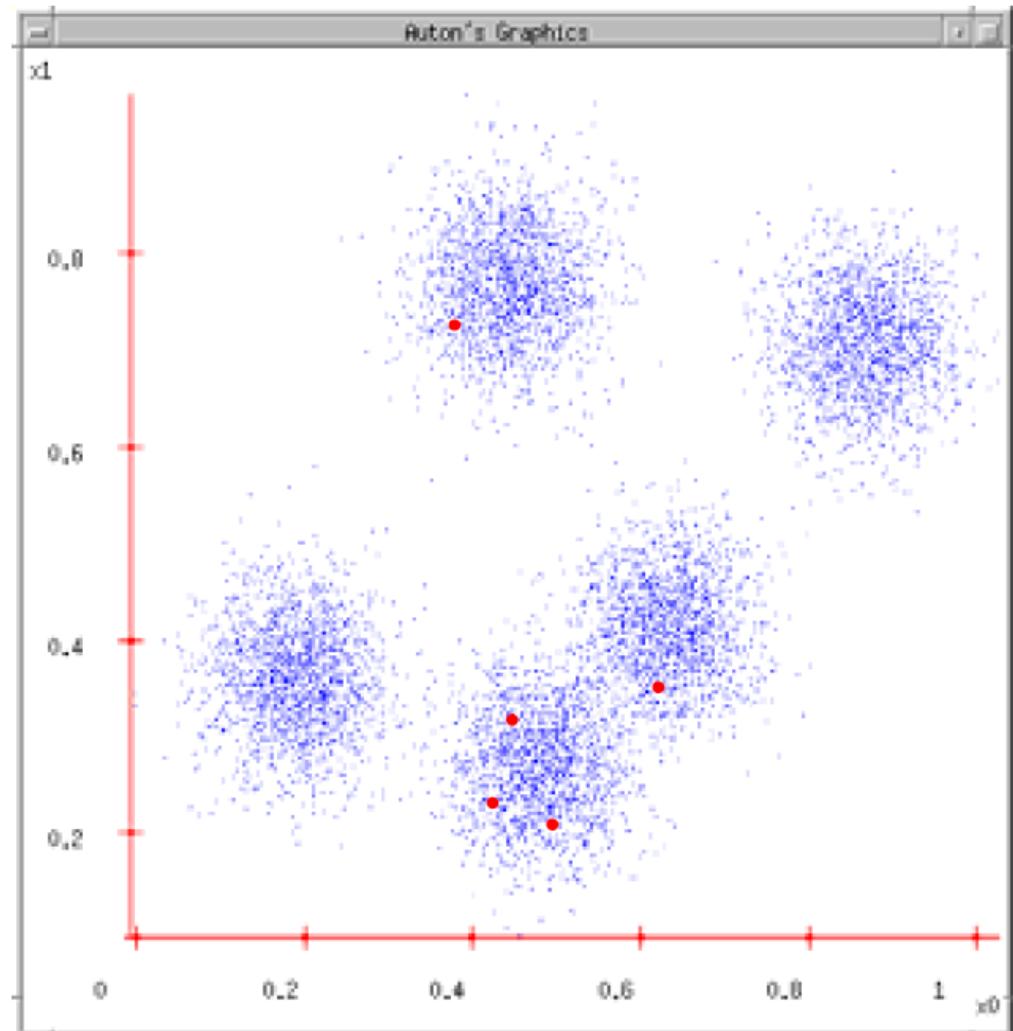
# K-means - exemplu

1. Inițializăm numărul de clusteri ( $k=5$ )



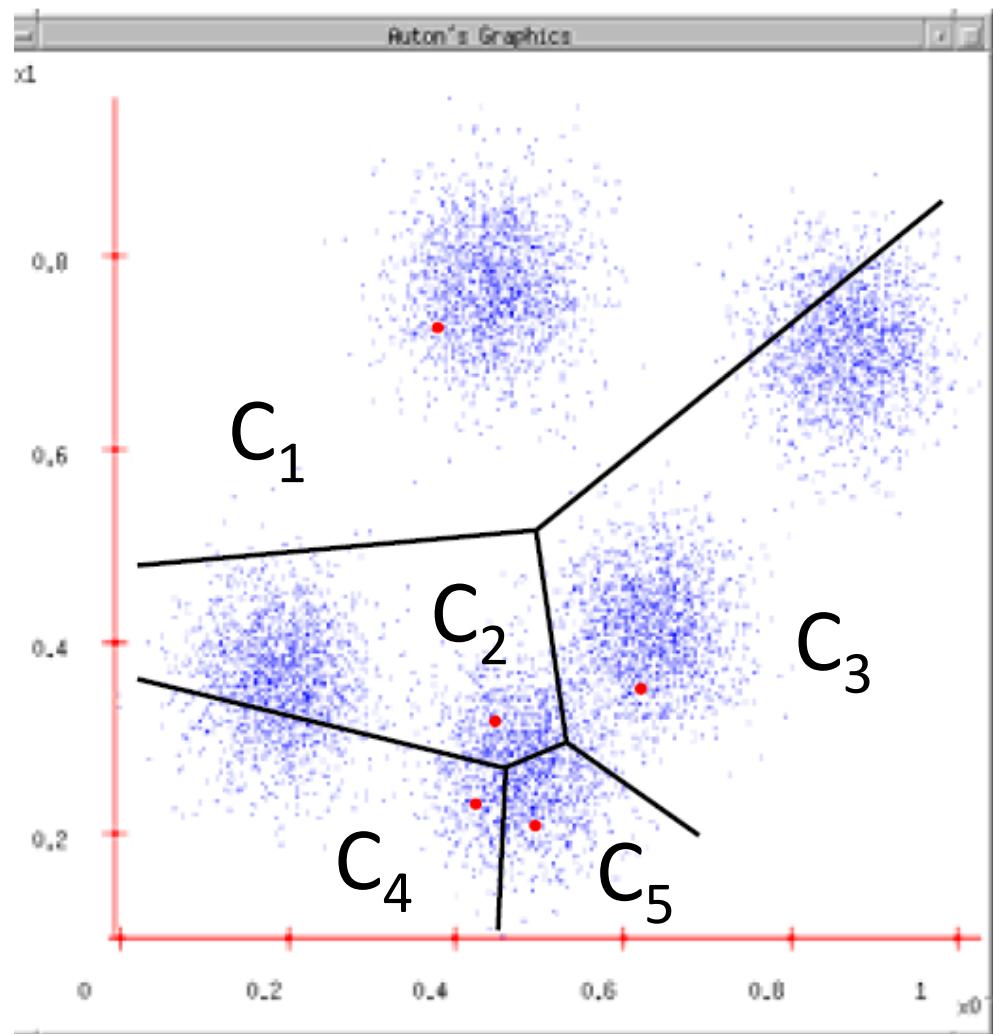
# K-means - exemplu

1. Inițializăm numărul de clusteri ( $k=5$ )
2. Alegem aleator cei  $k$  centri ai clusterilor



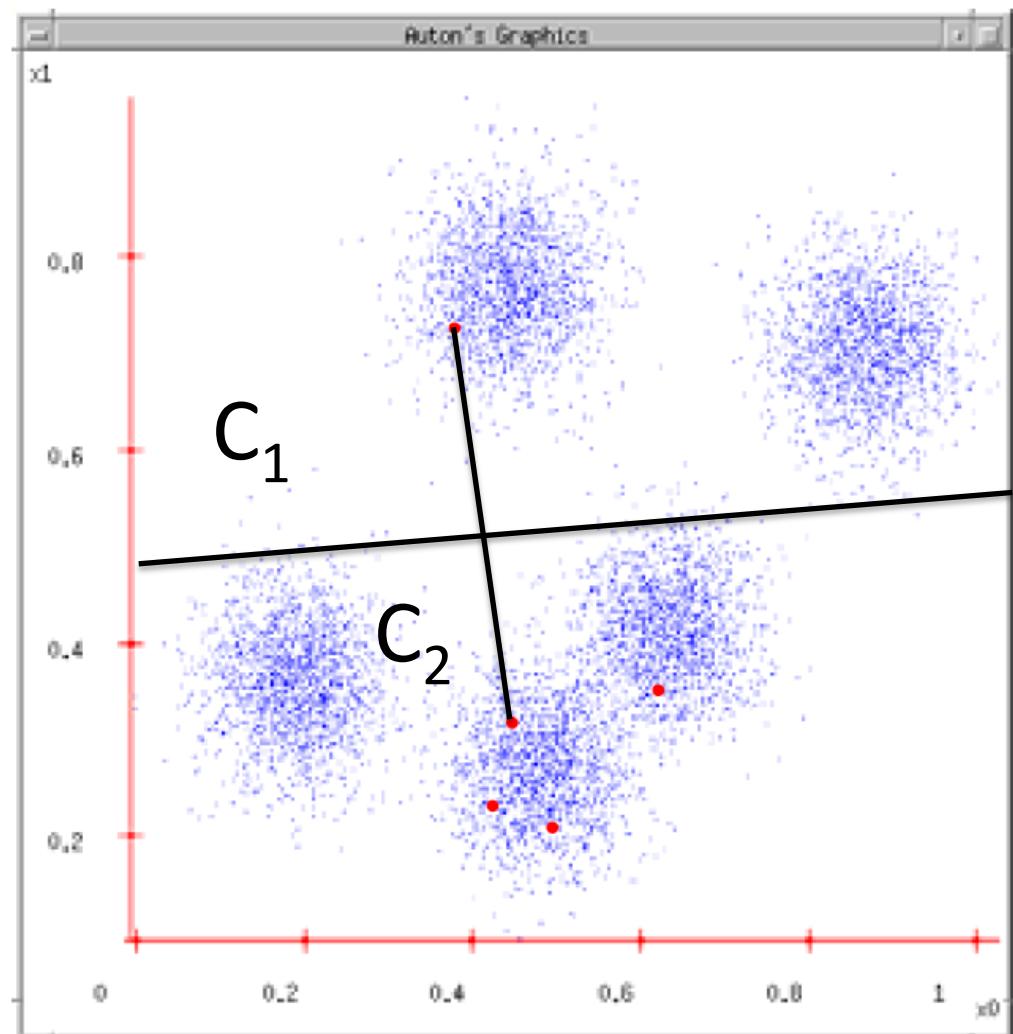
# K-means - exemplu

1. Inițializăm numărul de clusteri ( $k=5$ )
2. Alegem aleator cei  $k$  centri ai clusterilor
3. Determină apartenența fiecărui punct la un cluster



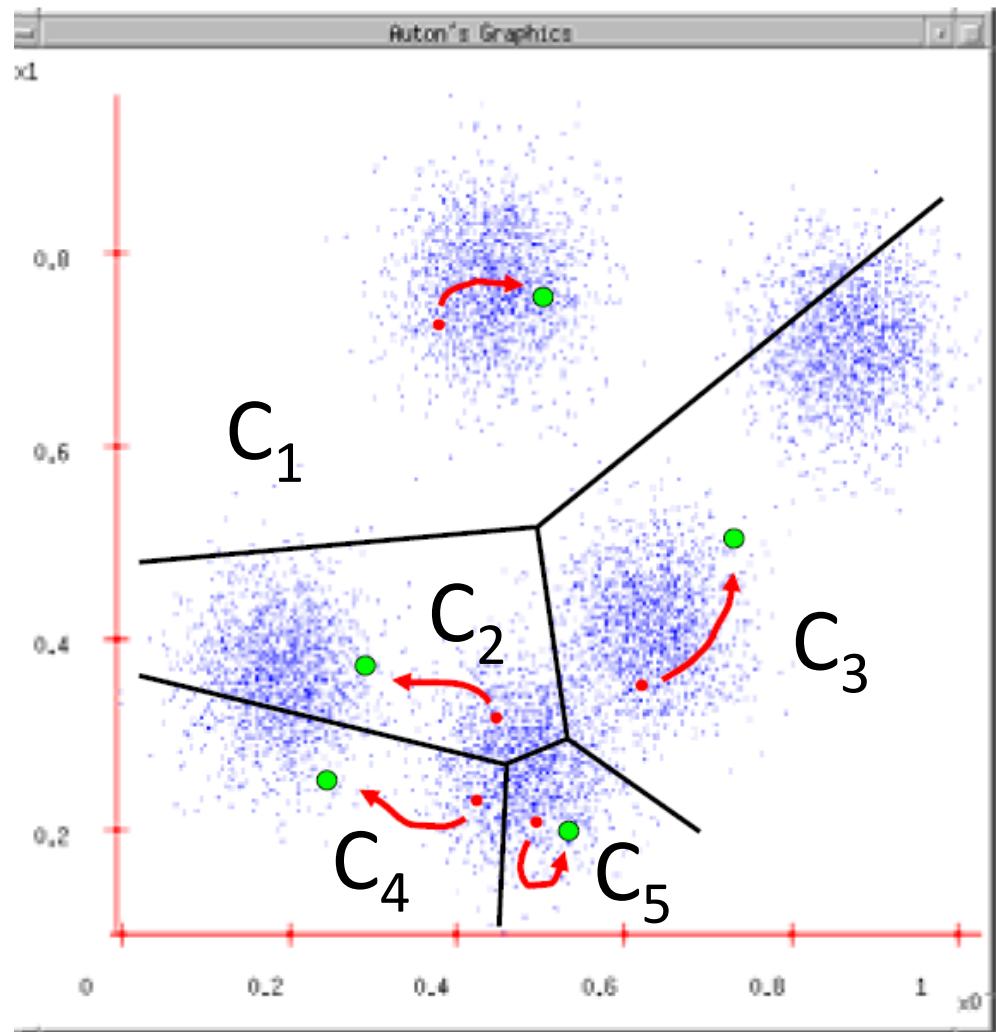
# K-means - exemplu

1. Inițializăm numărul de clusteri ( $k=5$ )
2. Alegem aleator cei  $k$  centri ai clusterilor
3. Determină apartenența fiecărui punct la un cluster



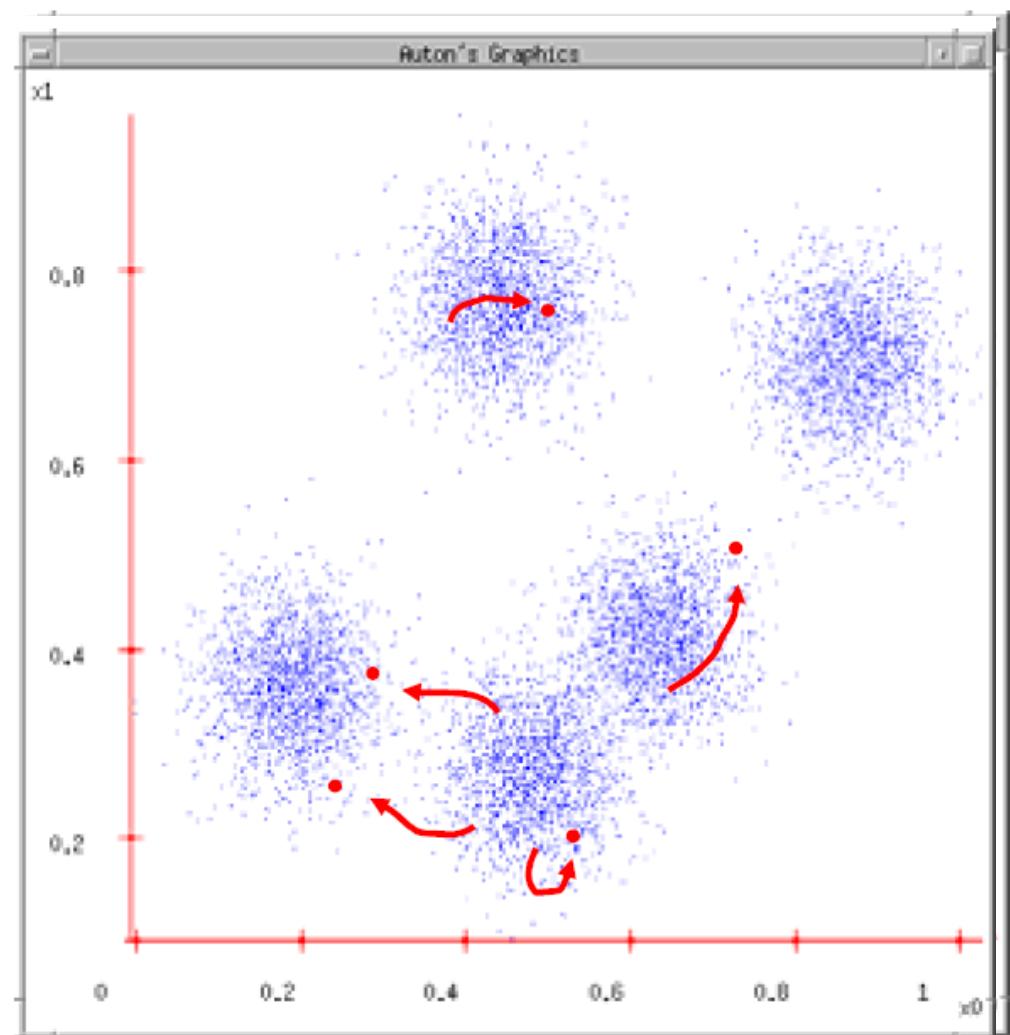
# K-means - exemplu

1. Inițializăm numărul de clusteri ( $k=5$ )
2. Alegem aleator cei  $k$  centri ai clusterilor
3. Determină apartenența fiecărui punct la un cluster
4. Pentru fiecare cluster  $C_i$  determină noul centru



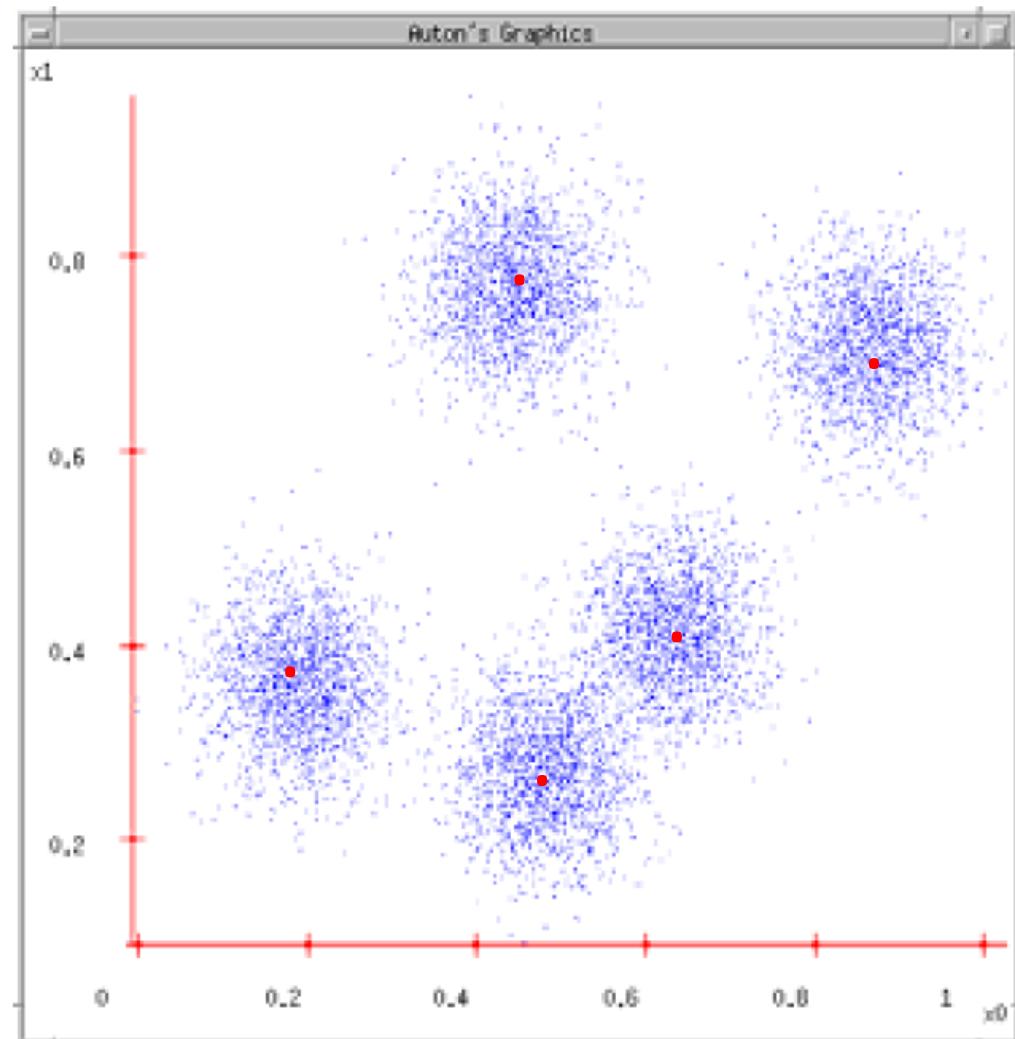
# K-means - exemplu

1. Inițializăm numărul de clusteri ( $k=5$ )
2. Alegem aleator cei  $k$  centri ai clusterilor
3. Determină apartenența fiecărui punct la un cluster
4. Pentru fiecare cluster  $C_i$  determină noul centru
5. Updatează centrul
6. Mergi la 3

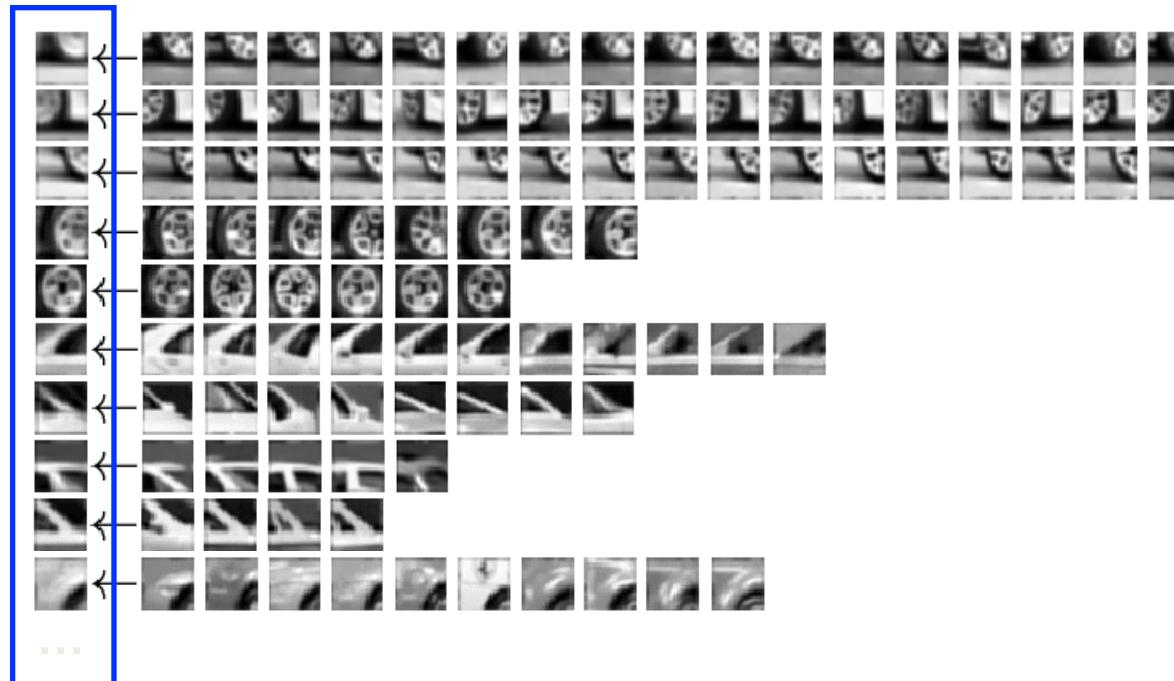
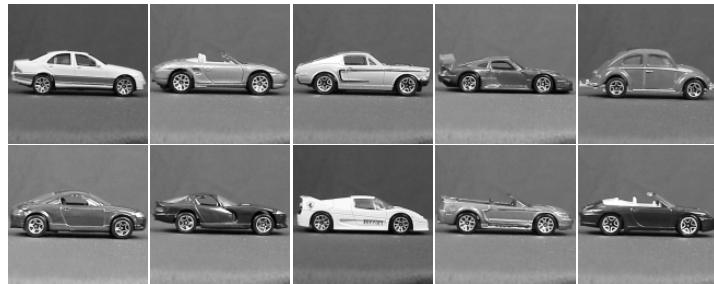


# K-means - exemplu

1. Inițializăm numărul de clusteri ( $k=5$ )
2. Alegem aleator cei  $k$  centri ai clusterilor
3. Determină apartenența fiecărui punct la un cluster
4. Pentru fiecare cluster  $C_i$  determină noul centru
5. Updatează centrul
6. Mergi la 3
7. Soluție



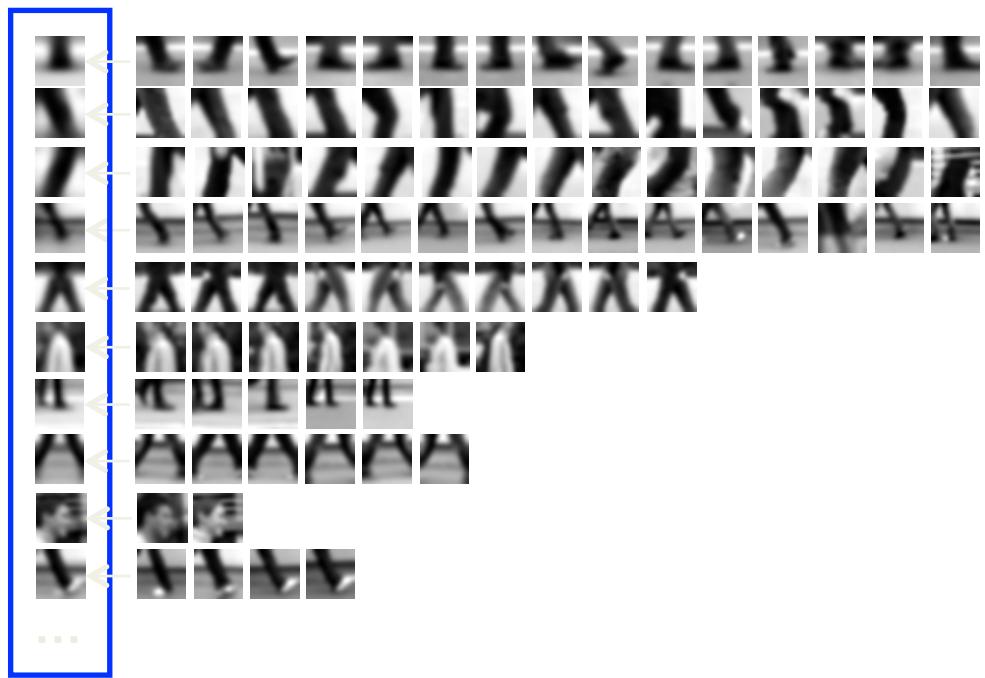
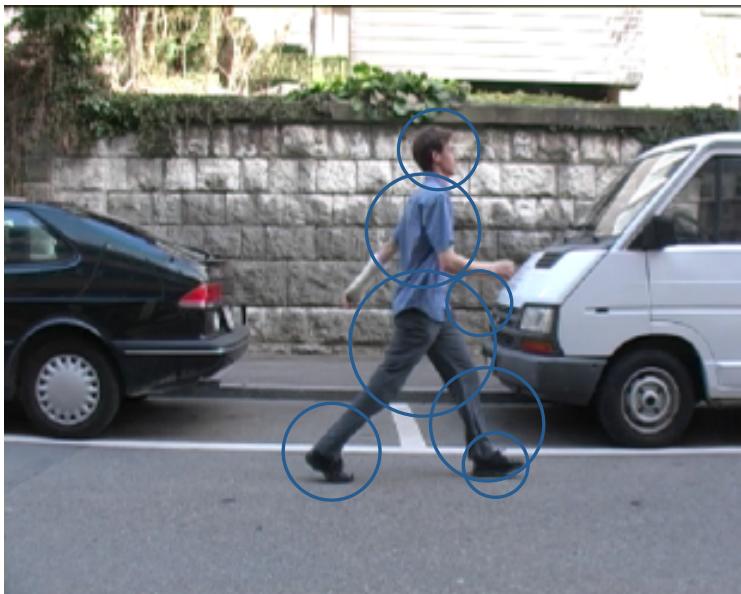
# Vocabular vizual - exemplu



Vocabular vizual

Slide adaptat după B. Leibe

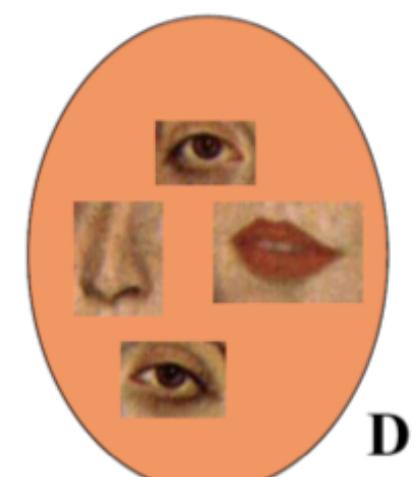
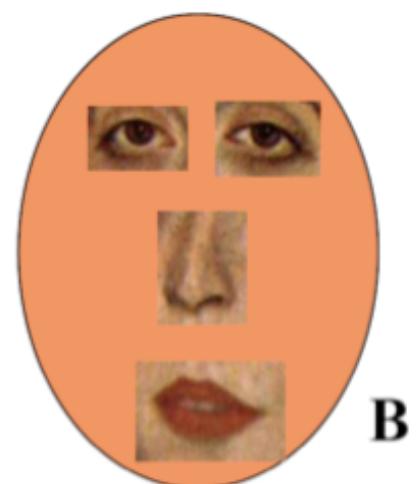
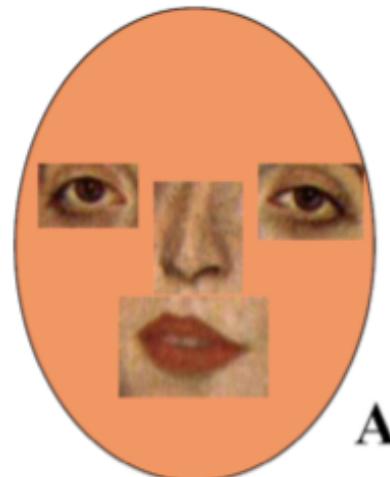
# Vocabular vizual - exemplu



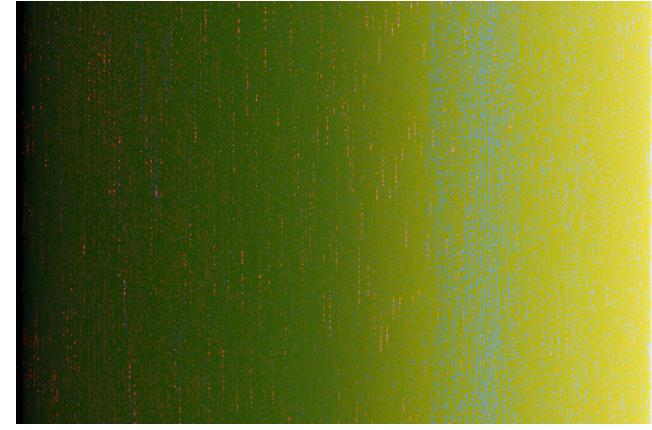
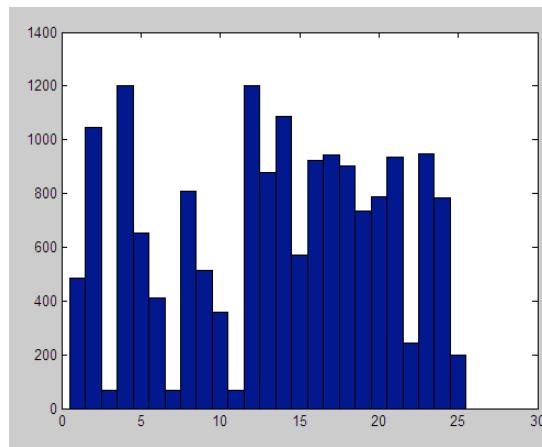
Vocabular vizual

# Limitări ale modelului bag of visual words

- Reprezentare care nu ține cont de poziția în imagine a cuvintelor vizuale
- Avantaje?
  - flexibil în poziționarea spațială a cuvintelor vizuale
- Dezavantaje?
  - mult prea flexibil?



# Poziția în imagine a caracteristicilor



Cele trei imagini au aceeași histogramă de culori.

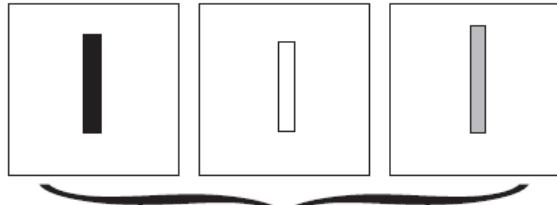
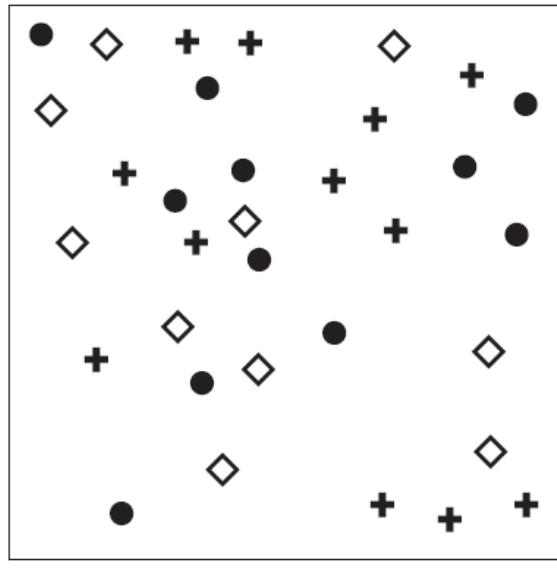
# Piramidă spațială



Calculează histograma pentru fiecare subimagine

# Piramidă spațială

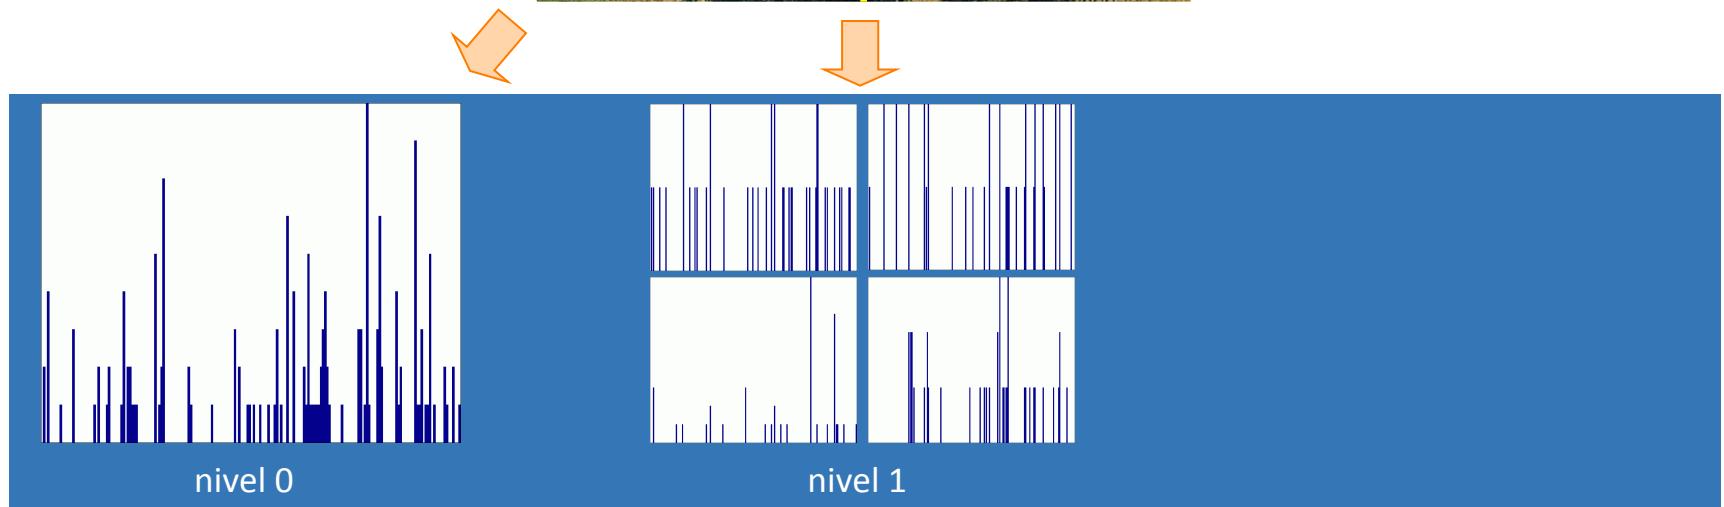
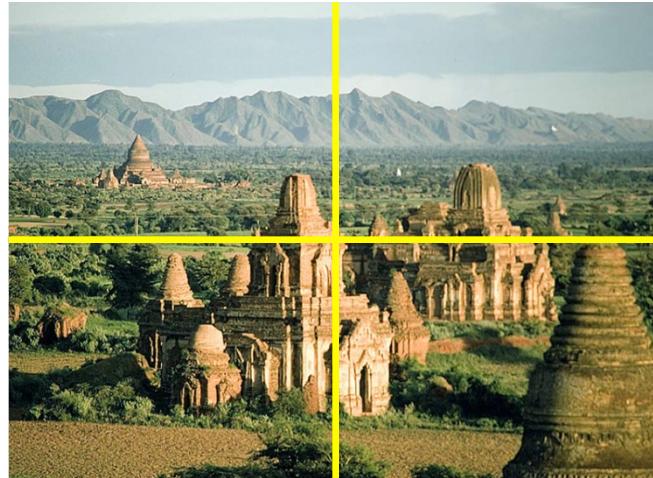
nivelul 0



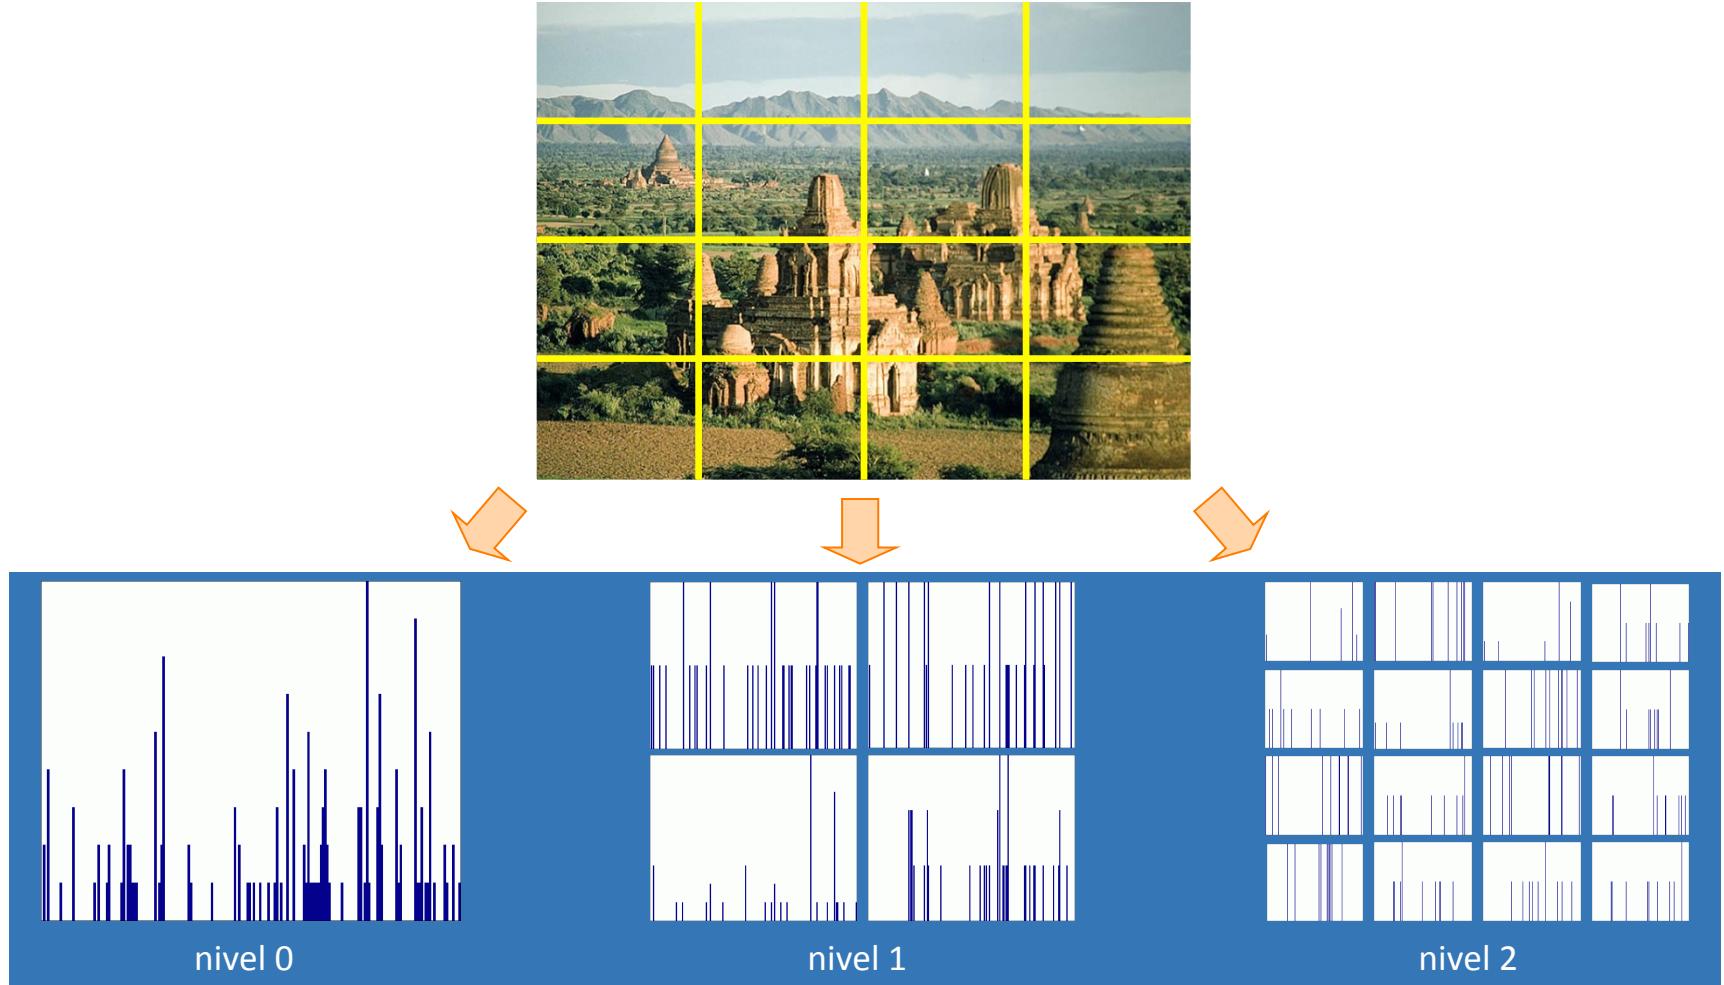
# Piramidă spațială



# Piramidă spațială



# Piramidă spațială



# Clasificarea imaginilor: modelul bag of visual words

## Învățare

1. Extragă caracteristici (descriptori) pentru toate imaginile de învățare
2. Clusterizează descriptorii, centri clusterilor = visual words = ‘cuvinte vizuale’
3. Asignează fiecărui descriptor eticheta/index-ul unui ‘cuvânt vizual’
4. Reprezintă fiecare imagine printr-o histogramă normalizată de ‘cuvinte vizuale’
5. Învață un clasificator pe exemplele de învățare folosind histogramele normalize

## Testare

1. Extragă descriptori din imaginea test, asignează fiecărui descriptor eticheta unui ‘cuvânt vizual’
2. Calculează histograma normalizată de ‘cuvinte vizuale’
3. Calculează eticheta corespunzătoare imaginii test sau un scor folosind clasificatorul învățat.