

Euler (1744):

“Nothing in the world takes place without optimization, and there is no doubt that all aspects of the world that have a rational basis can be explained by optimization”

Notatii

In cadrul cursului vom utiliza urmatoarele notatii:

- Vectori (considerati intotdeauna vector coloana) cu litere mici,

$$\text{i.e. } x \in \mathbb{R}^n, x = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

- Produs scalar in spatiul Euclidian: $\langle x, y \rangle = x^T y = \sum_{i=1}^n x_i y_i$
- Norma Euclidiană standard $\|x\| = \sqrt{\langle x, x \rangle} = \sqrt{x_1^2 + \dots + x_n^2}$
- Multimi cu litere mari: $S, Q, U \subseteq \mathbb{R}^n$ (\mathbb{R}_+^n - orthantul nenegativ, S_+^n - multimea matricelor pozitiv semidefinite)
- Matrice cu litere mari: $A, B, C, H \in \mathbb{R}^{n \times m}$
- Norma spectrală a unei matrici $\|A\| = \sqrt{\lambda_{\max}(A^T A)}$
- Matrice pozitiv definită: $A \succ 0$, și pozitiv semidefinită $A \succeq 0$

Notatii

In cadrul cursului vom utiliza urmatoarele notatii:

- Functii cu litere mici: $f, g, h: \mathbb{R}^n \rightarrow \mathbb{R}$.
- Gradientul, respectiv matricea Hessiana a functiei continuu diferentiabile $f: \mathbb{R}^n \rightarrow \mathbb{R}$: $\nabla f(x) \in \mathbb{R}^n, \nabla^2 f(x) \in \mathbb{R}^{n \times n}$.

Hessiana este matrice simetrica (i.e. in S^n)!

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}, \quad \nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f(x)}{\partial^2 x_1} & \cdots & \frac{\partial^2 f(x)}{\partial x_1 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x)}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f(x)}{\partial^2 x_n} \end{bmatrix},$$

Teorema de medie: fie functia $g: \mathbb{R} \rightarrow \mathbb{R}$ atunci exista $\theta \in [a, b]$ a.i. $g(b) - g(a) = g'(\theta)(b - a) = \int_a^b g'(\tau) d\tau \implies$ pt. $f: \mathbb{R}^n \rightarrow \mathbb{R}$

$$f(y) = f(x) + \langle \nabla f(x + \theta(y - x)), y - x \rangle \quad \theta \in [0, 1]$$

$$f(y) = f(x) + \int_0^1 \langle \nabla f(x + \tau(y - x)), y - x \rangle d\tau$$

Optimizarea matematica


$$f^* = \min_{x \in \mathbb{R}^n} f(x)$$

$$\text{s.l.: } g_1(x) \leq 0, \dots, g_m(x) \leq 0$$

$$h_1(x) = 0, \dots, h_p(x) = 0.$$

- ▶ x variabila de decizie
- ▶ functia obiectiv $f: \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$
- ▶ constrangeri de inegalitate si egalitate $g_i, h_j: \mathbb{R}^n \rightarrow \mathbb{R}$.

Multimea fezabila $X = \{x : g_i(x) \leq 0, h_j(x) = 0 \forall i, j\}$.



$$(NLP) : \min_{x \in X} f(x)$$

In **solutia optima** x^* functia obiectiv ia valoarea cea mai mica (**valoarea optima** f^*) in raport cu toti vectorii ce satisfac constrangerile (restrictiile). Pentru probleme generale avem **minime locale si globale!**

Teorema: Daca functia obiectiv f este **convexa** si multimea fezabila X este **convexa** atunci avem numai minime globale!

Multimi convexe

Multime afina:

$S \subseteq \mathbb{R}^n$ este afina daca $\forall x_1, x_2 \in S$ si $\forall \alpha \in \mathbb{R}$ avem


$$\alpha x_1 + (1 - \alpha)x_2 \in S$$

Exemplu multime afina:

- Multimea solutiilor unui sistem de ecuatii liniare $\{x : Ax = b\}$

Interpretare:

- Orice punct pe dreapta definita de x_1 si x_2 se afla in multime.




Exemplu multime afina

- Multimea solutiilor unui sistem de ecuatii liniare $\{x : Ax = b\}$

$$Ax = b, \quad Ay = b, \quad \alpha \in \mathbb{R}$$

$$A(\alpha x + (1 - \alpha)y) = \alpha Ax + (1 - \alpha)Ay = \alpha b + (1 - \alpha)b = b.$$



Multimi convexe

Multime convexa:

$S \subseteq \mathbb{R}^n$ este convexa daca $\forall x_1, x_2 \in S$ si $\forall \alpha \in [0, 1]$ avem


$$\alpha x_1 + (1 - \alpha)x_2 \in S$$

Interpretare:

- Orice punct pe segmentul de dreapta definit de x_1 si x_2 se afla in multime

Exemplu de multime convexa si neconvexa:

- Orice multime afina este multime convexa (orice combinatie convexa intre x_1 si x_2 se afla in multime)




Multimi convexe

- **Acoperirea convexa:** multime formata din toate combinatiile convexe posibile de puncte ale unei multimi S

$$\text{Conv}(S) = \left\{ \sum_{i \in \mathcal{I}, \mathcal{I} \text{ finit}} \alpha_i x_i : x_i \in S, \sum_{i \in \mathcal{I}} \alpha_i = 1, \alpha_i \geq 0 \right\}$$


- Exemplu de acoperire convexa: pentru o multime formata din trei puncte $S = \{x, y, z\}$ avem

$$\text{Conv}(S) = \left\{ \alpha_1 x + \alpha_2 y + \alpha_3 z : x, y, z \in S, \alpha_i \in [0, 1], \sum_{i=1}^3 \alpha_i = 1 \right\}$$



Multimi convexe

- **Hiperplan si semiplan:** multimi convexe definite astfel
 - ▶ hiperplan: $\{x \in \mathbb{R}^n : a^T x = b\}$, $a \neq 0, a \in \mathbb{R}^n, b \in \mathbb{R}$
 - ▶ semiplan: $\{x \in \mathbb{R}^n : a^T x \geq b\}$ sau $\{x \in \mathbb{R}^n : a^T x \leq b\}$, $a \neq 0, a \in \mathbb{R}^n, b \in \mathbb{R}$
- Exemplu de hiperplan si semiplanele aferente:




$$\{x \in \mathbb{R}^2 : x_1 + 2x_2 = 1\} \Rightarrow a = [1 \ 2]^T \text{ \& } b = 1$$

Multimi convexe

Poliedru:

- multime convexa definita de p hiperplane sau m semiplane $\left\{x \in \mathbb{R}^n : a_i^T x = b_i \forall i = 1, \dots, p, \quad c_j^T x \leq d_j \forall j = 1, \dots, m\right\}$ sau mai compact $\{x : Ax = b, \quad Cx \leq d\}$
- poate fi reprezentat si prin varfuri v_i si raze afine r_j :
 $\left\{\sum_{i=1}^{n_1} \alpha_i v_i + \sum_{j=1}^{n_2} \beta_j r_j : \sum_{i=1}^{n_1} \alpha_i = 1, \alpha_i \geq 0, \beta_j \geq 0 \quad \forall i, j\right\}$
- exemplu de poliedru nemarginit: $\mathbb{R}_+^2 = \{x \in \mathbb{R}^2 : x_1, x_2 \geq 0\}$



• Politop:

poliedru marginit, e.g simplex : $\{x \in \mathbb{R}^3 : x_1 + x_2 + x_3 \leq 1, x \geq 0\}$

Multimi convexe

Bila:

multime convexa definita de o norma $\|\cdot\|$, un centru x_c si o raza r :

$$B(x_c, r) = \{x \in \mathbb{R}^n : \|x - x_c\| \leq r\}$$


Exemplu, bila Euclidiană de centru zero si raza 1 in \mathbb{R}^2 :

$$B_2(0, 1) = \left\{x \in \mathbb{R}^2 : \sqrt{x_1^2 + x_2^2} \leq 1\right\}$$

Elipsoid:

multimea convexa definita de un centru x_c si o matrice $Q \succ 0$

$$\{x \in \mathbb{R}^n : (x - x_c)^T Q^{-1}(x - x_c) \leq 1\}$$



Multimi convexe

Con:

K este con daca $\forall x \in K$ si $\forall \alpha \geq 0$ avem $\alpha x \in K$


Con convex:

K este con si multime convexe

Exemplu con Lorentz: $\mathcal{L}^n = \{[x^T \ t]^T \in \mathbb{R}^{n+1} : \|x\| \leq t\}$

Exemplu conul Lorentz pentru $n = 2$:


$$\mathcal{L}^2 = \left\{ [x_1 \ x_2 \ t]^T \in \mathbb{R}^3 : \sqrt{x_1^2 + x_2^2} \leq t \right\}$$



Multimi convexe

Acoperire conica:

$$\text{Con}(S) = \left\{ \sum_{i \in \mathcal{I}, \mathcal{I} \text{ finit}} \alpha_i x_i : x_i \in S, \alpha_i \geq 0 \right\}$$



- **Conul dual:** $K^* = \{y : \langle x, y \rangle \geq 0 \ \forall x \in K\}$
- Daca $K = K^*$ atunci K este *con auto-dual*

Exemple conuri:

- Multimea \mathbb{R}^n este un con, iar conul sau dual este $(\mathbb{R}^n)^* = \{0\}$.
- $\mathbb{R}_+^n = \{x \in \mathbb{R}^n : x \geq 0\}$ se numeste *conul orthant* si este auto-dual in raport cu produsul scalar uzual $\langle x, y \rangle = x^T y$, i.e. $(\mathbb{R}_+^n)^* = \mathbb{R}_+^n$.


Multimi convexe

Con pozitiv semidefinit: multime formata din matrice pozitiv semidefinite, notatie $S_+^n = \{X \in \mathbb{R}^{n \times n} : X = X^T, X \succeq 0\}$

$$X \in S_+^n \iff x^T X x \geq 0 \quad \forall x \in \mathbb{R}^n$$

$$X, Y \in S_+^n, \alpha \in [0, 1] \Rightarrow x^T (\alpha X + (1-\alpha)Y) x = \alpha x^T X x + (1-\alpha) x^T Y x \geq 0$$

- Exemplu: $\begin{bmatrix} x & y \\ y & z \end{bmatrix} \in S_+^2 \iff x, z \geq 0 \text{ \& } xz - y^2 \geq 0$




- Observatie: conul S_+^n este auto-dual, i.e. $S_+^n = (S_+^n)^*$ in raport cu produsul scalar $\langle X, Y \rangle = \text{Trace}(XY)$

Multimi convexe

Operatii ce conserva convexitatea:

- ▶ *intersectia*: fiind data o familie de multimi convexe $\{S_i\}_{i \in I}$, atunci $\bigcap_{i \in I} S_i$ este o multime convexa
- ▶ *suma si scalarea*: fiind date doua multimi S_1, S_2 , atunci $S_1 + S_2 = \{x + y : x \in S_1, y \in S_2\}$ este o multime convexa. Mai mult, $\alpha S = \{\alpha x : x \in S\}$ este convexa daca S este convexa si $\alpha \in \mathbb{R}$
- ▶ fie o functie afina $f(x) = Ax + b$ si S multime convexa, atunci $f(S) = \{f(x) : x \in S\}$, este convexa. Similar, preimaginea: $f^{-1}(S) = \{x : f(x) \in S\}$ este si ea convexa

Exemplu intersectie multimi convexe:



Multimi convexe

Inegalitate matriceala liniara (LMI): Consideram o functie $G : \mathbb{R}^m \rightarrow S_+^n$, $G(x) = A_0 + \sum_{i=1}^m x_i A_i$, unde x_i sunt componentele unui vector $x \in \mathbb{R}^m$, iar matricele $A_0, \dots, A_m \in S^n$ sunt simetrice.

Expresia $G(x) \succeq 0$ se numeste *inegalitate matriceala liniara*.

Multimea $\{x \in \mathbb{R}^m : G(x) \succeq 0\}$ este o multime convexa, fiind o preimagine a lui S_+^n prin $G(x)$.

Exemplu: avem inegalitatea $\|A\| \leq \gamma$ cu $\gamma > 0$ si variabila A . Inegalitatea este echivalenta cu $\lambda_{\max}(A^T A) \leq \gamma^2$ sau:


$$\gamma^2 I - A^T A \succeq 0$$

Prin complementul Schur, aceasta poate fi scrisa ca un LMI:


$$\begin{bmatrix} I & A \\ A^T & \gamma^2 I \end{bmatrix} \succeq 0$$

Multimi convexe

Teorema de separare prin hiperplane: Fie S_1 si S_2 convexe iar $S_1 \cap S_2 = \emptyset$. Atunci, exista un hiperplan $a^T x = b$, cu $a \neq 0$, $a \in \mathbb{R}^n$ si $b \in \mathbb{R}$ astfel incat $a^T x \geq b$ oricare ar fi $x \in S_1$ si $a^T x \leq b$ oricare ar fi $x \in S_2$.



Teorema de suport cu un hiperplan: Fie S convexa si $x_0 \in \text{bd}(S) = \text{cl}(S) - \text{int}(S)$. Atunci, exista $a \neq 0$, $a \in \mathbb{R}^n$ astfel incât $a^T x \geq a^T x_0$ oricare ar fi $x \in S$.



Funcții convexe

Domeniu efectiv: notăm $\bar{\mathbb{R}} = \mathbb{R} \cup \{+\infty\}$. O funcție scalară $f : \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$ are *domeniul efectiv* descris de mulțimea:

$$\text{dom} f = \{x \in \mathbb{R}^n : f(x) < +\infty\}.$$

Funcție convexă : O funcție f este *convexă* dacă $\text{dom} f$ este o *mulțime convexă* și are loc inegalitatea:

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2)$$

pentru orice $x_1, x_2 \in \text{dom} f$ și $\alpha \in [0, 1]$

- Dacă în plus

$$f(\alpha x_1 + (1 - \alpha)x_2) < \alpha f(x_1) + (1 - \alpha)f(x_2),$$

$\forall x_1 \neq x_2 \in \text{dom} f$ și $\alpha \in (0, 1)$, atunci f funcție *strict convexă*


- Dacă există o constantă $\sigma > 0$ astfel încât

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2) - \frac{\sigma}{2} \alpha(1 - \alpha) \|x_1 - x_2\|^2,$$

$\forall x_1, x_2 \in \text{dom} f$ și $\alpha \in [0, 1]$, atunci f funcție *tare convexă*

Functii convexe

- Exemplu de functie convexa $f : \mathbb{R} \rightarrow \mathbb{R}$, $f(x) = x^2$



- Alte exemple de functii convexe
 - ▶ Functia definita de orice norma este convexa, i.e. $f(x) = \|x\|$ este convexa pe \mathbb{R}^n (folositi definitia).
 - ▶ Functia $f(x) = -\log(x)$ este convexa pe \mathbb{R}_{++} .
 - ▶ Functia $f(x) = \max\{x_1, \dots, x_n\}$ este convexa pe \mathbb{R}^n .
 - ▶ Functia $f(X) = -\log \det(X)$ este convexa pe spatiul matricelor pozitiv definite S_{++}^n (difical de aratat!).

- **Inegalitatea lui Jensen** este o generalizare a convexitatii: f este convexa daca si numai daca $\text{dom} f$ este convexa si

$$f\left(\sum_{i=1}^p \alpha_i x_i\right) \leq \sum_{i=1}^p \alpha_i f(x_i)$$

pentru orice $x_i \in \text{dom} f$ si $\sum_{i=1}^p \alpha_i = 1$ cu $\alpha_i \in [0, 1]$

- **Functie concava:** o functie $f(x)$ este *concava* daca $-f(x)$ este convexa (e.g. functia $f(x) = \log(x)$ este concava pe \mathbb{R}_{++})
- **Remarca:** o functie $f : \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$ este convexa daca si numai daca restrictia domeniului sau la o dreapta (care intersecteaza domeniul) este, de asemenea, convexa. Cu alte cuvinte, f este convexa daca si numai daca oricare ar fi $x \in \text{dom} f$ si o directie $d \in \mathbb{R}^n$, functia scalara $g(t) = f(x + td)$ este convexa pe domeniul $\{t \in \mathbb{R} : x + td \in \text{dom} f\}$.

Funcții convexe

- Exemplu restricție domeniu la o dreaptă: fie funcția

$$f(X) = -\log \det X$$

având domeniul de definiție $\text{dom} f = S_{++}^n$

Avem pentru orice $X \in S_{++}^n$ și $D \in S^n$:

$$\begin{aligned} g(t) &= -\log \det(X + tD) = -\log \det X - \log \det \left(I + tX^{-\frac{1}{2}}DX^{-\frac{1}{2}} \right) \\ &= -\log \det X - \sum_{i=1}^n \log(1 + t\lambda_i), \end{aligned}$$

unde λ_i sunt valorile proprii ale lui $X^{-\frac{1}{2}}DX^{-\frac{1}{2}}$. Din moment ce $-\log(t)$ este funcție convexă, rezultă că $g(t)$ este funcție convexă și implicit $f(X)$ este convexă.

- Reamintim că pentru o matrice $X \in S^n$ din DVS avem:
 $X = U\Sigma U^T$, unde U ortogonală, i.e. $U^T U = I_n$. Atunci definim $\Sigma^{1/2} = \text{diag}(\sigma_i^{1/2})$ și

$$X^{1/2} = U\Sigma^{1/2}U^T$$

Funcții convexe

Multimi subnivel și epigraful funcției.

- **Convexitate multimii subnivel**


Pentru un scalar $c \in \mathbb{R}$, mulțimea subnivel $\{x \in \text{dom} f : f(x) \leq c\}$ a unei funcții convexe $f : \mathbb{R}^n \rightarrow \mathbb{R}$ este convexă.

- **Epigraful funcției**

Fie $f : \mathbb{R}^n \rightarrow \mathbb{R}$, atunci *epigraful* (numit și supragrafic) funcției este definit ca fiind următoarea mulțime:

$$\text{epi} f = \left\{ [x^T \ t]^T \in \mathbb{R}^{n+1} : x \in \text{dom} f, \ f(x) \leq t \right\}.$$

- **Rezultat:** o funcție $f : \mathbb{R}^n \rightarrow \mathbb{R}$ este convexă dacă și numai dacă epigraful său este o mulțime convexă.




Funcții convexe

Condiții de convexitate pentru funcții continue diferentiabile.

Condiții de ordinul I: dacă $f : \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$ este continuu diferentiabilă și $\text{dom} f$ este o mulțime convexă. Atunci, f este convexă dacă și numai dacă:

$$f(x_2) \geq f(x_1) + \nabla f(x_1)^T (x_2 - x_1) \quad \forall x_1, x_2 \in \text{dom} f.$$




Functii convexe

Conditii de convexitate pentru functii continuu diferentiabile.

Conditii de ordinul II: daca $f : \mathbb{R}^n \rightarrow \bar{\mathbb{R}}$ este de doua ori continuu diferentiabila si $\text{dom} f$ este multime convexa. Atunci f este convexa daca si numai daca pentru orice $x \in \text{dom} f$ matricea Hessiana este pozitiv semidefinita, adica:

$$\nabla^2 f(x) \succeq 0 \quad \forall x \in \text{dom} f.$$

$$\nabla^2 f(x) \succeq 0.$$



Funcții convexe

Exemplu condiții de ordin I și II:

- ▶ Funcția $f(x) = -\log(x)$ este convexă pe $\mathbb{R}_{++} = \{x \in \mathbb{R} : x > 0\}$ deoarece $\nabla^2 f(x) = \frac{1}{x^2} > 0$ oricând ar fi $x > 0$.
- ▶ Funcția patratică $f(x) = \frac{1}{2}x^T Qx + q^T x + r$ este convexă pe \mathbb{R}^n dacă și numai dacă $Q \succeq 0$, deoarece pentru orice $x \in \mathbb{R}^n$ Hessiana $\nabla^2 f(x) = Q$ (dacă Q este simetrică).
- ▶ Se observă că orice funcție afină este convexă și, de asemenea, concavă.
- ▶ Condiția $\text{dom} f$ multime convexe impusă în toate teoremele precedente este necesară. De exemplu, considerăm funcția $f(x) = 1/x^2$ având $\text{dom} f = \mathbb{R} \setminus \{0\}$ multime neconvexă. Observăm că Hessiana $\nabla^2 f(x) = \frac{6}{x^4} \succeq 0$, dar funcția nu este convexă.

Funcții convexe

Operații ce conservă convexitatea funcțiilor:

- ▶ Dacă f_1 și f_2 sunt funcții convexe și $\alpha_1, \alpha_2 \geq 0$ atunci $\alpha_1 f_1 + \alpha_2 f_2$ este de asemenea convexă.
- ▶ Dacă f este convexă atunci $g(x) = f(Ax + b)$ (adică compunerea unei funcții convexe cu o funcție afină) este de asemenea convexă:

$$\frac{1}{2} \|Ax - b\|^2 = \frac{1}{2} x^T A^T A x - b^T A x - \frac{1}{2} b^T b$$

- ▶ Fie $f : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$ astfel încât funcția $f(\cdot, y)$ este convexă pentru orice $y \in S \subseteq \mathbb{R}^m$. Atunci următoarea funcție este convexă:

$$g(x) = \sup_{y \in S} f(x, y).$$

- ▶ Compunerea cu o funcție convexă monotona unidimensională: dacă $f : \mathbb{R}^n \rightarrow \mathbb{R}$ este convexă și $g : \mathbb{R} \rightarrow \mathbb{R}$ este convexă și monoton crescătoare, atunci funcția $g \circ f : \mathbb{R}^n \rightarrow \mathbb{R}$ este de asemenea convexă.

Funcții tari convexe

- Dacă $\text{dom} f$ convex și există o constantă $\sigma > 0$ a.i.

$$f(\alpha x_1 + (1 - \alpha)x_2) \leq \alpha f(x_1) + (1 - \alpha)f(x_2) - \frac{\sigma}{2}\alpha(1 - \alpha)\|x_1 - x_2\|^2,$$

$\forall x_1, x_2 \in \text{dom} f$ și $\alpha \in [0, 1]$, atunci f funcție *tare convexă*

Lema 1: Fie o funcție continuu diferentiabilă f (i.e. $f \in \mathcal{C}^1$), atunci relația de convexitate tare este echivalentă cu:

$$f(y) \geq f(x) + \langle \nabla f(x), y - x \rangle + \frac{\sigma}{2}\|x - y\|^2 \quad \forall x, y$$


Lema 2: În cazul funcțiilor de două ori diferentiabile (i.e. $f \in \mathcal{C}^2$), relația de convexitate tare este echivalentă cu:

$$\nabla^2 f(x) \succeq \sigma I_n \quad \forall x \in \text{dom} f$$

Convexitate tare

- Daca f este tare convexa atunci:

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) + \frac{\sigma}{2} \|y - x\|^2$$



- Daca $\text{dom } f = \mathbb{R}^n$, atunci f are un punct de minim global unic:

$$\frac{\sigma}{2} \|x - x^*\|^2 \leq f(x) - f^* \leq \frac{1}{2\sigma} \|\nabla f(x)\|^2$$

- Mai mult functia

$$f(x) - \frac{\sigma}{2} \|x\|^2 \text{ este convexa}$$

Convexitate tare - exemplu

Fie $f : \mathbb{R}^n \rightarrow \mathbb{R}$ o functie patratica, i.e.

$$f(x) = \frac{1}{2}x^T Qx + \langle q, x \rangle.$$

Observam expresia Hessienei $\nabla^2 f(x) = Q$

In concluzie, pentru functiile patractice, cu $Q \succ 0$, constanta de convexitate tare este:

$$\sigma = \lambda_{\min}(Q)$$

Exemplu: daca $Q = \text{diag}([q_1 \ q_2])$, cu $q_1 > q_2 > 0$, atunci constanta de convexitate tare este $\sigma = q_2$.

Funcții conjugate

Fie funcția $f : \mathbb{R}^n \rightarrow \mathbb{R}$, atunci funcția *conjugată*, notată cu f^* , se definește prin

$$f^*(y) = \max_{x \in \text{dom } f} \underbrace{y^T x - f(x)}_{F(x,y)}.$$

Funcția f^* este convexă indiferent de proprietățile lui f .

Exemple:

- Pentru funcția patratică convexă $f(x) = \frac{1}{2}x^T Qx$, unde $Q \succ 0$, funcția conjugată are expresia:

$$f^*(y) = \frac{1}{2}y^T Q^{-1}y.$$

- Pentru funcția $f(x) = -\log x$, conjugata sa este dată de expresia:

$$f^*(y) = \sup_{x>0} (xy + \log x) = \begin{cases} -1 - \log(-y) & \text{dacă } y < 0 \\ \infty & \text{altfel.} \end{cases}$$