

Rezolvări examen Tehnici de optimizare - 2018

Bogdan Macovei

Mai 2019

1 Numarul 1

1.1 Problema 1

Fie $f : R^+ \times R \rightarrow R$ cu $f(x) = \max(1 - \sqrt{x_1}, |x_2|)$.

a) Este f convexa?

b) Determinați punctele de optim ale lui f și natura lor.

Soluție a. Determinăm convexitatea fiecărei funcții care apare în definiția lui f :

$g(x) = 1 - \sqrt{x_1}$ este convexă dacă și numai dacă $g''(x) \geq 0 \ \forall x \in [0, \infty)$ (conform condițiilor de convexitate de ordinul II, susținute de faptul că $g \in C^2(R)$).

$$g''(x) = (g'(x))' = \left(-\frac{1}{2\sqrt{x}} \right)' = \frac{1}{4x\sqrt{x}} > 0 \ \forall x \in (0, \infty)$$

deci funcția este convexă.

Considerăm acum funcția modul, $|\cdot|$. Ea este convexă, conform definiției, dacă

$$\forall x, y \in R, \quad |\alpha x + (1 - \alpha)y| \leq \alpha|x| + (1 - \alpha)|y|$$

egalitate care este adevărată tocmai din inegalitatea modulului, ceea ce înseamnă că funcția modul este o funcție convexă, rezultând astfel că f este o funcție convexă.

Soluție b. Pentru a determina punctele de optim, trebuie să determinăm, mai întâi, punctele staționare, adică punctele astfel încât

$$\nabla f(x) = 0$$

Observăm, însă, că

$$\nabla f(x) = \begin{cases} [-\frac{1}{2\sqrt{x_1}}; 0]^T & x_2 \in [1 - \sqrt{x_1}, \sqrt{x_1} - 1] \\ [0; \pm 1]^T & \text{altfel} \end{cases}$$

Adică $\nabla f(x) \neq 0 \ \forall x$, deci f nu are puncte de optim.

1.2 Problema 2

Fie $f : R \times R \rightarrow R$ cu $f(x) = x_1^3 + (1 + x_2)^2$.

a) Aplicati Metoda Gradient cu pas ideal pentru punctul de inceput $z_0 = [1 \ 1]^T$,

b) Aplicati Metoda Newton cu pasul $\alpha = 1$, pornind de la acelasi z_0 ca la punctul (a).

Solutie. Calculam gradientul si Hessiana functiei f :

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 3x_1^2 \\ 2(1 + x_2) \end{bmatrix}$$

$$\nabla^2 f(x) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} \end{bmatrix} = \begin{bmatrix} 6x_1 & 0 \\ 0 & 2 \end{bmatrix}$$

Gradient Descent. Aplicam iteratia $z_1 = z_0 - \alpha_0 \nabla f(z_0)$ unde pasul ideal este specificat simbolic:

$$\alpha_0 = \arg \max_{\alpha \geq 0} f(z_0 + \alpha \nabla f(z_0))$$

Se obtine

$$z_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \alpha_0 \begin{bmatrix} 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 1 - 3\alpha_0 \\ 1 - 4\alpha_0 \end{bmatrix}$$

Metoda Newton. Aplicam iteratia $z_1 = z_0 - \alpha(\nabla^2 f(z_0))^{-1} \nabla f(z_0)$. Avem ca $\nabla^2 f(x) = (\nabla^2 f(x))^T$ si $(\nabla^2 f(x))^*$ dat de:

$$(\nabla^2 f(x))^* = \begin{bmatrix} 2 & 0 \\ 0 & 6 \end{bmatrix}$$

astfel ca inversa Hessiane va fi

$$(\nabla^2 f(x))^{-1} = \frac{1}{6} \begin{bmatrix} 1 & 0 \\ 0 & 6 \end{bmatrix}$$

Pasul in metoda Newton:

$$z_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix} - \frac{1}{6} \begin{bmatrix} 1 & 0 \\ 0 & 6 \end{bmatrix} \begin{bmatrix} 3 \\ 4 \end{bmatrix} = \begin{bmatrix} 0.5 \\ -1 \end{bmatrix}$$

1.3 Problema 3

Fie $\exp^* : R \rightarrow R$ cu $\exp^*(x) = \min_{z \in R} xz - e^z$ si problema de optimizare

$$(P) : \min_{x \in R^2} \{ \exp^*(x_1) + \exp^*(x_2) \mid x_1 + 2 \cdot x_2 \leq 1 \}$$

- a) este P convexa?
- b) Determinati punctele KKT si natura lor.

Solutie a. Analizam functia $\exp^*(x)$. Fie $f(x, z) := xz - e^z$, atunci:

$$\frac{\partial f}{\partial z} = x - e^z$$

Impunand conditia $\frac{\partial f}{\partial z} = 0$ (pentru a obtine punct de extrem) avem ca $x = e^z$, deci $z = \ln(x)$, astfel ca $\exp^*(x)$ are forma explicita:

$$\exp^*(x) = x \ln(x) - x = x(\ln(x) - 1)$$

care este o functie convexa, deoarece

$$\exp^{*'}(x) = \ln(x) \Rightarrow \exp^{*''}(x) = \frac{1}{x}$$

iar cum domeniul nu poate fi decat $(0, \infty)$ (din cauza logaritmului natural), inseamna ca

$$\exp^{*''}(x) \geq 0 \quad \forall x \in (0, \infty)$$

deci functia \exp^* este o functie convexa.

Daca $\exp^*(x)$ convexa, atunci $\exp^*(x_1) + \exp^*(x_2)$ este convexa, $\forall x \in (0, \infty)$; relatia $x_1 + 2 \cdot x_2 \leq 1$ defineste un semiplan (care este multime convexa), deci problema de optimizare P este o problema de optimizare convexa.

Solutie b. Pentru a determina punctele KKT , vom formula problema de optimizare constransa:

$$\begin{aligned} \min_{x \in R_+^2} \quad & \exp^*(x_1) + \exp^*(x_2) \\ \text{s.l.} \quad & x_1 + 2 \cdot x_2 - 1 \leq 0 \end{aligned}$$

Notand $f(x) = \exp^*(x_1) + \exp^*(x_2)$ si $g(x) = x_1 + 2 \cdot x_2 - 1$, avem ca Lagrangianul functiei este dat de formula:

$$\mathcal{L}(x, \lambda) = f(x) + \lambda g(x) = \exp^*(x_1) + \exp^*(x_2) + \lambda(x_1 + 2 \cdot x_2 - 1)$$

adica, in forma explicita (inlocuind \exp^* cu forma obtinuta la subpunctul anterior):

$$\mathcal{L}(x, \lambda) = x_1(\ln(x_1) - 1) + x_2(\ln(x_2) - 1) + \lambda(x_1 + 2x_2 - 1)$$

Pentru a scrie sistemul KKT , mai avem nevoie de doua informatii: gradientul lui f si gradientul lui g :

$$\nabla f(x) = \begin{bmatrix} \ln(x_1) \\ \ln(x_2) \end{bmatrix}; \nabla g(x) = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$$

Obtinem sistemul:

$$\begin{cases} \begin{bmatrix} \ln(x_1) \\ \ln(x_2) \end{bmatrix} + \begin{bmatrix} 1 \\ 2 \end{bmatrix} \lambda = 0 \\ \lambda x_1 + 2\lambda x_2 - \lambda = 0 \\ x_1 + 2x_2 - 1 \leq 0 \\ \lambda \geq 0 \end{cases} \iff \begin{cases} \ln(x_1) + \lambda = 0 \\ \ln(x_2) + 2\lambda = 0 \\ \lambda(x_1 + 2x_2 - 1) = 0 \\ \lambda \geq 0 \\ x_1 + 2x_2 - 1 \leq 0 \end{cases}$$

Daca avem ca $\lambda = 0$, atunci $x_1 = x_2 = 1$, contradictie cu $x_1 + 2x_2 \leq 1$ ($3 \not\leq 1$), deci $\lambda > 0$. Daca $\lambda > 0$, atunci din a treia ecuatie a sistemului avem ca $x_1 + 2x_2 - 1 = 0 \Rightarrow x_1 = 1 - 2x_2$.

Din prima si din a doua ecuatie obtinem ca $x_1 = e^{-\lambda}$, respectiv $x_2 = e^{-2\lambda}$, si folosind informatia de mai sus, cum ca $x_1 = 1 - 2x_2$, avem:

$$e^{-\lambda} = 1 - 2e^{-2\lambda} \Rightarrow 2e^{-2\lambda} + e^{-\lambda} - 1 = 0$$

Notam $e^{-\lambda} = y$ si obtinem ecuatie de gradul al doilea $2y^2 + y - 1 = 0$, cu solutiile $y_1 = -1$, $y_2 = 0.5$. Este evident ca $y_1 = -1 < 0$ nu poate fi solutia unei ecuatiei exponentiale, deci

$$e^{-\lambda} = 0.5 \Rightarrow -\lambda = -\ln(2) \Rightarrow \lambda = \ln(2)$$

Se obtin, astfel, x_1 si x_2 , iar punctul $x = [x_1 \ x_2]^T$ este punct de minim global.

2 Numarul 2

2.1 Problema 1

Fie $f : R^+ \rightarrow R$ cu $f(x) = \max_{z \in R} zx - e^z$.

- a) Este multimea $X = \{x \in R^+ \times R^+ \mid f(x_1) + f(x_2) \leq 0\}$ convexa?
b) Care este solutia problemei de optimizare $(P) := \min_{x \in X} \{\|x\|_2^2\}$?

Solutie a. Functia este cea de la problema 3, Numarul 1, forma ei explicita fiind $f(x) = x(\ln(x) - 1)$. (obs: la numarul 1 se cerea minimul functiei, dar este doar greseala de scriere, tot maximul era corect sa fie cerut, intrucat functia $zx - e^z$ este concava).

Multimea X este convexa deoarece $f(x)$ este convexa $\Rightarrow f(x_1) + f(x_2)$ convexa, iar constrangerea de ingalitate formeaza un semiplan, care este multime convexa conform teoriei.

Solutie b. Explicitam multimea X :

$$X = \{x \in R_+^2 \mid x_1(\ln(x_1) - 1) + x_2(\ln(x_2) - 1) \leq 0\}$$

Se cere $x^* := \min_{x \in X} \|x\|_2^2$. Definitia normei este $\|x\|_2^2 = x_1^2 + x_2^2$, deci problema de optimizare se va scrie

$$\begin{aligned} \min_{x \in X} x_1^2 + x_2^2 \\ s.l. \ x_1(\ln(x_1) - 1) + x_2(\ln(x_2) - 1) \leq 0 \end{aligned}$$

Notand $g(x) := x_1^2 + x_2^2$ avem ca $\nabla g(x) = [2x_1 \ 2x_2]^T$, iar egaland cu 0 am fi obtinut punctul stationar $[0 \ 0]^T$ care, insa, nu este definit in multimea X , deoarece $\nexists \ln(0)$. Astfel, stiind ca P este convexa, vom determina minimul din multimea fezabila X , iar acel minim va fi solutia problemei de optimizare.

Fie $f(x) := x_1(\ln(x_1) - 1) + x_2(\ln(x_2) - 1)$ cu gradientul

$$\nabla h(x) = \begin{bmatrix} \ln(x_1) \\ \ln(x_2) \end{bmatrix}$$

Egaland cu 0, obtinem punctul stationar $x^* = [1 \ 1]^T$ care este si punctul de minim cautat in problema. (este sigur punct de minim global, functia obiectiv fiind convexa)

2.2 Problema 2

Problema 2 este identica problemei 2 de la numarul 1.

2.3 Problema 3

Fie problema de optimizare

$$(P) := \min_{x \in \mathbb{R}^2} \{ \exp(x_2) \mid \|x\|_2 - x_1 \leq 0 \}$$

- a) Determinati problema duala.
- b) Determinati punctele *KKT* si natura lor.

Solutie a. Vom rescrie problema de optimizare sub forma:

$$\begin{aligned} & \min_{x \in \mathbb{R}^2} e^{x_2} \\ & s.l. \sqrt{x_1^2 + x_2^2} - x_1 \leq 0 \end{aligned}$$

Lagrangianul asociat este

$$\mathcal{L}(x, \lambda) = e^{x_2} + \lambda \sqrt{x_1^2 + x_2^2} - \lambda x_1$$

Problema duala se va formula

$$q^* = \max_{\lambda \geq 0} \left(\min_{x \in \mathbb{R}^2} \mathcal{L}(x, \lambda) \right)$$

Avem ca

$$\nabla_{x_1} \mathcal{L}(x, \lambda) = -\lambda + \lambda \frac{x_1}{\sqrt{x_1^2 + x_2^2}}; \quad \nabla_{x_2} \mathcal{L}(x, \lambda) = e^{x_2} + \lambda \frac{x_2}{\sqrt{x_1^2 + x_2^2}}$$

Cum pentru $x_2 = 0$ se obtine contradictia $1 = 0$, inseamna ca avem constrangerea $\lambda = 0$, ceea ce implica $x_2 = -\infty \in \bar{R}$ (iar $x_1 \in R$). Problema duala va fi data de functia duala $q(\lambda) = -\infty$ daca $\lambda = 0$ si $x_2 = -\infty$.

Solutie b. Problema de optimizare se observa ca este una convexa (atat functia obiectiv, cat si functia care genereaza constrangerea de inegalitate sunt functii convexe). Sistemul (*KKT* – *CP*) corespunzator va fi:

$$\begin{cases} \lambda \frac{x_1}{\sqrt{x_1^2 + x_2^2}} - \lambda = 0 \\ e^{x_2} + \lambda \frac{x_2}{\sqrt{x_1^2 + x_2^2}} = 0 \\ \lambda(\sqrt{x_1^2 + x_2^2} - x_1) = 0 \\ \lambda \geq 0 \\ \sqrt{x_1^2 + x_2^2} - x_1 \leq 0 \end{cases}$$

Daca impunem conditia $g(x) = 0$ sa fie activa, obtinem ca $x_2 = 0$ ceea ce conduce, in a doua ecuatie a sistemului, la contradictia $1 = 0$. Impunem, astfel, ca $g(x) \neq 0 \Rightarrow \lambda = 0$, ceea ce conduce la solutia $x_2 = -\infty$ in a doua ecuatie. Din constrangerea de inegalitate a problemei primale:

$$\sqrt{x_1^2 + x_2^2} \leq x_1 \Rightarrow x_1^2 + x_2^2 \leq x_1^2$$

obtinem ca $x_2^2 \leq 0$, insa conduce la contradictia $\infty \leq 0$. Concluzia este ca problema nu admite puncte KKT .